https://geshiyin.top/

工作经历

联想 2023年07月 - 至今
助理工程师 HLab 北京

- 主要负责AIGC大模型调研，端侧部署研究
- 了解 LLM推理运行、量化等知识以及多模态、RAG等应用以及DiT相关结构的文生图文生视频开源模型
- 主要五段工作项目
  - 数字人项目 2023.7-2024.1
    - 项目描述：该项目主要为将调研的所有内容做一个综合性demo项目，利用qwen1.5-7B-Chat作为大模型基座并使用vLLM进行推理加速，Geneface++作为对嘴模型完成数字人demo，最终作为展示项目呈现给公司SVP观看并得到肯定，今年CEO财年年报视频是以我们数字人demo模型为基础生成的
    - 角色：核心开发者，负责大模型推理加速部分以及Geneface++特定人物训练
  - 端侧GPU-LLM混合精度量化部署项目 2024.3-2024.5
    - 项目描述：该项目为利用2&4bit混合精度量化方案对LLM权重进行量化，使其精度在尽量损失减少的情况下速度能够接近达到端侧GPU的理论上限速度，最终使LLM PPL损失10%的情况下使模型推理速度符合产品要求
    - 角色：主要开发者，负责模型量化后对话能力恢复以及导出符合端侧部署需求的模型格式
  - 端侧NPU-GPU LLM异构推理项目 2024.7-2025.3
    - 项目描述：该项目为进一步挖掘硬件潜力，应对复杂多变的业务场景，开启本项目探索 NPU 与 GPU 协同工作模式，结合全算子量化技术，打造高性能异构推理引擎。具体为通过试验和理论结合的方式对LLM中全算子量化，使其精度在损失12%左右的情况下能够适配周易NPU运行并且prefill速度达到产品要求，同时进行了NPU-GPU PD分离实验验证，最终在刚发布的yoga pad pro 14.5上应用
    - 角色：主要负责人，负责模型量化、onnx导出、实验分析、团队合作沟通等主要工作
  - 端侧推理优化加速研究 2025.3-至今
    - 调研和复现高通平台上 LLM 推理优化加速方法，如 ssd 、 tiling 、算子转换等操作，研判其在自研npu平台上的可行性
    - 角色：主要负责人
  - NPU-LLM 编译 2025.7-至今
    - 调研 TVM 等编译算法在 NPU 上实现情况，学习 AI 编译器和 AI 硬件相关知识
    - 对合作的 NPU 厂家 软件编译工具链进行 code review，包括模型编译和量化
    - 角色：参与者

教育经历

中国科学院大学 2020年09月 - 2023年06月
电子信息 硕士 计算机网络信息中心 北京

- 研究方向：深度学习，表征学习，地理人工智能
- GPA：3.87/4.00(TOP5%)
- 所学课程：高级人工智能，模式识别与机器学习，知识图谱，数据挖掘等

华中科技大学 2016年09月 - 2020年06月
电子信息工程 本科 电子信息与通信学院 武汉

- 加权:86.88/100(TOP10%)
- 所学课程：信号与系统，电路，面向对象程序设计，计算机网络，操作系统，数据库等

学校项目经历

基于无监督学习的空间场景编码关键技术研究 2022年01月 - 至今
国家自然科学基金 面上项目

- 针对之前的工作做进一步研究，与UW-Madison助理教授高松和UGA助理教授买庚辰合作，研究基于无监督学习的空间场景编码模型，用于空间场景相似性匹配、城市规划、场景还原等下游任务
- 针对之前空间场景数据稀疏性问题，设计新的数据格式避免这一问题，同时采用对比学习思想创新设计适用于任意尺度地理空间场景数据的数据增强策略
- 对单个地理位置属性编码模型Space2Vec进行改进，设计空间场景编码模型Scene2Vec，相关成果已被International Journal Of Applied Earth Observation And Geoinformation期刊接收

大数据驱动的公共管理决策创新模式与集成示范平台 2018年09月 - 至今
国家自然科学基金 重大研究计划

- 负责跨部门共享和资源开放的公共管理大数据治理机制设计，大量调研相关文献，并基于多元利益主体博弈理论分析，构建公共管理大数据微观协同治理机制，同时以政府决策为导向，建立公共管理大数据宏观协同治理机制，将宏微观协同治理机制应用于城市群重大公共安全事件应急决策
- 负责《公共管理大数据集成平台理论、方法与应用》专著中《公共管理大数据质量评价体系》一节撰写

基于深度卷积神经网络的空间场景相似性匹配关键技术研究 2020年09月 - 2021年12月
国家自然科学基金 面上项目

- 突破传统基于关键字和邻近关系的地理搜索方式，使用空间场景进行相似性搜索，实现模糊查询、跨区域搜索
- 针对地理空间场景数据难直接输入深度学习模型的问题设计多通道矩阵数据格式表示，同时针对输入地理空间场
的问题，将卷积神经网络中的池化层改为空间金字塔池化使输出尺寸固定，利用三元组损失函数进行训练，并和
等方法进行比较，结果要优于这些方法
- 相关成果已发表于地理信息领域旗舰期刊《Transactions in GIS》

双子山智慧工地-主动防控安全预警系统 2021年09月

双子山自然土地 土动刚性实时预警系统 2021年09月 - 2022年09月

上海市重点工程 网页前端开发

- 负责网页中地图板块的搭建
- 利用百度地图 API 实现塔吊、履带吊等在地图中的可视化
- 与后台数据通信实现防撞预警机制

中国高校计算机大赛-移动应用创新赛 2019年03月 - 2019年10月

国家级比赛 iOS开发

- 开发视唱评测APP《视唱达人》，获得全国二等奖，曾上架App Store（后因迭代产品推出下架）

学术论文

- DeepSSN: A deep convolutional neural network to assess spatial scene similarity. Transactions in GIS, 26, 1914– 1938.（学生一作）
- SpatialScene2Vec: A self-supervised contrastive representation learning method for spatial scene similarity evaluation[J]. International Journal of Applied Earth Observation and Geoinformation, 2024, 128: 103743.
- M2T: A Framework of Spatial Scene Description Text Generation based on Multi-source Knowledge Graph Fusion[J]. Journal of Geo-information Science, 2023, 25(6): 1176-1185 https://doi.org/10.12082/dqxxkx.2023.230034

荣誉奖项

中国科学院大学计算机科学与技术学院三好学生	2021
华中科技大学优秀毕业生	2020
国家励志奖学金	2017
华中科技大学优秀学生干部	2017,2018,2019
华中科技大学新生奖学金	2016
华中科技大学学习优秀奖学金	2017,2018,2019
TI杯全国大学生电子设计竞赛校二等奖	2019
贝贝网种子杯编程竞赛排名11/1000	2017

学校经历

院研究生会体育部部长
四年本科期间担任班级班长
华中科技大学iOS club副主席

其他

- **技能：** Python/PyTorch/Swift/LaTeX/Markdown
- **Github：** https://github.com/yoghur
- **CSDN博客：** https://blog.csdn.net/qq_35700335?spm=1000.2115.3001.5343
- **语言：** CET4:639 CET6:514