中国科学院大学（中科院自动化所）

计算机应用技术专业（人工智能多模态方向）博士

出生年月：1996.08　　性别：男　　[redacted]

[redacted]　　地址：北京市中关村东路 95 号

教育背景

本科　　大连理工大学　　自动化专业

硕博　　中国科学院大学（中科院自动化所）　　模式识别国家重点实验室　　导师：刘静

- **研究方向：多模态预训练（图像/视频/音频 语义理解，文本生成，跨模态检索，问答），多模态大模型。**
- **以第一/共一作者发表五篇 CCF-A 会议/TRANS 期刊（NIPS，ICLR，ACMMM，TPAMI，TMM），获得 2 项国际竞赛冠军。**
- **谷歌学术引用 800+次，github 开源项目 600+ star。**
- 担任 TPAMI，TIP，NIPS，ECCV，ICLR，ICCV，ICML 等知名国际顶级会议和期刊的审稿人。

研究经历

视觉语义描述　　09/2020-06/2021

任务：为图片或视频生成自然语言描述，是计算机视觉与自然语言处理的交叉领域。

- "CPTR: Full Transformer Network for Image Captioning". Arxiv2021

提出全球**首个**基于全 Transformer 结构的**图像**语义描述网络，在 MSCOCO 公开数据集上的性能超过传统 CNN+LSTM 两阶段范式。

- "Video Captioning with Pretraining Techniques". **ACM MM 2021**

提出**多模态建模**视频语义，首次引入**预训练-微调**技术的**视频**语义描述方法，在 MSR-VTT 和 VATEX 两个公开数据集上取得了当时**最佳性能**。赢得 ACMMM21 视频语义描述竞赛**冠军**。

跨模态预训练模型　　09/2021–01/2024

任务：利用海量弱关联数据训练跨模态预训练模型，实现对跨模态内容理解与生成下游任务的泛化。

- "**VALOR**: Vision-Audio-Language Omni-Perception Pretraining Model and Dataset". **TPAMI 2024**

动机：面向于**视觉-文本**、**音频-文本**与**音视频-文本**等多模态、多类型（**跨模态检索、描述与问答**）等下游任务。

贡献：首次提出**百万级图文音强关联数据**，首次提出**图文音三模态**预训练模型架构 **VALOR**，提出**多模态分组策略**实现模态对齐、条件掩码预测等自监督任务的模态扩展，增强模型处理任**意两种或全部三种**模态数据的能力。在 **15** 个跨模态评测标准上取得了当时的 **SOTA** 性能。

- "**VAST**: A Vision-Audio-Subtitle-Text Omni-Modality Foundation Model and Dataset". **NIPS2023**

动机：对 VALOR 的**数据**和**模型模态**两个方面进行扩展，统一视频中**全模态**（视觉、音频、**字幕**与文本）的建模。

贡献：提出**单模态描述器自动标注-大语言模型信息整合**的**数据自动标注**流程。提出首个**大规模（27M）高质量全模态**视频文本数据集，文本同时与视觉、音频、字幕信息相关联。提出首个**全模态基础模型** VAST 可以同时接受四种或任意模态组合为输入。取得 20+个不同模态与任务（检索、描述、问答）的评测标准的 SOTA 性能(MSRVTT,MSCOCO,YouCook,Clotho,AudioCaps 等)。以**绝对优势，超过 Flamingo(deepmind), VideoCoCa(谷歌), GIT(微软), mPLUG(阿里), 混元(腾讯)和 InternVideo(上海 AI Lab)等国内外知名公司和研究院的大模型。后被上海 AILab follow 提出 InternVideoV2**。

- "**COSA**: Concatenated Sample Pretrained Vision-Language Foundation Model". **ICLR2024**

动机：当前视频-文本预训练数据（Webvid）对齐数据质量差。

贡献：提出**串联样本预训练**方法，利用现存**图像-文本数据**来训练**视频-文本预训练模型**。通过**按顺序拼接随机子在线构造伪长视频-长文本**数据集，此方法构造的数据具有低视觉冗余性和强事件级时序对应性。实验结果表明

对**长视频**-文本、**短视频**-文本和**图像**-文本任务有一致性提升。取得了最先进的性能，**创新性被多名审稿人高度评价**。

多模态大模型 **01/2024-07/2024**

- **中科院自动化所紫东太初大模型 3.0 研发**

任务：图像-视频-语音-文本全模态大模型，负责**视频**部分，优化**其在各个视频大模型 benchmark 上的性能。**

贡献：基于模态分组策略实现支持**多模态输入**（视觉，听觉，字幕）。提出**平衡时间采样与空间采样**的策略解决中长视频输入，支持**多时长输入**（10s 短视频，3min 中视频和 10min 长视频）。提出时间百分比表达支持**多粒度任务**（语义理解任务&精细**定位任务**）。在 msrvtt，anet 等 QA benchmark 性能超过 **llama-vid，videochat2** 等语义理解模型； 在 charades，anet 等**定位** benchmark 大幅超越 **timechat，vtimellm** 等视频定位模型，在 egoschema，videomme 等长视频 benchmark 上大幅超过 **moviechat** 等长视频模型。

实习/项目经历

- 中科院**自动化所-华为**紫东太初大模型 1.0 研发 **08/2021 – 11/2021**

任务&贡献：pytorch 代码迁移至 mindspore，大模型图像语义描述任务微调性能达标。

- **字节跳动 智能创作团队 智能多模态理解算法实习生** **06/2022 – 07/2023**

任务：训练通**用视频-语言预训练模型**，性能在评测基准上达到业界领先水平。

贡献：完成模型基础框架和 codebase 搭建，实现模型结构、训练方法、训练数据等方面的优化，大幅提高跨模态基础模型的性能，供公司研究使用，目前基于该基础模型**产出两篇文章**。在视频-文本跨模态下游任务实现**业界领先**。

比赛经历

- **ACM MM 2021 视频语义描述比赛 冠军** **06/2021 – 08/2021**

任务：为来自 YouTube 的视频片段生成英文文本描述。难点有视频内容开放多样、测试集与训练集分布差异大。

贡献：提出多模态强化视频特征表示：从表征、运动、区域、音频等多个维度进行高判别力的特征提取。设计基于注意力机制的多模态特征解码与融合，使用预训练策略、混合目标的强化学习训练策略，模型集成策略。性能大幅超过**清华、腾讯、人大**等队伍，获得**冠军**。

发表文章

- "VAST: A Vision-Audio-Subtitle-Text Omni-Modality Foundation Model and Dataset". ***NIPS2023*** (一作)
- "COSA: Concatenated Sample Pretrained Vision-Language Foundation Model". ***ICLR2024*** (一作)
- "Pre-training for Video Understanding Challenge: Video Captioning with Pretraining Techniques". ***ACMMM2021*** (一作)
- "VALOR: Vision-Audio-Language Omni-Perception Pretraining Model and Dataset". ***TPAMI* 2024**(共一，导师一作)
- "VLAB: Enhancing Video Language Pre-training by Feature Adapting and Blending". ***TMM 2024***(共一，导师一作)
- "Cptr: Full transformer network for image captioning". ***Axriv2021*** (一作)
- "Global-local propagation network for RGB-D semantic segmentation". ***Axriv2021*** (一作)
- "Enhancing Vision-Language Pre-Training with Jointly Learned Questioner and Dense Captioner". ***ACMMM2023*** (二作指导)
- "Sounding Video Generator: A Unified Framework for Text-guided Sounding Video Generation". ***TMM2023***. (合作)
- "GLOBER: Coherent Non-autoregressive Video Generation via Global Guided Video Decoder" ***NIPS2023*** (合作)

专业技能

- 熟悉**视觉、语言、音频等跨模态内容理解、生成、预训练**，熟悉**多模态大模型**，有丰富的**研究与参赛经历**。
- 熟悉 Linux、Python，熟练掌握 PyTorch 等开源深度学习框架。

部分荣誉

- ACMMM 2021 视频语义描述比赛冠军
- ECCV2022 视频时序动作定位挑战赛冠军
- 第八届中国国际"互联网+"大学生创新创业大赛金奖
- 中国科学院大学三好学生
- 中国科学院院长奖