教育背景

康奈尔大学 美国

理学硕士 **专业：计算机与信息系统** | GPA: 4.0/4.0 2023.8 – 2025.5

华中科技大学 武汉

工学学士 **专业：计算机科学与技术** | GPA: 90.3/100 2018.9 – 2022.6

- **奖项:** 优秀毕业生(06/2022) 科技创新奖学金(12/2021) 学习优秀奖学金（12/2019）

论文

1. Graph Hawkes Transformer for Extrapolated Reasoning on Temporal Knowledge Graphs. In Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (**EMNLP2022**), pages 7481–7493, Association for Computational Linguistics.

2. Great Memory, Shallow Reasoning: Limits of kNN-LMs. Accepted by **NAACL 2025**, main conference.

3. Beyond Syntax: Multi-language Code Authorship Attribution via Contrastive Sentence Transformers, to be submitted.

科研/实习经历

Sahara AI | Python，强化学习，RAG，Agent 机器学习算法工程师 2024.5 – 至今

- 主导开发了Sahara Knowledge Agent. 基于LangChain框架为Motherson Group开发多模态RAG系统，支持非结构化数据处理，混合检索和Agentic workflow。在Motherson的专有评估数据集上实现了**95%的Recall@10和85%的准确率**。
- 基于Chroma DB构建了40GB的向量数据库，支持多种格式文档, 并利用unstructured库进行高效的文本、图像和表格提取。
- 支持多种外部插件和工具调用，例如搜索引擎。支持意图识别，问题扩展，幻觉检测等功能，确保问答的质量。
- 开发了一个基于GRPO的RL Agent框架，能够自主决定调用检索工具查询Wiki数据库，回答复杂的多跳推理问题。框架支持多轮工具调用、多工具协同、基于规则的奖励机制以及自定义工具等功能，7B模型在复杂场景下的检索精度提高**35%** 。

Cornell NLP Lab 科研助理 导师 Alexander M. Rush 2023.9 – 至今

- 基于对比学习的方法训练了7B Sentence Transformer模型进行多领域和跨领域的作者身份识别。在HIATUS项目中排名全美第二。并且在多种语言的作者身份识别和代码识别领域都达到了目前最优结果。
- 应用k-means进行文档聚类，并设计聚类内采样方法构建困难的负样本和正样本，相比SOTA模型实现了**40.8%的R@8**提升。
- 通过GradientCache和LoRA进行 **32x** batch size和**46x** model size的扩展，利用**DeepSpeed**和PyTorch Lightning实现了多GPU训练。

猎户星空 **NLP算法工程师** 2023.5 – 2023.8

- 基于中文维基数据集和公司私有化业务数据集对预训练模型Orion-7B进行中文微调，在相应任务达到了GPT-3.5的性能。
- 应用 instruction-aware prompt tuning的思想，通过post-training 提高了模型在说明书问答等下游任务上的指令遵循能力。
- 为私有大模型开发了OpenAI兼容的流式APIs， 基于**FastAPI**实现异步并发，使用Apache Bench进行压测。
- 开发了大模型评估的框架，包含MMLU，BBH，GSM8K等20多种数据集和jailbreak benchmark，全面评估模型的性能。

华中科技大学 John Hopcroft Lab 科研助理 导师 何琨教授 2021.10 – 2022.10

- 提出了一个新颖的 TKG 推理模型，基于 Transformer 架构去捕获结构信息和时序信息来帮助推理。
- 将历史事件数据转为事件子图序列，使用**DGL**库聚合图结构信息，相比R-GCN能够更好的处理复杂的结构化图数据。
- 创新性地引入了Hawkes过程并构建了条件强度函数来建模时序信息，设计了关系敏感的时间编码，使实体预测 **MRR**提升了**4%-5%**，时间预测**MAE**提升了**44%-63%**。

项目经历

ALICE (AI Agent | Gaming AI) | C#, Python 2024.5 –至今

- 带领Cornell Tech团队开发了 ALICE，一款高效的 3D 场景创建工具，实现了游戏开发、3D 设计和 VR 场景构建的自动化。
- 构建了一个多智能体框架，能够基于用户指令自动生成并执行 **C# 代码**，从而创建或者改进当前的3D场景或物体，实现用户意图对齐、游戏组件模块化，并支持交互式、反馈驱动的工作流程。可以作为传统程序化工程的进阶代替。
- 在生成过程中收集人机交互指令与代码数据，构建数据飞轮，用于持续优化本地LLM的训练和对齐效果。

MiniTorch (Python, Numba, CUDA) 2023.8 – 2023.12

- 使用Python从零实现了**PyTorch API** , 支持神经网络架构，张量计算，模型训练。
- 实现了自动求导，反向传播，广播机制和深度学习库的内置函数。
- 对MiniTorch进行了并行化处理，通过SIMD在CPU上实现了5倍加速，并通过CUDA在GPU上实现了10倍加速。

竞赛奖项

- **全国大学生数学建模大赛全国一等奖(0.64%)**
- **第 11 届大学生数学竞赛省三等奖**

技术技能

编程语言: Python, C, C++, Golang, JavaScript, SQL, HTML/CSS,

框架/库: Pytorch, Scikit-learn, Matlab, NumPy, pandas, FastAPI, CUDA, MongoDB, Milvus, AWS, MySQL, Git, Linux, Qdra