何啸宇

电话: 186 5280 3116　　邮箱: ephxyscj@gmail.com　　出生年月: 1996 年 8 月

教育经历

- **中国科学院 计算技术研究所**　计算机软件与理论　博士　　2018 年 9 月—2023 年 9 月，北京
  - 研究方向: 理论计算机科学、量子计算、算法设计与优化
- **中国科学院大学**　计算机科学与技术　本科　　2014 年 9 月—2018 年 6 月，北京

工作经历

华为泰勒实验室—AI 芯片算法理论团队 Project Leader 研究方向: AI 算法芯片 codesign 2023 年 10 月—至今，上海

带领团队负责关键算法与芯片 codesign 设计优化，研究内容包括：

- **低精度 Attention 算法性能优化，**面向矩阵 FP4/向量 FP8 比特低精度
  - **方案:** 块感知精度重缩放技术：默认低精度，当块误差高于阈值时以高精度重算该块，重启率<5%；细粒度分析 EXP2 函数输入/输出格式数值误差，最小误差 FP8 格式选型
  - **效果:** 结合 FlashAttention，当 softmax 中 EXP2 及 Score 在 FP8 上计算时，实现模型准确率**无明显劣化。**支撑下一代芯片面积不变，向量计算**吞吐翻倍**，与矩阵 FP4 算力吞吐一致
- **Hybrid Attention 表示能力理论研究**
  - **方案:** 基于理论计算机科学-通信复杂信理论建模，理论刻画和比较不同注意力机制的表达能力。证明对于“顺序函数组合”的多步推理任务，L+1 层的全注意力可解，而混合网络（包含 L-1 层全注意力层和指数层 2^(3L^2)线性注意力层，可按任意顺序堆叠）无法解决该任务
  - **效果:** 严格理论证明了混合注意力与标准全注意力在表达能力上存在差距
- **稀疏 Attention 算法性能优化，**提高矩阵/向量算力利用率
  - **方案:** 探索 online+并行的近似 topK 算法，优化 DSA 向量算力瓶颈，模型准确率无损
  - **效果:** topK 单算子性能优化 25%+，DSA 端到端性能优化效果验证中
- **多场景专用芯片电路面积、功耗优化，包括：**
  - 端侧 ISP 硬化神经网络，逐通道非均匀量化方式实现平均 4 比特位宽，出图质量无损
  - 通信 DSP 模块，构建专用组合优化算法求解器，搜索最大复用计算图，模块计算量优化 30%+
  - NPU/CPU/GPU/oDSP 等场景专用电路亲和算法设计优化+算法友好电路设计优化

选列论文

- **BAPS: A Fine-Grained Low-Precision Scheme for Softmax in Attention via Block-Aware Precision reScaling**，共同一作，*ICML2026* under review. https://arxiv.org/abs/2602.02071
- **A Provable Expressiveness Hierarchy in Hybrid Linear-Full Attention**，共同一作，*ICML2026* under review. https://arxiv.org/abs/2602.01763
- **Scalable Algorithm Simplification Using Quantum AND Logic**，共同一作，*Nature Physics*
  - 基于算法理论创新结果，提出适用当前量子计算芯片的算法优化方法，提升量子搜索算法实现效率 3 倍
  - 与物理实验团队合作，首次硬件实现了规模达 6 比特的量子搜索算法
  - 结果作为**封面文章**发表于 **Nature Physics** 期刊，理论方案获 Google 团队引用并评价
- **On the Baer-Lovász-Tutte Construction of Groups from Graphs: Isomorphism Types and Homomorphism Notions**，*European Journal of Combinatorics* (SCI Q2)
- **On the Decision Tree Complexity of String Matching**，*European Symposium on Algorithms* (CCF B)

获奖情况

- **2025 年华为公司金牌个人奖（获奖比例 1%）**
- **2024 年 CCF 理论计算机科学博士学位论文激励计划（CCF 专委优博）**
- **ACM-ICPC 国际大学生程序设计竞赛亚洲区域赛 金奖×3；全国高中数学联赛一等奖、NOIP 一等奖**

其他

- **技能：**C/C++, Python, PyTorch, CUDA, Verilog