叶日平

AI 系统优化专家

男 | 汉族 | 34 岁

联系方式

15895833280

ripingye@163.com

技能

团队协助：技术项目管理，知识传承，人才培养

编程语言：C++、Python

AI 推理优化：LLM/AIGC 大模型推理优化，图算融合，AI 编译器(Ascend Tensor/TVM/MLIR/Triton)，NPU/GPU 计算架构，算子 Kernel 优化

数学能力：数学建模与求解，凸优化、组合优化

教育背景

硕士，东南大学 985 2014.9~2017.6

信息与通信工程专业

- 国家奖学金(2015)
- 全国数学建模二等奖
- 华为软件精英挑战赛二等奖

本科，东南大学 985 2010.9~2014.6

信息与通信工程专业

- GPA 排名 5/230，本校保研

工作经历

- **华为技术有限公司，麒麟(Kirin) AI 算法与解决方案部，AI 系统优化专家，2018.9~至今，职级 高级工程师 A（17）**

负责 NPU 高性能计算领域相关工作，主要涉及大模型端侧推理优化，NPU 计算架构建模，AI 编译器核心技术突破与落地，HPC 软件架构设计与系统分析；担任部门 Committer/MDE 等工作；人才培养和知识传承，培养多名新员工，公司内技术大讲堂相关技术与知识分享等。

- **华为技术有限公司，交换机与企业网关架构与设计部，云计算工程师，2017.6~2018.9**

负责 SDN 控制器相关软件进行云化，微服务化等工作。

项目经历

- **面向下一代昇腾 NPU 的 DSL 编程和算子自动融合技术研发（技术负责人）**

随着 open AI 的 triton 以及 NVIDIA 的 cu-tile 等 Tile-based 编程兴起，华为提出了自研 NPU 上基于 tile-based 的 DSL 编程和算子自动融合技术。作为该技术负责人之一，提出了基于 tile 的卷积深度融合方案，基于寄存器压力和关键路径的单核内指令乱序调度算法优化和基于 HEFT(Heterogeneous-Earliest-Finish-Time)的多核切分算法，在相关网络中验证中相比现有方案性能提升 15%以上，涵盖端侧 camera/音频/大模型等网络，相比 trition 具有自动融合的优势。

- **大模型端侧推理部署加速优化（方案设计&主导开发）**

7B 大模型入端在手机/车机上部署，需要在端侧受限的资源下提供极致的性能和功耗体验。通过 chunk 切分，低 bit 量化(3/4, per-group,per-head)，边加载边计算，稀疏内存排布，AI in flash 等方式，优化内存，内存占用降低 50%以上。通过算子融合，多分支并行，微切片，Attention 模块结合 NPU 硬件特性，设计 pipeline-attention 的优化方案，实现了 7B 大模型在手机上 xx tokens/s 的性能。实现了在手机上部署大模型商业目标。

- **图算融合技术项目（技术负责人&主导开发）**

提出了一种基于 TVM TE 的 graph 表达和图算融合编译优化技术，基于分层 schedule 的 TBE native 的图算融合方案，为 TVM/TBE 引入函数机制，据此形成分层 schedule 的图算融合方案，复用了大量算子的 DSL 和编译技术。该技术显著降低计算数据搬运，具有良好的泛化性，在手机端

拍照\音频模型中落地后，性能收益达 20%，功耗降低 40%。Mate70 平台 SmartISP 业务性能超目标 20%。

针对动态 Shape 场景，提出基于 TBE/TVM 的卷积动态 shape 编译优化技术，通过 符号化表达优化，scalar 优化和流水优化，将 NPU 上的 Conv2D 动态 Shape 算子性能提升 100%。

- **NPU 计算架构硬件建模与算子计算优化（技术负责人&开发者）**

NPU 硬件多 memory 层级和多 pipe 硬件单元以及复杂的数据交互通路，对于 cube 类算子，性能优化非常复杂。针对这种情况，提出了基于 NPU 硬件进行建模的方法，抽象出 memory 层级和大小以及数据通路，针对 cube 算子的计算优化问题，提出公式化建模切分，将计算切分问题转化为带约束的非线性整数规划问题，并通过近似松弛，转成可求解问题，使用一维搜索求，该方法相比手工方式效率提升 100%以上，性能提升 30%以上。

参与第一代自研 NPU 相关工作，参与 resnet50 网络 NPU 集群训练优化(59.8s)，达成当时的世界第一水平(2019 年)。

论文专利

1. 专利 MAS-Attention：Memory-Aware Stream Processing for Attention on Edge Devices. Canada(CA)，92071733. 第 5 发明人
2. 专利 基于码本的模数混合预编码方法. CN106253956A. 第 2 发明人
3. C. Xu, Riping Ye, Y. Huang, S. He and C. Zhang, "Hybrid Precoding for Broadband Millimeter-Wave Communication Systems With Partial CSI," in IEEE Access, vol. 6, pp. 50891-50900, 2018. 第 2 作者
4. Riping Ye, S. He, Y. Huang, B. Jiang and M. Su, "Power minimization hybrid precoding for millimeter wave communication systems," 2016 IEEE International Conference on Communication Systems (ICCS), Shenzhen, 2016. 第 1 作者
5. B. Jiang, R. Ye, Y. Huang, S. He, M. Su and H. Wang, "Comparison of single carrier and OFDM on 45GHz millimeter-wave communication system with hardware impairments," 2016 19th International Symposium on Wireless Personal Multimedia Communications (WPMC), Shenzhen, China, 2016. 第 2 作者