孙健龙

男 | 28岁 | 18862107390 | sjlweibuo@foxmail.com

教育经历

新南威尔士大学 **2019.3-2021.6**

人工智能 硕士

苏州大学 **2014.9-2018.7**

计算机科学与技术 学士

工作经历

IBM **2021.11-2025.4**

AI工程师（机器视觉），大模型工程师

一汽红旗智能问答大模型项目 **2024.1-至今**

设计并迭代开发大模型训练系统

主要工作：

- 定义大模型系统架构：基于企业私有云环境，设计多智能体协同框架，集成调度、训练与推理模块，支持 LLM 本地部署与 API 接入，并采用模块化微服务架构，确保系统高扩展性与可维护性。
- 构建数据敏感等级体系：通过字段分级、自动识别与白名单机制，仅保留 L0–L1 数据参与训练，对 L2–L3 数据实施脱敏或屏蔽处理；显著降低模型处理过程中的隐私泄露风险，保障数据全流程合规。
- 构建集成式 Prompt Engineering 框架：引入 RAG 检索增强机制融合企业内知识库，并加入Multimodal Chain-of-Thought技术，支持图表/文本/结构化数据联合推理，结合 Reflexion 机制迭代优化推理路径与响应质量，结合多轮推理与检索增强，有效提升回答准确率至 85%，平均减少信息响应时间 35%，显著增强业务查询与分析效率。

一汽齿轮数据分析大模型项目 **2023.5-2024.1**

设计基于小规模数据集的大模型系统

主要工作：

- 数据整合与特征工程优化：主导整合ERP、CRM、生产日志等多源业务数据，使用Python（Pandas、PySpark）和SQL进行数据抽取与转换，统一数据格式，处理缺失值和异常值。通过标准化处理和特征提取，提升模型在企业查询与分析任务中的准确率，并规范化输出，显著增强了模型对业务场景的适应能力。
- 小规模数据集上的模型微调：在工业质检小样本数据场景下，通过 LoRA 引入低秩矩阵近似，冻结原始参数，仅调整权重增量，在显存受限环境下完成高效训练；在工艺流程多分类任务中采用 Adapter Tuning，在模型层间插入轻量模块，支持多任务快速切换与迁移学习。最终在仅微调约 10% 参数的情况下，模型在质检缺陷预测任务中 F1-score 提升 12.4%，训练资源占用减少约 70%，显著增强了小样本场景下的实用性与部署效率。

强生心脏3D点云项目 **2021.11-2023.5**

设计心脏测距算法模型

主要工作：

- 使用RPM-Net，PF-Net，Farthest point sampling，Pointnet++等技术与工具完成3D点云的构建与测距，完成了算法的创新与多次迭代，成功与客户签订多期研发订单总价值800w美元，并成功发表4个相关专利。

技术栈

Python，Pandas，PyTorch，Pandas、PySpark、Sklearn，

LangChain，AutoGen，RAG，LoRA，Prompt Engineering，Reflexion

Java，RESTful API，