崔玉宝

北京 albertzhouzhou@gmail.com 17860710683 m17860710683 1998/12

教育经历

中国石油大学(华东) - 本科 计算机科学与技术 - 专业前30% - 校级优秀奖学金 2017/09 - 2021/06

专业技能

搜索：架构全貌、排序模型、BadCase诊断&泛化

AI 原生: LLM、prompt、RAG、Agent、Multi-Agent；扩散模型

容器技术：Docker、Kubernetes、argo-workflow

数据库：MySQL、Redis、iceberg、hive、Milvus

推理优化：量化、蒸馏

基础：RPC、http、Linux

编程语言：Golang、Python

证书&荣誉

MEG-卓越创新(个人)

MEG-进攻突破(团队)

AI 原生研发优秀团队

ownership(Searcher)

文化代言

卓越新人

紧迫感之星

CET-6

工作经历

Baidu - [搜索离线架构及基础技术组 - 系统与数据智能团队] 技术.后端功能开发.T5.高级工程师 北京 2021/07 - 至今

AI原生开放平台【Panda】----------[全盘方案设计&核心功能实现]

获奖

AI 原生研发优秀团队 - 百度技术战略委员会 | MEG-进攻突破奖

概述

构建企业级 LLM 应用开发平台，提供从知识管理、智能问答到复杂工作流的一站式解决方案。平台服务全厂 17,900+ 用户，累计调用量突破 1.1 亿。

核心成果

- 设计统一的大模型服务架构，实现对接 OpenAI、LangChain 等生态，支持多维度限流及负载均衡
- 构建智能知识库系统，基于 Milvus 向量数据库，实现文档自动抽取和问答对生成，支持多版本管理
- 开发可扩展的工具框架，集成 Prompt、Script、HTTP API 等类型，并延伸至 Flow、Agent、Q&A 等应用场景
- 实现 Agent 智能体协作系统，支持单/多智能体编排，适配复杂业务场景下的多角色协同
- 创新上下文管理机制，从时效性、重要性、相关性多维度优化对话体验

难点

- 设计灵活的工具抽象层，实现多类型工具的统一管理和调用
- 开发智能体编排引擎，解决多智能体协同推理和任务分配问题
- 构建分布式工作流框架，确保复杂流程的可靠执行

价值

- 显著提升研发效率：提供统一接入标准，降低 LLM 应用开发门槛
- 保障系统稳定性：完善的限流和监控机制，支持大规模企业级应用
- 提供多场景覆盖：支持通过如流、iframe、服务号、OpenAPI 等多种方式接入

职责

作为核心负责人，全面把控项目设计、开发、管理及运维，确保平台稳定运行和持续优化。

搜索排序 BadCase 归属拆分丨Case诊断 丨 问题泛化 丨 样本归因 丨 问题修复----------【项目负责人】

获奖

MEG-卓越创新（个人）

概述

构建端到端的模型质量提升体系,实现 BadCase 自动化分析与修复闭环

成果

- 研发智能归因系统,将 BadCase 精准分发至业务团队,相关性及分类准确率达 80%+,并提供可解释的分析链路
- 设计创新的"假设-验证-归纳"诊断框架,将人工分析时长从 15-30 分钟压缩至 1 分钟以内,同时提升诊断覆盖度
- 开发问题泛化机制,实现从单点问题到问题类型的映射,有效支持自动化问题发现和精准样本补充
- 构建多维度样本评估体系,从数据分布、标注质量、模型表现等维度量化分析问题根因,指导数据优化策略
- 基于 LLM 和检索技术,自动合成训练数据进行定向优化,实现 BadCase 修复同时提升模型泛化能力

价值

搭建"发现-拆解-诊断-修复"的全自动化质量提升闭环,显著提升模型迭代效率,持续增强模型性能

PForge(自研 Prompt 优化框架) ----------[创新实践丨独立开发]

概述

开发了 P-Forge 框架,这是一个专注于 LLM Prompt 优化的工具平台,可实现提示词的自动化优化与评估。

核心功能

• 多样化的 Prompt 模板体系(APE/ROLE/CRISPE 等),提供结构化的提示词编写范式
• 构建优化系统,支持批量评估和自适应调优,基于 LLM 反馈实现 Prompt 的智能迭代
• 开发评估框架,从多样性、一致性等维度对输出质量进行量化评估,支持自定义指标

技术亮点

• 创新性地将传统机器学习训练思路迁移到 Prompt 优化领域,实现了类似梯度下降的优化机制
• 采用混合优化策略,将 LLM 的语义理解能力与数值优化方法相结合
• 支持批量处理及并行评估,显著提升优化效率

价值

• 大幅降低批量数据上的 Prompt 工程的人工成本
• 提供可复现的优化流程,实现提示词质量的持续改进
• 易于扩展,可快速接入不同的 LLM 模型和业务场景

模型量化(PTQ)----------显著提效、结合已有机制&LLM推动自动化归因

- **离线量化提速70+%**：单机=>PaddleCloud，流程改造，多模型Infer并行优化
- **量化接入自动化**：实现测试流量自动转量化输入，以模型线上资源占用费用为优先级例行自动量化接入
- **任务失败自动归因**：基于 LLM+日志分析 实现失败自动归因，并给出异常定位和可能的修复方案

模型服务平台----------搜索GPU服务管理&模型测试、上线[平台负责人]

- 在线模型800+，管理GPU卡36000+，周级上线30+。权限管理[RBAC]、架构迁移[PHP=>Go]、GPU服务资源利用率优化

级联重训机制----------显著提效[全盘方案设计&功能实现]

- 算子抽象 + argoWorkflow 流程自定义，新业务接入开发耗时 3 人天=>20min

搜索场景模型Debug----------逆序分析[TermScore、SwapDiff]

分层多版本可溯源数据管理----------[核心开发]

爱好&评价

阅读 音乐 自行车 Coding 思维敏捷 责任心强 沟通能力 学习能力 创新思维 执行力强