曹罡语

电话：18045044057　　邮箱：18045044057@163.com
年龄：32　　最高学历：硕士

核心优势

医疗大模型全流程技术经验：深入理解并主导了医疗大模型从数据准备、继续预训练、指令微调(SFT)到人类反馈对齐(DPO/RLHF)的完整技术流程。具备将前沿算法（如 RAG）落地于复杂医疗场景解决实际业务挑战的核心能力。
医疗领域数据工程经验：擅长处理医药领域的**多源异构数据**（如诊疗指南、药品说明书、医学文献等），主导构建了高质量的医药数据集。在数据清洗、智能标注、知识增强方面有丰富实践，能够量化归因数据对模型性能（如合规性、可控性）驱动作用。
大模型算法研究与工程能力：熟悉 Transformer 及主流大模型架构，具备应用 PyTorch 等深度学习框架解决复杂医学问题的实践经验。主导实现了基于 RAG 的推理增强方案，并探索了数据合成等技术以解决医疗数据稀疏性问题，成功将模型幻觉率降低 40%。
技术领导力与前沿探索：作为 AI 技术负责人，从 0 到 1 组建并带领 10 人 AI 团队攻关核心算法。持续关注 LLM、多模态、agent 等前沿方向，并致力于推动其在医疗领域的应用与创新。

教育经历

2024/04-2027/06	清华大学	数据科学与人工智能	MEM
2018/09-2020/06	哈尔滨工业大学	交通信息工程及控制	硕士
2013/09-2017/06	哈尔滨工业大学	交通设备与控制工程	本科

注：2017.07 - 2018.08　研究生入学考试备考，并于次年成功考取

获奖经历

- **清华大学工业工程案例大赛一等奖：参赛作品：医院导分诊智能体；走访了燕达、湘雅等医院，实践医疗一线痛点需求分析到 AI 产品原型设计的全过程。**
- **具身智能仿真医疗服务机器人，获全国仿真创新应用大赛智能装备仿真赛道机器人系统仿真方向服务机器人组全国一等奖；探索并实践了具身智能及 agent 在医疗场景的应用。**

工作经历

2023.2 - 至今　　老百姓大药房　　AI 技术负责人

工作职责：

- **医疗大模型数据体系构建：**负责设计并实施服务于医疗大模型（LLM）的数据处理 pipeline。主导构建了覆盖数据采集、清洗、人机协同数据标注、向量化存储的全周期管理方案，为模型训练提供了高质量的“数据养料”。
- **大模型训练与对齐(SFT& DPO)**：主导了医疗领域模型的后训练工作。设计并落地了训练数据质量评估框架，量化分析了 SFT 数据与 RLHF 数据分布对模型合规性、准确性的影响。通过构建高质量指令与偏好数据集，有效提升了模型在医疗问答、报告生成等任务上的性能。
- 知识增强与检索增强生成（RAG）： 针对医疗问答场景中事实性要求高、知识更新快的问题，主导设计并实现了融合外部权威知识库（如临床指南、药品库）的 RAG 方案，通过优化检索和重排模块，将模型幻觉率降低了约 40%。
- 长尾场景模型优化与数据增强： 为解决新特药、罕见病、复杂症状组合等训练数据稀疏的问题，探索并应用了多种数据增强技术（如回译、同义词替换），并小范围尝试了基于大模型的指令生成方法来合成高质量 SFT 数据，有效提升了模型在长尾场景下的召回率和准确率，提升了模型泛化能力。
- 技术领导与算法攻关：作为 AI 团队技术负责人，主导核心算法模块的技术选型、架构设计与代码评审。制定了团队的 AI 技术路线图，将业务挑战拆解为具体的可执行的算法任务，并推动技术方案最终转化为可衡量的模型性能提升与产品指标。

2021.11-2023.02 **荣耀终端有限公司** **数据算法工程师**

工作职责：

- **AI 数据平台架构设计：**负责供应链预测模型的 **AI 数据中台架构设计**，主导从海量业务系统、数据入湖及 AI 训练的端到端数据平台化链路建设。通过梳理业务对象与逻辑实体，构建了可复用的数据资产与特征工程体系，确保了数据源的准确性与模型特征工程的可行性。
- **数据质量与标准体系：**建立并推行覆盖核心业务域的数据质量监控体系与数据标准。通过自动化探查与校验规则，主动识别并治理数据不一致、缺失等问题，为下游的数据挖掘与机器学习任务提供了高质量的数据基础。
- **知识图谱基础构建：**负责维修方案、故障现象等关键领域知识的结构化与图谱化梳理。这项工作为后续构建基于知识图谱的智能诊断系统奠定了高质量的知识库基础。

2020.06-2021.11 **中兴通讯** **数据治理工程师**

工作职责：

- **元数据与数据血缘管理：**主导公司级元数据管理平台建设，负责核心模块的技术方案设计。通过解析 ODS 层数据结构，成功构建了清晰的表级数据血缘图谱，为数据资产追溯与影响分析提供了关键支持。
- **主数据系统治理：**全面负责公司物料主数据的全生命周期管理，通过建立标准化与维护机制，显著提升了供应链数据的准确性与一致性，为下游核心业务系统的稳定运行提供了关键数据保障。

项目经历

医药零售 AI 营销智能体 (2024.12 - 至今)

项目角色：项目技术负责人

一、 项目背景

为解决连锁药店在核心盈利业务（营销非商返利）中面临的效率低下、转化瓶颈、合规风险高三大挑战，作为项目核心负责人，从 0 到 1 主导设计并落地了一款 AIGC 营销智能平台。项目旨在通过大模型技术，重塑医药营销内容的生产与分发模式，实现自动化、精准化、合规化的内容运营闭环，最终提升营销 ROI。

二、 技术栈

核心模型技术： 大模型 SFT/DPO、RAG、PEFT(LoRA)、langchain、React

核心系统组件： Python (FastAPI)、VectorDB、Docker

三、 项目贡献

0. 顶层设计与技术选型

职责：作为项目经理，向业务方与管理层进行了多轮方案汇报与价值阐述，成功获取项目立项与资源支持。

主导技术选型：通过对主流商业 API 与开源模型在**生成质量、合规性、推理成本**三个维度进行 Benchmark，明确了通用模型在医药领域的局限。基于评测结果，最终确立了“私有化部署开源大模型，并通过持续领域微调”的技术路线。

1. 知识体系构建与数据治理模块

职责：为确保生成内容的专业性与合规性，主导设计并实现 RAG 流程。开发自动化 ETL 管道，整合内部药品库与外部法规文件，构建向量化知识库。在推理时，通过检索精准的上下文注入 Prompt，强制模型生成有据可依的内容，大幅降低事实性错误和合规风险。

2. 核心模型训练与业务对齐模块

领域知识注入： 为解决通用大模型“不精通”医药的问题，主导了模型的指令微调(SFT)过程。利用构建的 SFT 数据集对基础模型进行参数高效化微调（PEFT，如 LoRA），成功将医药行业知识注入模型。（通过对模型在特定领域任务集上的 Bad Case 分析，迭代指令数据，使模型采纳率提升了 30%）

业务偏好对齐： 为使模型生成内容更具“营销感”，主导实施了直接偏好优化(DPO)。通过策划 A/B 测试，结合运营人工评估，构建了上万条“优选-弃选”数据对，将业务偏好成功传递给模型。

3. AI 能力产品化与业务赋能模块

核心功能产品化设计：针对业务团队不具备提示词工程能力的痛点，创新性地设计并产品化落地了“参数化提示词智能体”。agent 可以支撑业务人员通过文本（yaml）和简单勾选的方式输出结构化 prompt，为运营人员提供了低门槛提升 AI 工具效率的能力。

四、 项目成果

运营效率提升： 将营销内容平均生产周期压缩 50%，相关人力成本降低 60%，团队整体内容生产效率提升 30%。

业务价值实现： 通过 AI 驱动的精准营销文案，赋能线上营销活动点击转化率(CTR)平均提升 15%，初步形成决策闭环。

合规能力强化： 构建的全链路合规防火墙，使营销文案的自动化敏感词拦截率高达 99.2%，显著降低了企业运营风险。

项目名称：医药零售门店数字化转型 – ‘百药师’AI 荐药系统，2023.9-2025.3
项目角色：项目经理+数据算法负责人
项目角色：项目经理 & 数据工程师
一、 项目背景
为应对全国大型连锁药房普遍面临的两大核心挑战：1）服务非标化：2000+门店员工专业水平与服务意愿参差不齐，导致顾客体验不一；2）盈利能力瓶颈：线下咨询的成交转化率与客单价毛利增长乏力，严重制约了公司的持续发展。本项目旨在通过 AI 技术打造标准化的、专家级的辅助诊疗与荐药服务，赋能一线店员，实现服务质量和销售业绩的双重突破、同时避免合规风险。

二、 技术栈
AI & 机器学习: Transformers (BERT), CRF, XGBoost
知识图谱 & RAG: Neo4j, LangChain, Faiss,Embedding 模型

三、 项目贡献
0. 顶层解决方案设计与技术决策
职责： 作为项目的整体负责人和架构师，深度调研一线业务，向公司管理层及业务方汇报并论证了项目的商业价值与技术可行性。设计了“线上 AI 大脑+线下门店终端”的整体解决方案架构。在技术选型上，为确保一线店员的信任与采纳，诊断模型放弃了端到端的黑盒方案，转而采用更具可解释性的 XGBoost 模型，并创新性地设计了“症状贡献度”的可视化方案。

1. AI 诊断的数据基座构建与治理
职责：针对一线海量的非结构化问诊对话，主导构建了 AI 诊断的数据治理体系与标注平台。通过制定精细化的标注规范，并引入多轮交叉验证机制，成功交付了 10 万+高质量实体标注数据集。该数据集不仅是本次模型训练的“养料”，更沉淀为公司未来在医药 AI 领域的核心数据资产。

2. 核心模型矩阵的构建与优化
自然语言理解模块(NLU): 为精准理解顾客口语化描述，主导设计并实现了基于 BERT+CRF 的症状实体识别模型。针对线下门店对实时性的严苛要求，通过模型剪枝与推理优化，成功将响应延迟控制在毫秒级，满足了实时交互需求。
AI 辅助诊断与可解释性模块: 主导构建了 AI 辅助诊断模型，并将“可解释性”作为核心设计原则。通过量化并展示 XGBoost 模型对每个症状的诊断决策贡献度，为店员提供了直观、可信的诊断依据，极大提升了业务方的信任度和采纳意愿。

3. 领域知识图谱与 RAG 增强模块
职责： 为解决 AI 模型的“幻觉”问题并确保医学专业性，主导设计了以“科室-病症-药品”为核心的医药知识图谱，整合了药品说明书、临床指南等多源异构数据。通过定制化的 Embedding 与智能分块策略，显著提升了 RAG 系统的检索精准度与事实一致性，成功将模型的知识性幻觉率降低了约 40%。

四、 项目成果

核心业务指标提升： 店员咨询转化率提升约 25%，整体毛利率增长 1.5%。
运营效率优化： 核心商品库存周转天数缩短 15%，人工审核成本减少 20%。
合规与风险控制： 合规风险拦截率达到 99%以上，确保了患者隐私保护与药品广告法规的全链路合规。