程彬

38岁 本科学历 手机：13575768008 邮箱：ckey_dou@163.com

个人总结

- 异构计算与AI框架专家：10年以上经验，精通GPU（CUDA/cuDNN/OpenCL）、DSP、NPU等异构硬件编程与性能优化，深度理解其微架构。
- 全栈式AI系统架构师：具备从底层芯片仿真、异构计算框架设计，到AI训练/推理框架（MindSpore）开发与调优的全栈能力。
- 深厚的性能优化功底：在端侧（手机、摄像头）、云端（服务器），参与数个关键算法与模型的深度性能优化。
- 扎实的工程实践：精通C/C++/Python，对高性能计算、分布式系统、编译技术有深刻理解。

工作经历

华为技术有限公司 | 杭州

主任工程师/高级工程师| 2010年12月 - 至今 *核心成就与职责*:

1. 大模型推理优化与高性能算子库构建

- 架构设计：作为算子SE，主导大模型推理算子库的架构设计与开发，涵盖细粒度高性能Host API、Tiling Cache机制、可调可测等特性，支撑算子高效执行；
- 融合优化算子开发：负责融合Pass、Norm类高性能算子设计与开发；
- 性能提升：通过Norm类融合、MOE router大算子、MLA预处理融合大算子、高性能FA/PA kernel等优化手段，显著提升Qwen/DeepSeek等主流大模型的推理性能。

2. 主导自研AI框架MindSpore核心模块开发与优化

- 单机执行框架：负责MindSpore单节点执行框架的架构设计与核心模块开发，包括数据抽象、内存管理与算子抽象等，为框架奠定坚实基础。
- 动态Shape特性：主导动态Shape特性的设计与开发，涵盖前端编译与表达、Runtime执行、算子InferShape和KernelMod重构等关键环节，提升框架灵活性。
- 图算融合与编译器：作为主力参与算子编译器、图算融合的设计与开发，优化计算图执行效率，并作为第一作者提交相关专利一篇。

3. 异构并行计算框架设计与关键算法优化

- 框架设计：主导异构并行框架的数据、算子、流图等核心模块设计，提供统一、高效的并行编程模型。
- 算法优化：负责人脸检测算法在海思3559A芯片的移植与性能优化，优化后性能较串行版提升2倍以上，较原有手动并行版再提升10%；推动框架落地Mate10拍照HDR后处理算法，实现2倍性能提升，并降低峰值内存40%。

4. 自研芯片功能级与时钟精确级仿真

- 芯片仿真：作为核心成员，参与自研无线嵌入式CPU/DSP芯片的功能级和时钟精确级仿真，验证芯片设计正确性与性能

杭州新世纪信息技术有限公司

开发工程师| 杭州 | 2009年7月 - 2010年10月

- 参与衢州烟草车辆监管系统、浙江烟草商业专卖监管系统等多个企业级Java Web项目的后端开发与维护工作，积累了初步的软件工程与项目管理经验。

专业技能

- 编程语言：精通 C/C++，精通 Python，熟练 Shell/AWK
- 异构计算：精通 CUDA, cuDNN, OpenCL；熟悉 GPU/DSP/NPU 微架构与性能调优
- AI框架：深度参与 MindSpore 开发；熟悉 TensorFlow/PyTorch 应用与原理
- 硬件/芯片：有芯片仿真（CA/CX）、硬件抽象层（HAL）设计经验
- 软技能：技术规划、架构设计、跨团队协作、项目主导、代码评审、新人指导