陈洋

意向岗位: 多模态算法工程师

基本信息

电话：15652611604

邮箱： 15652611604@163.com

性别：男

出生日期：1993.5.8

现所在地：北京

最高学历：硕士

求职意向

意向岗位：多模态算法工程师

意向城市：北京

自我评价

- **专业能力**：6年人工智能算法工作经验，在两家AI企业担任算法工程师，历任算法组长、算法负责人职务，主导完成多个重点项目。形成算法研发、目标拆解、团队管理等可复用的SOP。

- **团队协作**：团队采用公开公平的规章制度来带队，并做好带头作用。比如，制定研发排期表，做好每

项目经历

2025.06 - 2025.10 **图灵智慧眼项目**

项目背景：

- 主导研发一款基于多模态方案的交互式智慧学习助手。

项目职责:

1. 主导项目团队搭建，协调跨部门资源，保障团队高效协作和项目进度。
2. 负责项目需求拆解与多模态大模型方案选型，确保方案可行性和落地性。
3. 统筹多模态大模型数据采集、构建、训练、评测和性能优化全流程工作。

解决方案：

1. 构建带场景交互的多模态视觉对齐数据与指令微调数据，并通过多阶段训练、评测和版本迭代优化。
2. 采用KvCache、PrefixCache、LMCache等技术在模型推理阶段，进行推理加速，提升模型性能。

项目成果:

1. 成功构建多模态视觉对齐数据7.2万条，指令微调数据13.5万条；通过多阶段训练和优化，视觉多模态大模型在保留通用能力的前提下，垂直场景多任务的平均准确率从69%提升至97.5%。
2. 实现模型推理性能近 3+倍提升，显著优化同参数数量级别模型的运行效率，降低成本。

2024.07 - 2025.10 **图灵AI精准学项目**

项目背景：

- AI赋能教育的发展趋势下，参与研发图灵AI精准学产品，旨在通过智能技术提升教学与学习效率。

项目职责:

1. 构建面向文档和表格的RAG系统，支撑业务数据的智能检索与应用
2. 设计智慧教务助手智能体方案，并负责其私有化部署落地；
3. 研发AI讲题和AI自讲评测的技术方案，满足精准学核心业务需求

解决方案：

1. 设计并实现了向量召回结合重排机制的文档 RAG方案，以及基于宽表结构NL2SQL的表格RAG方案。
2. 设计并部署支持集成文档与表格RAG能力的单智能体教务助手。
3. 研发可灵活编排、交互的多智能体方案，在保障扩展性的基础上满足精准学业务需求。

项目成果:

1. 文档RAG在标准测试集上的准确率达到97%，表格RAG准确率达85%。
2. AI讲题方案准确率从65%提升至96%，AI自讲评测准确率稳定在95%以上。

2024.07 - 至今 **情感陪伴机器人项目**

职位

项目背景

日进度跟踪，及时提供协助。跨部门时，明确好目标，管理好时间节点，做好沟通，保证按时按量交付。

- **驱动模式**：习惯使用目标和数据驱动模式来解决日常生活和工作的问题，通过制定长期目标，拆解短期，再不断用实践数据来论证和达到目标。

- **持续学习**：具备快速学习掌握新技术的能力，且坚持长期阅读最新的技术论文和行业技术文章，保持技术体系和行业认知不掉队。

- 为满足情感陪伴与儿童教育场景中对实时、高质量语音交互的需求，主导情感陪伴机器人语音交互系统的研发。

项目职责:

1. 负责方案选型和交互框架设计、语音交互系统构建。
2. 主导多语言ASR系统从方案选型、模型训练到服务架构设计与工程落地的全流程研发。
3. 深度参与TTS研发和推理提速、声纹识别、声音克隆、记忆存储和基于 MCP 的智能体工厂的方案选型和研发。

解决方案：

1. 设计并实现了一套基于ESP32芯片的实时语音交互框架，支持语音实时交互打断，多轮对话，IOT指令识别，满足低延迟、高稳定性要求。
2. 针对儿童场景语音特点，构建高质量多语言训练数据集，经历Whisper、SenseVoice等模型迭代优化，最终实现支持多语言的ASR模型。
3. 采用AsrRouter+消息队列+AsrWorker+TritonServer的分布式服务架构，支持WebSocket长连接，实现高并发处理与动态扩展。

项目业绩:

1. 从0到1完成硬件语音交互方案，成功推动公司获取首个意向客户并促成后续项目快速商业落地。
2. 多语言ASR模型词错率（WER）低于3%，支持五语种混合识别，有效覆盖目标广大目标用户的需求。
3. ASR服务性能较基线提升50%，服务成本降低近30%，系统具备高可用、易扩展特性，支撑情感陪伴机器人和核心语音业务的稳定运行。

2022.05 - 至今 **深度学习模型量化加速及降本**

职位

项目背景：

- 业务大规模量产提出降本增效的需求，亟需优化业务核心AI模型的推理效率，包括LLM、TTS及视觉模型，以提升性能并降低成本。

项目职责:

1. 面向情感陪伴机器人业务，负责对LLM及TTS等关键模型进行推理加速。
2. 面向绘本业务降本需求，负责对相关视觉模型进行量化与加速优化。

解决方案：

1. 针对LLM推理，结合使用LmCache、prefixCache、连续批量化等技术，优化GPU利用率，显著减少请求延迟。
2. 针对TTS推理，通过微服务架构优化、连续批量处理、减少CPU与GPU间通信瓶颈等方式，提高音频生成吞吐量。
3. 针对视觉模型，采用压缩量化、TensorRT微服务化等技术，在保证精度前提下降低计算与存储开销。

项目成果：

1. 在固定单GPU（3090）与同等输出质量条件下，LLM推理性能提升7倍。
2. 在固定单GPU（3090）上，TTS服务在同等条件，QPS从18提升至50，吞吐量显著增强。
3. 在固定GPU（V100）与输入分辨率条件下，关键点检测模型Superpoint的QPS提升4倍以上，有效支持业务降本目标。

工作经历

2020.11 - 至今 **北京光年无限科技有限公司**

深度学习算法工程师（负责人） | 人工智能

工作内容:

1. 研发：负责文本和多模态大模型的算法研发，包括方案选型、模型训练和相关智能体的应用研发等，主要落地应用在教育和情感陪伴场景。
2. 降本：负责图灵核心业务模型的推理性能优化和持续降本工作。
3. 管理：24年下半年至今担任算法负责人，负责公司老业务的迭代维护，和新业务的拓展，难题攻坚。负责团队管理、制定绩效人员激励。

工作业绩:

1. 成功完成公司首代自研文本LLM，并牵头推动在网信办拿到算法和大模型备案号，上线后帮助公司增加了30%+的订单。自研多模态 LM帮公司将传统视觉业务实现了转型，帮助公司拓展了多个新品类。
2. 持续进行降本增效，提升了多个核心模型性能，包括Superpoint、TTS、文本LLM等。服务成本教三方降低近30%。
3. 带队期间团队高效完成了三个公司重点项目，成员自身能力得到持续激发，团队执行效率提升近30%。

2019.09 - 2020.11 **北京一览群智科技有限公司**

计算机视觉算法工程师 | 人工智能

工作内容:

1. 负责OCR算法研发、技术方案迭代，应用落地和工程化。
2. 参与政企、金融的大型项目现场POC，并驻场进行研发、私有化系统部署和后期维护。
3. 负责整个OCR系统性能优化、工程化及容器化。

工作业绩:

1. 完成了OCR目标检测算法的多次迭代，文本检测的准确率提升10%，OCR整体准确率提升6%，在（票据、研报、保单等）核心场景的识别准确率远超同行。
2. 完成OCR系统的工程化、微服务化和容器化，使得服务稳定性和可用性大幅提升。同时容器化部署后，极大地缩短了现场部署实施时间，降低了近30%的研发人员成本。
3. 快速响应客户的核心诉求，帮助公司在多个POC中，拿下大额订单。

教育经历

2012.09 - 2016.07 **北京建筑大学**

地理信息系统 | 本科

2016.09 - 2019.07 **北京建筑大学**

测绘工程 | 硕士

相关技能

- 技术基础能力：熟练使用Linux开发环境，掌握C/C++、Python编程语言，具备CV与NLP领域深度学习算法原理基础，能熟练运用Pytorch框架开展算法研发工作
- 多模态算法实践：熟练掌握CV基础原理，在OCR、目标检测、图像分割等方向有实战经验，同时具备NLP和 Speech相关算法能力，可支撑多模态任务研发。
- 模型训练与管理：熟练使用SWIFT、LLama-Factory训练框架，掌握DeepSeed分布式工具，能独立完成HF、MS模型与数据托管仓库的日常维护和管理。
- 智能体相关：熟练掌握 ReAct、LangGraph、Coze等框架的使用，熟悉 MCP、Agent Skills 和 A2A 等智能体标准交互协议。
- 模型优化与全链路开发：掌握NCNN、TensorRT、VLLM等模型优化加速框架，可独立完成从需求分析、模型选型、研发到云端及移动端部署的全流程工作
- 工程化部署能力：熟悉Dockerfile、Jenkins工程编写，能通过Jenkins、Docker完成算法测试与私有化定制部署，保障模型落地效率

技术分享

- 知乎: AI领域知识分享

NLP专栏：https://www.zhihu.com/people/ting-gu-shi-de-ren-99/posts

- GitHub: 开源项目代码库，链接：https://github.com/chenyangMl