624d8c94d100724f1nx93Ny1FlpVxo-8WfOYWOGjl_7SMxM~

饶尧-算法工程师-3.5 年

饶　尧
Rao　Yao

个人资料 PERSONAL

年　龄：25
毕业学校：西华大学
学　历：本科
专　业：物联网工程

联系方式 CONTACT

手　机：15108480629
邮　箱：15108480629@163.com
地　址：北京

求职意向 Career Objective

工作性质：全职
期望职位：算法工程师
工作地点：北京

工作经历

2021.6 – 2024.11
算法工程师
北京东方国信科技股份有限公司

1.语料处理与优化：负责训练语料的收集、清洗与优化，确保数据质量，为模型训练提供高质量输入。
2.NLP 技术研发与优化：主导智能对话系统中的命名实体识别、关系抽取、文本摘要、文本分类等核心 NLP 任务的研发工作；负责 NLP 算法的开发、优化及技术方案的规划与实施。
3.业务语料抽取：从数据应用角度出发，精准抽取业务所需分析的相关语料，支持业务决策与模型优化。
4.前沿技术调研与落地：根据业务需求，调研前沿技术并推动其在项目中的落地应用，提升技术竞争力。

2024.11 – 2025.2
算法开发工程师
京东

1.项目上线支持：协助完成 Eva 智能体项目的上线工作，确保系统稳定运行并满足业务需求。
2.数据预处理：负责履约单号数据的清洗、转换和标准化处理，为后续模型训练提供高质量数据支持。
3.模型开发与部署：主导大模型的训练、部署及测试流程，确保模型性能达到业务指标要求。
4.训练策略制定：根据项目需求和数据特性，制定高效的模型训练策略，优化训练效率和模型效果。

个人技能

1、熟悉 Python 语言，具有良好的编程规范；
2、了解逻辑回归、SVM、KMeans、随机森林、XGBoost、LightGBM 等机器学习算法原理；
3、熟悉 Transformer 等深度学习模型架构及其原理；
4、熟悉 PyTorch 框架，掌握模型量化、剪枝、知识蒸馏概念及其理论；
5、了解 ChatGPT、ChatGLM、StableDiffusion、Qwen2-VL、Deepseek 等模型架构及其原理；
6、具备实现 Fine-Tuing、Prompt-tuning、PET、P-Tuning、Agent、Multi-Agent、RAG 等相关技术的能力；
7、本人求实负责、敢于担当、韧性较足、期待与优秀的您共事；

项目经验

Project1：联通数智人项目

项目简介：联通数智人项目旨在通过对联通语料数据的深度分析、优化和模型迭代，提升自然语言处理系统的性能和用户体验。项目聚焦于意图识别、模型优化、用户画像、语料管理等关键领域，通过技术创新和系统完善，构建了一个高效、智能、稳定的语言处理平台，为联通的数字化服务提供了强大的技术支持。

工作职责与成果：

1.意图识别模型开发与优化，面对海量的意图分类数据，需要构建高效准确的意图识别模型，采用 MacBert 模型对包含 70 个意图类别的百万数据进行训练，开发意图识别模型，对模型进行多次调优迭代，优化模型参数和架构，提升模型性能，成功训练出准确率高、泛化能力强的意图识别模型，为自然语言处理任务提供了可靠的技术支持。

2.模型推理加速与优化，在实际应用中，MacBert 模型的推理速度较慢，需要优化以满足实时性要求，采用 TextCNN 对 MacBert 模型进行知识蒸馏，将知识从复杂的 MacBert 模型迁移到轻量级的 TextCNN 模型，调整知识蒸馏的策略和参数，优化 TextCNN 模型结构，确保模型在压缩后仍保持较高的性能，知识蒸馏后的 TextCNN 模型大小为 23MB，F1Score 为 0.92，推理速度显著提升，单条样本平均推断时间从 MacBert 的 1.591ms 降低到 0.124ms，极大地提高了系统的实时性。

3.正则冲突检测与优化，在正则配置中存在冲突问题，导致部分语料命中多个正则且意图不同，影响模型的准确性和稳定性，开发正则冲突检测功能，对全国 31 省所配置的 21 万条正则进行冲突检测，设计高效的冲突检测算法，对海量正则规则进行逐一排查和分析，检测出 3573 条规则冲突，解决了正则配置中的冲突问题，提升了模型的准确性和稳定性。

4.用户画像与猜你想问功能开发，为了提升用户体验，需要实现用户画像并基于画像推荐用户可能感兴趣的问题，采用决策树算法建立用户画像，根据用户的特征和行为数据构建画像模型，结合用户画像数据，开发“猜你想问”功能，通过算法预测用户可能提出的问题，实现了用户画像和“猜你想问”功能，使用户在询问之前就能收到可能感兴趣的问题推荐，提升了用户交互体验。

5.缠绕语料分析与优化，训练语料中存在缠绕语料（多个相近的语料在不同意图中），影响模型的准确性和泛化能力，开发缠绕分析功能，对训练语料进行缠绕解除，通过算法分析语料的相似性和意图差异，对缠绕语料进行重新分类和调整，缠绕解除后的训练语料经过模型迭代，显著提升了模型的准确性和泛化能力。

6.智能标注功能开发与优化，人工标注语料成本高、效率低，需要优化标注流程，实现智能标注功能，采用单模型、多模型、语料相似度、大模型等四种智能标注方案，设计智能标注算法，结合人工审核，确保标注数据的准确性和一致性，实现了从最初的 70 意图类别标注到二分类审核的转变，大大降低了人工成本，提高了语料标注效率。

7.用户诉求聚类分析与意图重构，需要挖掘用户的潜在诉求，优化意图分类体系，对千万数据进行诉求聚类分析，配合业务人员进行意图重构，采用聚类算法对用户数据进行分析，识别出潜在的诉求模式，结合业务需求重新定义意图分类，解决了父子意图以及意图边界缠绕问题，优化了意图分类体系，提升了模型对用户诉求的识别能力。

8.语料均衡优化，语料样本不均衡，影响模型的训练效果，实现语料压缩和语料扩增功能，对样本不均衡的语料进行处理，设计语料压缩和扩增算法，对少数类样本进行扩增，对多数类样本进行压缩，使语料分布更加均衡，经过语料均衡处理后，模型迭代提升了 F1 指标，显著提高了模型的性能和泛化能力。

Project2：TuringCenter

项目简介：TuringCenter 项目致力于推动大模型技术的落地应用，通过深入调研前沿技术并结合实际业务需求，开发并优化了一系列功能模块，旨在提升系统的智能化水平和用户体验。项目涵盖了从自然语言处理到知识管理的多个领域，通过技术创新和系统集成，实现了高效、精准的业务支持，为公司业务发展提供了强大的技术驱动力。

工作职责与成果：

1. 负责提升用户交互体验，优化报表推荐功能。采用 TF-IDF 算法实现报表推荐功能。通过分析用户问题的关键词和语义特征，利用 TF-IDF 算法计算问题与报表的相关性，并根据相关性排序推荐关联报表。成功实现了用户提问时对关联报表的精准推荐，提升了用户获取信息的效率和满意度。
2. NER 任务实现与部署，需要从文本中提取关键实体（时间、地点和指标）以支持后续的业务处理，采用 TENER 模型实现命名实体识别（NER）任务，提取文本中的时间、地点和指标实体，使用 Flask 框架将 NER 模型进行部署，并与后端系统进行对接，确保模型能够实时处理业务请求，成功实现了高效的 NER 模型部署，能够准确提取关键实体信息，为业务系统提供了稳定的数据支持。
3. 大模型优化与业务集成，需要优化大模型的输出效果，并实现与公司系统的无缝集成，采用 baichuan 模型实现 Prompt-tuning，对输出结果进行话术润色；同时采用 COT（ChainofThought）对问题进行逐步拆解，配合 Agent 实现了大模型自动调用公司系统的 API，并完成相关业务功能，通过优化和集成，大模型的输出更加符合业务需求，提升了用户体验和系统效率。
4. 意图识别技术选型与优化，业务需求频繁变动，需要一种灵活且高效的意图识别方案，分别采用 MacBert+PET 和 MacBert+P-tuning 技术实现意图识别，对比两种技术方案后，选择了 MacBert+P-tuning，通过模板的形式，实现了用少量样本训练模型也能接近用大量样本训练模型的效果，成功解决了业务需求变动频繁的问题，降低了样本数据的依赖，提升了模型的适应性和灵活性。
5. FAQ 问答系统开发，需要为 FAQ（常见问题）语料开发高效的问答系统，采用基于 ChatGLM 模型进行 Fine-Tuning，优化问答效果，对 ChatGLM 模型进行微调，使其更好地适应 FAQ 语料的问答需求，开发出高效的 FAQ 问答系统，能够快速准确地回答用户常见问题，提升了用户体验。
6. 文档数据抽取与优化，需要从 word、pdf 和 excel 文件中抽取数据，但面临水印干扰、表格跨页和表格嵌套等问题，开发文档数据抽取工具，解决水印干扰、表格跨页和表格嵌套问题，设计并实现数据抽取算法，优化处理流程，确保数据的准确性和完整性，成功解决了文档数据抽取中的复杂问题，提高了数据抽取的准确性和效率。
7. RAG 知识库问答系统开发，需要解决大模型幻觉问题和实时问题，提升问答系统的准确性和时效性，基于 LangChain 技术实现 RAG（Retrieval-AugmentedGeneration）知识库问答，整合知识库数据，优化问答流程，确保系统能够实时准确地回答问题，开发出高效的 RAG 知识库问答系统，显著降低了大模型幻觉问题，提升了问答的准确性和实时性。
8. 多任务模型整合，需要将意图识别和 NER 任务整合到一个模型中，以提高系统效率和资源利用率，采用基于 ChatGLM 模型+LoRA 实现了意图识别和 NER 任务，通过 LoRA（Low-RankAdaptation）技术对 ChatGLM 模型进行优化，将多个任务模型合并到一起，成功整合了意图识别和 NER 任务，提高了系统的效率和资源利用率，为业务提供了更高效的技术支持。

Project3：延保履约 Eva 智能体

项目简介：对用户线上申请的理赔单号进行辅助审核以及线下的自动化审核。拥有图片审核，产品故障分析，理赔条款分析，场景审核等多种专员能力，通过审核效能提升带来的人力成本收益 74.5 万，自动审核+辅助审核采纳率达到 93.4%。获得京东大模型项目激励。

工作职责与成果：

1.参与 EVA 智能体项目上线工作。负责编写接口代码，实现用户点赞或点踩时对大模型输出结果的实时刷新功能。通过接口编程，确保用户操作能够即时触发模型输出的更新。成功实现了用户交互与模型输出的动态同步，提升了用户体验。

2.监控大模型在业务中的实时表现。对大模型输出结果进行规则化校验。分析不满足校验规则的输出，找出问题所在。通过分析发现了模型输出中的潜在问题，为后续优化提供了依据。

3.探索多模态大模型的应用。调研并完成了 Qwen2-vl-72B 模型的部署工作。通过技术研究和实践，将模型成功部署到系统中。为项目引入了先进的多模态大模型，拓展了项目的功能。

4.对多个大模型进行批量测试。测试京东集团大模型接口 gpt-4o-0806、Chatrhino-81B、Doubao-pro-32k、deepseek-chat、Qwen2-vl-72b 模型。通过测试分析各模型的性能和兼容性，最终选择 Doubao-pro-32k 进行上线，确保了项目的顺利推进。

6.处理标注数据与模型输出的格式差异。由于标注人员的标注数据是单个标签，而大模型的输出是 json 数据。对标注数据进行预处理，还原成模型输出的格式。方便了后续的微调训练，提高了数据的可用性。

7.优化 EVA 智能体的推理流程。EVA 智能体中每个专员之间是 pipeline 的串行推理，上一个专员的输出会是下一个专员的输入。对数据进行二次预处理，确保训练所用数据与线上模型推理的入参数据保持一致性。提升了模型推理的准确性和效率。

8.对 Qwen2-7b 模型进行微调。采用 Qwen2-7b 模型对场景审核专员数据进行微调。分别进行了 lora 微调和全参微调。微调前模型的准确率为 10.91%，lora 微调后的准确率为 83.64%，全参微调的准确率提升至 92.73%，显著提高了模型性能。

9.建立反思功能，利用履约成本、满意度、客诉信息等非常丰富的外界信息反馈和审核人员的示范操作让 agent 持续优化，自我更新，是 agent 设计的核心。其中试错是完成任务的关键，利用试错产生的反馈数据和 badcase 采用大模型提示词，基于角色的反思，基于反馈模型的可学习的 prompt 反思，一级强化学习训练等技术手段，建立系统的反思和自我调整机制，持续优化决策内容，决策流程，记忆内容，prompt 提示词等。使准确率提升 2 个百分点。