北京理工大学
BEIJING INSTITUTE OF TECHNOLOGY

年龄：23 丨所在地：北京丨 2026 届毕业生

教育背景

北京理工大学（985）（保送） 控制工程（A+） 硕士 **班长** **2023.09-2026.06**

华东理工大学（211） 自动化 本科 **班长** **2019.09-2023.06**

- 学习情况：硕士平均成绩 ***90.72***，本科平均成绩 ***89.28***，本科专业排名 ***2/87***（**前** ***2%***）
- 荣誉奖励：**上海市奖学金**、2 次特等奖学金、3 次一等奖学金、3 次社会奖学金、优秀毕业生、2 次优秀学生干部、优秀共青团员
- 竞赛获奖：第 12 届全国大学生数学竞赛（非数学类）三等奖、第 12/13 届上海市大学生数学竞赛（非数学类）三等奖

实习经历

北京智谱华章科技股份有限公司 **大模型算法实习生** **2025.03-至今**

- **实现多模态模型推理能力提升**：设计了一种**多轮自迭代训练方法**，构建正负偏好数据对训练奖励模型，使用拒绝采样思想迭代生成高质量训练数据来实现模型自我进化。具体方案：1. 利用 DeepSeek-R1 根据人工标注的图像描述和问题生成多个候选回答，并采用多个 LLM Judge + 人工筛选高/低质量数据；2. 使用高质量数据对 Qwen2-VL-2B-Instruct（策略模型）进行 SFT + GRPO 训练；3. 使用高/低质量数据组成的正负偏好数据对训练 Qwen2-VL-2B-Instruct（奖励模型，输出头替换为线性层 + Tanh 的标量输出）；4. 使用更新后的策略模型重新生成多个候选回答，并通过更新后的奖励模型评分筛选新一批高/低质量数据；5. 重复执行步骤 2，3，4。主测试集准确率 ***44.2->82.5***，达到同尺寸 ***SOTA***（Qwen2-VL-72B-Instruct 主测试集准确率 78.0），视觉数学推理测试集 MathVista 准确率 ***43.0->63.7***，MathVision 准确率 ***12.4->22.3***。
- **参与 Zwrite 产品研发**：参与并实现了一套基于 Multi-Agent + Workflow 的深度研究报告生成产品。具体方案：1.增强用户输入的 Query；2. Planning Agent 对增强 Query 进行拆解，生成多个 Task；3.根据 Query、Tasks 和参考大纲（用户上传）生成一系列问题与用户交互，生成新 Tasks；4. SubAgent 借助多个 Tool 对每个新 Task 进行深度研究；5. Planning Agent 收集 SubAgent 返回的研究内容，参考大纲生成最终报告。**负责所有 Agent 模型训练**，收集并清洗 Claude 生成的多轮对话及报告数据作为冷启动数据，选择 GLM-Z1-32B 作为 Agent 模型，对其进行 SFT（冷启动）+ 端到端 RL 训练，提升模型多轮对话、Tool_Call 等能力。在 LLM Judge 与人类专家制定的 Checklist 相结合的评测指标中达到 ***SOTA***，原 SOTA 得分 80.3，GLM 得分 ***53.1->84.7***。
- **参与端到端模型训练自动化工具研发**：参与并实现了一套覆盖数据处理、模型训练、权重转换、模型部署及评测的全自动训练推理评测工具，仅需一个配置文件和脚本即可实现训练推理评测的闭环流程。**负责 GLM-4-32B 的自动化流程**，包括：一键生成训练格式数据及蒸馏数据、启动基于用户配置的自动化训练、转换 Megatron 训练权重至 Text Generation Inference（TGI）权重、部署 TGI 权重并进行性能测试、专项和通用精度测试。使用该工具分别在混合了智谱内部通用数据的三个专项领域数据集上对 GLM-4-32B 进行 SFT，意图识别准确率 ***69.3->95.7***，数学推理准确率 ***58.2->86.4***，金融问答准确率 ***66.8->84.1***，模型通用能力保持不变，验证了该工具与 SFT 有效性。该工具极大简化了模型训练推理评测流程，可为用户节省约 ***95%***的时间。
- **对比 DPO 与 LoRA 训练效果**：使用同一批风格偏好数据集分别对 GLM-4-32B 进行 DPO 和 LoRA 训练（LoRA 仅使用 Prompt 和 Chosen 数据），采用多个 LLM Judge 评测训练后的模型，结果显示 DPO（***31.8->87.2***）和 LoRA（***31.8->84.2***）的平均得分基本持平，证明在某些任务场景下，DPO 相比 LoRA（SFT）并不能显著提升生成质量。

项目经历

基于强化学习的多无人机对抗决策方法 **项目负责人** **2023.10-2024.11**

- **项目背景**：旨在解决无人机在高度复杂的动态环境中的自主决策问题，提升其在复杂空战场景中的作战能力。
- **提出基于 Transformer 的分层强化学习架构**：将 PPO 算法的 Actor 网络拆分为上下两层，并分别集成 Transformer Decoder。上层战斗决策网络负责态势感知与战术决策，生成战术意图并转化为下层网络可执行的目标指令；下层控制策略网络直接控制无人机的舵面动作，负责执行上层网络下达的战术指令。
- **设计基于动态奖励机制的课程学习与自博弈训练框架**：将无人机对抗任务分解为“基础攻击”、“防御强化”、“综合对抗”三个渐进式学习阶段，动态调整各阶段奖励权重，指导无人机分阶段掌握基础战术能力。在课程学习所得基础策略上，引入基于 Elo 评分的自博弈机制，并采用基于修正胜率的迭代终止标准，通过无人机与历史策略持续对抗，驱动策略自主进化，显著提升策略在复杂对抗环境中的泛化能力。
- **项目成果**：设计并实现基于 MAPPO 的多无人机对抗决策方法，显著提升无人机在复杂战斗环境中的自主决策能力，同时实现一个支持自定义配置参数的多无人机实时对抗仿真演示软件。已基于此项目申请 **2 项专利**，在投 **1 篇 IEEE 论文**。

腾讯开悟人工智能全球公开赛 **比赛链接** **2024.05-2024.11**

- **比赛目标**：训练一个智能体，以最少的步数从起点走到终点，并尽可能多的收集宝箱。
- **实现思路**：使用 PPO 算法，设计三阶段课程学习奖励函数。第一阶段：仅给予靠近和到达终点的奖励；第二阶段：在第一阶段基础上添加低权重靠近和得到宝箱的奖励；第三阶段：将终点视作最后一个宝箱并增加权重。
- **比赛成绩**：初赛排名 ***20/150***，进入决赛。

个人技能

- 掌握 Python 、Shell 脚本，熟悉 Linux 系统、Docker 容器，了解并行分布式训练框架 Megatron / Deepspeed。
- 熟悉 PPO、GRPO、DPO 等强化学习算法，了解 RLHF 实现，拥有大模型监督微调、强化学习微调、数据蒸馏等
- 具备优秀的文献阅读能力，了解大模型经典论文，如 Transformer、BERT、GPT、InstructGPT、ViT、MAE、CL