[redacted]
https://github.com/icoderzqliu

教育经历

中国科学院大学 - 计算机技术 硕士 2022.08 - 2025.06

研究方向：自然语言处理，大语言模型　导师：**杨敏** 教授

GPA：3.81 / 4.00

相关课程：自然语言处理、高级人工智能、深度学习、机器学习、算法设计与分析、数据结构、操作系统、概率论与数理统计

武汉大学 - 计算机科学与技术 本科 2018.08 - 2022.06

GPA：3.87 / 4.00

发表论文

Google Scholar

1. Long Context is Not Long at All: A Prospector of Long-Dependency Data for Large Language Models

Longze Chen*, **Ziqiang Liu***, Wanwei He*, Yunshui Li, Run Luo, Min Yang. **(共一)**

Annual Meeting of the Association for Computational Linguistics **(ACL 2024, CCF-A)**. [paper] [code]

- 通常的LLMs扩长：（1）推理时直接修改位置编码，（2）进一步用更长的数据训练LLMs
- ProLong：**更长的训练数据也有好坏之分**，增强 LLMs 的长文本建模能力到底需要具有长距离依赖的数据而不是长度很长的数据。
- ProLong 综合多种因素为每个训练样本分配一个长依赖得分，从而筛选长距离依赖数据。仅利用ProLong筛选的少量的长文本数据进行扩长训练，就可以取得比使用全量数据进行扩长训练更好的结果！

2. TP-Link: Fine-grained Pre-Training for Text-to-SQL Parsing with Linking Information

Ziqiang Liu, Shujie Li, Zefeng Cai, Xiangyu Li, Yunshui Li, Lei Zhang, Min Yang.

The International Conference on Computational Linguistics **(COLING 2024, CCF-B)**. [paper]

- 为了解决对话式Text-to-SQL任务中的句法共指消解问题以及链接信息冗余问题，提出了一种预训练框架，旨在通过利用链接信息来改进对话式Text-to-SQL解析任务。语句链接预测（Utterance Linking Prediction）任务可以显式建模上下文中的词级共指关系，有效解决了多轮对话中复杂的共指和省略问题；基于SQL树状编辑距离的模式链接预测（Schema Linking Prediction）任务，以建模多轮对话中高细粒度的模式链接关系，解决了信息冗余问题。
- 在多轮Text-to-SQL数据集CoSQL和SParC上都达到了目前的SOTA指标。

3. II-Bench: An Image Implication Understanding Benchmark for Multimodal Large Language Models

Ziqiang Liu, Feiteng Fang, Xi Feng, Xinrun Du, Chenhao Zhang, Ge Zhang, Shiwen Ni.

Annual Conference on Neural Information Processing Systems (submitted to **NeurIPS 2024, CCF-A**). [paper] [dataset] [code] [page]

- 多模态大模型真的懂图片的弦外之音么？我们的II-Bench证明，在弦外之音的理解上，现有的MLLMs依旧与人类相差甚远。II-Bench包含七大图像种类(漫画，meme图等)，六个主要领域(生活，艺术等)，共1434张图片samples，充分考验了多模态大模型的理解暗示的能力。
- 对弦外之音的理解和"玩梗"能力不光是一个有趣的topic，也充分反映了语言模型捕捉图片内的高度抽象的visual details并进一步进行联想和推理的能力，以及MLLM对图片信息的高阶感知能力。

4. Marathon: A Race Through the Realm of Long Context with Large Language Models

Lei Zhang, Yunshui Li, **Ziqiang Liu**, Jiaxi Yang, Junhao Liu, Min Yang.

Annual Meeting of the Association for Computational Linguistics **(ACL 2024, CCF-A)**. [paper] [dataset]

- 随着模型上下文窗口的扩大，现有的长上下文基准测试已不足以评估大型语言模型的长上下文理解与推理能力。
- Marathon以单项选择题的形式开发了一个全新的长上下文评估基准测试，用于快速、准确和客观地评估大型语言模型的长上下文理解能力。在Marathon上评估了几种最新、最流行的大型语言模型以及三种有效的长上下文优化方法。展示了LLM的长上下文推理和理解能力，并验证了这些优化方法的有效性。

5. COIG-CQIA: Quality is All You Need for Chinese Instruction Fine-tuning

Yuelin Bai, Xinrun Du, Yiming Liang, Yonggang Jin, **Ziqiang Liu**, Min Yang, Shiwen Ni, Ge Zhang.

Annual Conference on Neural Information Processing Systems (submitted to **NeurIPS 2024, CCF-A**). [paper] [dataset]

- **弱智吧 is All You Need?** 使用“弱智吧标题+GPT-4回答”微调后的大模型评估结果，超过了其他的SFT指令集数据。
- 从英文翻译的中文数据集不能很好地契合中文的语言习惯和文化背景；用AI生成的数据集质量难以保证，容易出现事实性错误；即使是人工标注的数据集，也存在数据量小、覆盖领域不全面等问题。
- 从中文互联网的各种知识源头直接收集数据，比如知乎、豆瓣、百科、小红书等，经过一系列严格的清洗和人工标注，构成高质量、多样化的中文指令微调数据集COIG-CQIA。

6. Deem: Diffusion models serve as the eyes of large language models for image perception

Run Luo, Yunshui Li, Longze Chen, Wanwei He, Ting-En Lin, **Ziqiang Liu**, Tongliang Liu, Min Yang, Binyuan Hui.

Annual Conference on Neural Information Processing Systems (submitted to **NeurIPS 2024, CCF-A**). [paper]

实习经历

米哈游网络科技股份有限公司 - 算法研究员 逆熵-鹿鸣 2023.11 - 至今

1. 大语言模型的扩长**预训练**与评测：对预训练后的自研模型进行二阶段扩长预训练，提出长依赖数据筛选算法ProLong(Accepted by ACL 2024)，对训练数据进行打分筛选，然后时候筛选之后的数据进行大规模扩长预训练，大幅提升模型的长文本能力，在短文本上的性能也没有下降。负责长文本模型在ppl上的评测，以及在多个下游任务(Lost-in-the-middle、LongBench、NeedleInAHaystack)上的全面评测，同时负责在短文本上的性能评测(lm-evaluation-harness)。
2. Model Merge：研究各类模型融合算法，构建更大的base模型，保证直接merge后的模型在通用benchmark上没有明显掉点。
3. 代码大模型：探索代码大模型的预训练数据组织形式，参与代码大模型的数据筛选、训练，7~8B规模的代码大模型效果超过CodeLlama、Llama3-8B。负责代码大模型在HumanEval、MBPP、Swe-Bench上的全面评测。
4. 大模型安全：大模型的输出可能是不可控的，在上线过程中会引发很多安全问题。基于RAG架构完成大模型上线中faq必答模块的开发，使用faiss来构建索引，当用户问题命中预定义好的问答对时，利用大模型改写答案后输出。同时负责开发大模型输入和输出的安全检测模块。
5. FP8训练：负责Megatron-LM利用FP8的训练。FP8训练利用 E5M2/E4M3 格式，具备与 FP16 相当的动态范围，适用于反向传播与前向传播。FP8 训练在相同加速平台上的峰值性能显著超越 FP16/BF16，并且模型参数越大，训练加速效果越好，且其与 16-bits 训练在收敛性和下游任务表现上无显著差异。

字节跳动科技有限公司 - 算法实习生 Data-电商 2023.06 - 2023.11

1. 负责大模型在电商内容安全场景下的智能进审和审核任务的优化。
2. 构建领域任务benchmark，对各个backbone在业务数据上进行sft，统一对比效果挑选出能力最强的backbone；提出了rule-to-asr的领域知识注入方法，再进行sft能够显著提升下游任务的效果；细化任务功能，不断提升模型能力，最终的模型能够给定输入文本，输出违规的区域和违反的规则，在各个场景的PR均达到70+%，在线上流量较大的两个场景下的PR能达到90+%，最终整体的policy acc达到91.52%，area acc达到91.39%，all acc达到88.96%，效果和功能均好于线上模型，并成功上线。
3. 参与中文领域大模型、多语言领域大模型的开发。大模型在领域数据上继续预训练，以更好地进行领域知识学习；然后通过构建指令微调原子任务、提升指令数据的多样性、增大生成任务的比率、调整领域与通用数据的比率等各种方法，以提升大模型的指令跟随能力。

中国科学院深圳先进技术研究院 & 深圳得理科技有限公司 2023.04 - 至今

1. 工作内容：法律大语言模型 (Legal Large Language Model)。我们构建了法律垂直领域的大型语言模型，用于法律咨询，法律问答以及法律文书撰写等。负责模型在法律领域上的指令微调（SFT）。
2. 为进一步提升模型的知识容量和事实准确性，增强了法条法规检索工具和案例检索工具，使得模型能够精准引用法律条文等事实类知识来回答用户提问，同时向用户展示相关的经典法律案例以供参考。
3. 使用vLLM、TensorRT-LLM部署模型上线。

荣誉奖项

中国科学院大学三好学生	2023年度，2024年度
武汉大学优秀毕业生	2022年度
武汉大学优秀学生奖学金	2019年度，2020年度，2021年度

比赛奖项

千言：第二届面向事实一致性的生成评测比赛 2023.01 - 2023.05

面向事实一致性生成任务的指令微调语言模型 (11/691) 中国中文信息学会 & 百度

2021 中国大学生计算机设计大赛 2021.01 - 2021.08

《智能婴儿监护器》 国家级二等奖 中国大学生计算机设计大赛组委会

2020 中国大学生计算机设计大赛 2020.01 - 2020.08

《领感》 国家级二等奖 中国大学生计算机设计大赛组委会

专业技能

- **技能：** 了解大模型的前沿技术，有大模型预训练、继续预训练、微调的相关经验，了解FP8的原理，有FP8预训练的相关经验，掌握Megatron-LM、LLaMA-Factory等框架对大模型进行训练，有长文本(Long Context)、模型融合(Model Merge)、代码大模型(Code LLM)、检索增强(RAG)的相关研究经验，有大模型的开发落地部署经验。
- **证书/执照：** CCF CSP认证考试累计排名12.86%，计算机技术与软件专业技术资格——软件设计师
- **语言：** CET-6（530）、CET-4（545）
- **兴趣爱好：** 篮球，健身，电影，音乐