[redacted]

教育背景

清华大学，计算机科学与技术系，硕士 2023.9 - 今

中国政府奖学金，GPA: 3.80 / 4.00

上海交通大学，自动化，本科 2017.9 - 2021.6

上海市政府三等奖学金，GPA: 3.44 / 4.3，百分制: 83.73

工作/实习经历

智谱 AI，大模型算法实习生 2024.07-今

- Agentic RAG
  - 构建 RAG 评测框架，对比长文本模型 GLM-9B-128k 和 RAG，期望通过优化 RAG 框架可以达到比长文本模型效果更好。
  - 针对现有数据集如 HotpotQA 和 NQ 长度不够的问题，无法有效地评测出长文本模型与 RAG 的区别，所以对该数据集增加干扰项，使数据集处于 50k 个 token 以上。
  - 调研其他开源 Agentic RAG 框架，如 Qwen-Agent，接着将其和现有的评测框架合并。

Wise AI Malaysia，AI 工程师 2021.11-2023.8

- 人脸活体检测
  - 主导人脸活体检测模型算法研发，包括数据收集、模型设计、训练、评测和改进。
  - 在 ResNet 的基础上微调。训练数据集来源于公开数据集、企业内部、第三方购买、自己手动收集的和生成数据。
  - 通过多轮迭代训练，同时在评测数据集验证其有效性，经过第三方机构攻击测试，该模型成功达到了符合国际标准 ISO-30107 Level 1 的合规要求。

科研/项目经历

DiaKoP: 基于多轮对话的知识密集型问答系统 (CIKM Demo) 2024.2-2024.6

- 搭建一个可解释的、事实性的、支持多轮对话的知识密集型问答系统。
- 通过语义解析将自然语言转换成符号表示，利用其在知识图谱推理和检索出相关信息、最后借助大语言模型语言生成的能力给出事实性答案。
- 由于语义解析不一定准确，因此利用 DeepSpeed，采用 ZeRO-2 策略，结合 QLoRa 微调 CodeLlama 7B，目标以用户指令作为输入，输出为修正后的符号表示。
- 以 Gradio 作为前端，基于 FastChat 和 vLLM 加速推理框架部署经量化的 Llama3-70B 作为基座模型。

文生用户界面: Text-to-UI 2023.9-2024.1

- 从网上收集以‘用户需求-Tailwind css’对为形式的数据集。
- 采用 LoRA 策略微调 CodeLlama-7B。输入为自然语言，输出为前端界面代码。
- 为了验证模型的有效性，和其他模型进行定性比较，包括 Bard、GPT 3.5、CodeGeeX 和 ChatGLM。

本科毕业设计: 基于图神经网络的脑肿瘤图像检索 2020.12-2021.6

- 利用图神经网络 (GNN) 对图像之间的关系进行建模，每个节点表示两个图像之间的相似度，因此通过图节点分类任务实现图像检索。
- 与传统没有采用 GNN 的基线模型对比，基于 GNN 的方法在精确率指标上能达到 2-8% 的提升。

学术论文

DiaKoP: Dialogue-based Knowledge-oriented Programming for Neural-symbolic Knowledge Base Question Answering
Zhicheng Lee*, Zhidian Huang*, Zijun Yao, Jinxin Liu, Amy Xin, Lei Hou, Juanzi Li
Conference on Information and Knowledge Management (CIKM demo), 2024

Deep Semi-Supervised Learning via Dynamic Anchor Graph Embedding Learning
Zihao Wang, Enmei Tu, **Zhicheng Lee**
International Joint Conference on Neural Networks (IJCNN), 2021