[redacted]

2023 年 2 月 – 至今｜美团｜LLM（LongCat） AI Infra技术专家

- **LLM 推理（Inference）架构（2023.2 - 2025.9）：**
  - 推理框架建设：构建美团 LLM 推理框架，支持ContinueBatching、PageAttention等主流特性。建设大规模PD分离推理架构，实现计算与资源的精细化调度，支持异构算力的推理。构建Speculative Decoding等推理策略支持，支持Medusa、Eagle和MTP等主流投机策略优化。
  - 大规模MoE推理架构：设计并优化 MoE 分布式推理体系，在 EP / TP / DP / CP 多维并行下实现高通信和计算overlap，显著提升推理吞吐降低延迟。基于该架构支持DeepSeek在线推理，tps达到100以上，达到业界的sota水平。
  - LongCat系列模型支持：与算法团队紧密开展模型-系统联合设计，推动 LongCat-Flash 等系列模型在推理侧结构优化、通信的overlap，最终构建shortCut、Zero-Expert和MLA等技术选型，支持LongCat-Flash模型训练并开源，推理tps达到130+，吞吐是DeepSeek一倍以上，性能达到同规模下行业领先水平。支持LongCat-Ultra等万亿规模参数在线推理，为未来更大规模的推理效率探索提供了基础能力。
- Agentic LLM系统架构**（2023.7 - 2025.12）：**
  - Agentic Infra：构建大规模的Agent Infra架构，从 Agent Runtime、环境与记忆系统到分布式调度与资源管理形成完整技术栈；稳定支撑 GPU 集群上百万级并发 Agent 推理与执行。建设多类复杂任务环境，包括 GUI Agents / OSWorld、Code Agent、“类原神”交互式环境、DeepSearch 以及美团业务域任务，支持 2000+ 任务并行规模化运行。构建可复现实验沙箱、轨迹回放（Trajectory Replay）机制 与统一评测基准，显著提升实验复现性与算法迭代效率。
  - Agentic RL系统：构建支持千卡规模Agentic RL 系统，覆盖 PPO / GRPO / GSPO 等主流算法。构建训推协同的一体化架构，打通 Agent 推理、环境交互、数据采集与 RL 训练闭环，支持 Streaming Rollout、Partial Rollout 等高效采样策略，提升单位算力下的有效样本吞吐。深度优化系统调度能力和训推能力，提升整个系统算力MFU。推进训推一致性等关键能力建设，提升大规模 RL

[redacted]

训练的稳定性与可控性。支持全模态omini的全链路架构，提升强化学习的效率优化。

- LLM Data系统架构负责人**（2023.2 - 2025.12）**
  - 建设大模型预训练数据，支持大模型训练数据超过50T token。建设日均抓取50亿的大模型数据系统，支持万亿级别的网页链接库。支持多模态预训练的数据大规模采集。
  - 建设大模型数据解析链路，构建高质量的分层数据解析策略（Tra/Bert/LLM）。设计可扩展文本解析框架，用于结构化抽取、去重、质量分和多样性采样等，并与数据流水线深度集成，实现训练数据全生命周期管理、可追溯与可复现。

2022 年 7 月 ｜美团｜搜索与推荐工程技术负责人

- **搜推架构（Search & Recommendation Architecture）**：负责在线搜索与推荐系统整体架构设计，覆盖召回、粗排、精排与重排；优化高 QPS/低延迟服务架构、缓存与资源调度，显著提升吞吐、稳定性与资源利用率。
- **检索系统（Retrieval Systems）**：主导面向美团场景的高性能检索系统建设，覆盖倒排索引检索、向量/ANN 检索与多通道召回；系统优化索引构建、分片与线上查询链路，在 10w+ QPS 下实现低延迟与高稳定，支撑超大规模内容语料的实时检索。
- **算法平台（Algorithm Platform）**：搭建统一算法平台，支持 CTR/预估模型训练与在线推理，打通特征工程、样本构建、模型训练、部署与 A/B 实验，加速从实验到大规模生产的转化效率。

2020 年 9 月 – 2022 年 7 月｜京东｜AI Infra技术专家

- **算法平台（Algorithm Platform）：**
- CTR大模型技术负责人：从 0 到 1 搭建 基于GPU的万亿参数级 CTR 模型，覆盖数据、特征、分布式训练与部署；设计支持在线学习（Online Learning）的系统架构，稳定服务搜索与推荐核心业务。
- NLP大模型技术负责人：构建百卡级别的GPU训练集群，构建基于Megatron 3D并行的训练框架，支持T5系列NLP百亿级别模型的大规模训练，支持公司内部意图识别等场景落地。

2014 年 3 月 – 2019 年 3 月｜百度｜搜索广告系统技术专家（Search Advertising Systems）

- **搜索广告架构（Search Advertising Architecture）**：负责搜索广告系统核心触发架构，覆盖从 Query → AdWords → Ranking 的全链路，在数百亿级流量下实现高并发、低延迟与高稳定的广告投放。
- **GTM（Generative Triggering Mechanism，生成式触发机制）**：行业内率先将生成式 NLP 模型引入广告触发系统，从 Query 自动生成高相关 AdWords，显著扩展匹配空间，实现 90%+ 召回提升 与 10%+ 收入提升；获 百度最高技术奖（2016）。
- **广告 RL（Reinforcement Learning for Ads）**：构建广告系统强化学习训练与在线服务架构，将 RL 引入召回与排序决策，根据环境反馈持续自适应策略，广告收入提升约 **5%**。

[redacted]