乔易 @

+1 765-337-0072 aclouditation@gmail.com CA, United States linkedin.com/in/yqhack github.com/AClouDitation

教育背景

计算机工程学士

普渡大学 GPA: 3.95/4.00

2016 年 8 月 – 2020 年 5 月 West Lafayette, IN

工作经历

资深软件工程师

Google LLC

2025 年 3 月 – 至今 Mountain View, CA

高级软件工程师 2023 年 3 月

软件工程师 III 2021 年 10 月

软件工程师 II 2020 年 6 月

- 深入参与 Google Shopping 全栈研发，覆盖从数据采集到前端展示的所有组件
- Google C++、Java、Python 代码可读性审批人（Readability Approver）
- Google C++ 面试官
- Google Shopping 服务端实验审批人
- Google Shopping 数据质量值班与发布工程师
- Landing Page Signals 团队技术负责人

软件工程师实习生 2019 年 9 月

- 在 Google Display Ads 部门进行秋季软件工程实习

软件工程师实习生

YourMechanic

2019 年 5 月 Mountain View, CA

- 使用 AngularJS、React 和 Ruby on Rails 开发 yourmechanic.com 网站

本科研究员

Xroads Systems Exploration Lab

2018 年 5 月 – 2018 年 8 月 West Lafayette, IN

- 参与 *Transkernel* 项目研究与相关工具开发

项目经历

AI 搜索 2025 年–至今

多轮交互引导式购物

- 在 Google AI 搜索中发起“多轮交互引导式购物”提案，旨在解决用户复杂的购物决策难题。
- 基于上下文工程设计并实现系统原型，通过内部路演验证技术可行性并确立产品方向。
- 指导设计用户意图分类器，精准识别请求并触发相应的购物引导流程。
- 设计分阶段 A/B 实验，量化分析用户行为与趋势以驱动产品迭代。

购物深度搜索

- 深度参与 Google 深度搜索（Deep Research）的研发集成，针对购物场景制定核心优化方案。
- 为 Google 多智能体协作平台（Agency）提供购物垂直领域的技术支持。
- 负责 Agency 购物信号的整合与处理，通过优化动态提示词与上下文增强模型对购物需求的理解能力。
- 主导各版本深度搜索的质量评估，建立可靠的评测基准以持续提升回答质量。

商品着陆页信号 2024 年-2025 年

商品着陆页摘要系统

- 主导设计并落地商品着陆页摘要系统，基于业界先进的大语言模型，对商品页生成结构化与非结构化摘要，便于下游直接使用。
- 系统具备高扩展性与高稳定性，日均处理 150 万着陆页。
- 覆盖页面筛选、定期刷新、页面渲染、LLM 推理与后处理，支持按需定制数据切片。
- 产出数据广泛用于 Google Shopping、Ads 与 YouTube，并可作为银标用于后续蒸馏。

LLM 商品特征提取

- 构建训练数据，进行 SFT 并蒸馏 Gemini 模型，从传统方法难覆盖的长尾着陆页中提取商品特征。
- 构建 LLM 与主分析系统之间的中间层微服务，接口简洁、风险隔离，确保可靠与可扩展；于 MVP 中实现 2k QPS 吞吐。
- 战略性推进服务横向与纵向扩容，峰值吞吐超 100k QPS。
- 提供标准化上线流程。
- 作为范例，上线商品价格提取，在传统方法的基础上使 600 亿个商品上的价格覆盖率 +1.5%，精确度 +0.5% （>99.0%）。
- 指导上线库存可用性提取，覆盖率 +6%-9%，精确度 +0.1%-0.2%（>99.0%）。

LLM 分级特征提取

- 设计并实现分层提取框架，在不牺牲质量的前提下降低 70% 推理成本。
- 训练了小型高效的 TextBERT 模型，并分析其适用范围。
- 在可信页面使用小型高效 TextBERT，遇到更具挑战的页面回退至更大的 Gemini 模型。
- 调整模型超参数以优化推理，使 TextBERT 吞吐量提升 >10×，推理芯片占空比 >90%。

自动化模型更新

- 搭建端到端（* 外部 Tensorflow TFX）训练流水线，按计划定期自动重训用于特征提取的 LLM，适应网页持续变化，避免质量回退。
- 覆盖数据采集、清洗、训练、验证、评估与部署，全流程无人值守。
- 将“1 名工程师 ×1 个季度”的工作量，压缩为“一次性配置 + 每次更新约 3 天机器时间”。
- 作为范例，自动上线划线价提取，几乎零工程投入即可提供约 50% 覆盖率。

离线 LLM 提取可信度评估

- 搭建离线 LLM 批量推理（* 外部 MapReduce）流水线，在流量加权抽样着陆页上评估模型的“可信度”，日处理 2.4 亿页。
- 引入推理缓存，将批量推理成本降低 95% 以上。

Shopping on Search 2022 年-2024 年

优惠新鲜度过滤

- 以最近抓取时间为信号过滤或下调陈旧优惠，点击质量提升 4.8%。

商品变体与自动选择

- 实现 AR 美妆变体色板，变体长交互率提升 10.4% 并减少了商品的短点击。
- 设计并实现变体自动选择框架，采用状态压缩动态规划自动排序与选择“最优”变体集合，匹配用户查询意图；商品点击质量提升 26.35%。

后端静态分析工具

- 设计并实现用于分析 Google Shopping 服务后端数据流的静态分析引擎。
- 基于 Graphviz 实现可视化前端。
- 帮助工程师在复杂的后端服务中：
  - 理解服务中的流程和特性；
  - 定位数据的产生/消费位置；
  - 识别数据依赖；
  - 发现潜在的功能/框架错误与冗余。

本地购物 **@Google** 2020 年-2022 年

本地商店搜索

- 设计并实现本地门店搜索服务，提供门店库存结果。
- 贯通全栈引入本地化意图得分。
- 提升检索效率，重构后端服务，使后端延迟下降 9%，带来：
  - +29.1% 本地商店印象覆盖率；
  - +28.4% 本地商店查询；
  - +25.9% 本地商店点击；
  - +6.2% 本地商店点击率。

本地后备搜索

- 当本地搜索结果不足时回退到在线搜索结果。
- 对显式地理查询（如 “<product> near me / in <location>”），空白页率下降 92.5%，对商家长点击提升 3.75%。

路边取货/附近筛选

- 作为对 COVID-19 的响应，在搜索结果页上线 “路边取货/附近” 筛选，支持本地商家并帮助用户快速找到附近商品。

Transkernel **研究项目**

- 论文发表于 USENIX ATC’19：arxiv.org/abs/1811.05000。
- 使用动态二进制翻译将 Linux 内核的某些部分卸载到外围核心。
- 使用高度优化的 QEMU，成功将设备的电池寿命延长了 30%。
- 提供了详细的 API/ABIs 兼容性报告，涵盖不同版本的 Linux。

荣誉与奖项

- 院长荣誉榜 (Dean’s List)，学期嘉奖 (Semester Honors)
- 亚太信息学奥林匹克竞赛 (APIO)，铜牌
- 全国青少年信息学奥林匹克联赛 (NOIP)，一等奖