基本信息

姓名：龚军

性别：男

年龄：38

地点：北京

电话：18518303628

邮箱：heixia108@gmail.com

自我评价

- 11 年互联网大厂经验，对大规模 CPU/GPU 资源管理与调度有深入理解；
- 熟悉 Kubernetes、YARN 等业界主流集群管理系统的架构和开发；
- 作为技术专家深度参与腾讯内部公司级大数据平台、容器云平台、算力平台、云原生 AI 底座等核心项目研发和落地，在大数据、广告、模型推理等方面积累了丰富的业务经验；
- 良好的沟通和团队协作能力，多次担当大项目和技术研发负责人；
- 热爱工作，在腾讯绩效表现良好，6 次 Outstanding，4 次 Good+；
- 善于学习新事物，积极关注业界新技术发展演进；
- 积极参与开源社区贡献，Kube-scheduler、Volcano、Istio、Hadoop 等多个开源项目活跃贡献者；
- 英语能力良好，能熟练阅读英文书籍和技术文档；
- 《Hadoop YARN 权威指南》主要译者之一，《腾讯大数据构建之道》部分章节负责人。

工作经历

2014.04～至今　　腾讯　　TEG / 机器学习平台部　　12 级技术专家

2012.07～2014.03　　易安信　　存储研发平台　　软件工程师

核心项目经验

云原生大数据/AI，项目负责人

负责云原生大数据和 AI 项目的研发和业务落地

- Spark 云原生：提升大规模集群下的性能与稳定性，性能提升 30%左右；通过资源超发、应用组资源借用、混部等挖掘数十万核资源；
- 大规模 GPU 集群调度性能和稳定性优化，管理百万级 GPU 卡；
- 大规模落地 GPU 潮汐混部，挖掘的潮汐卡数达到数千卡，潮汐卡的分配率达到 100%；
- 基于 vllm 的 DeepSeek 推理优化：PD 分离场景下，自研负载均衡调度器 llm-scheduler、首 token 优化，QPM 提升 6%，TTFT 降低 20%。

云原生大数据与 AI 底座，获得 2022 年公司级技术突破奖，项目负责人

负责云原生大数据与 AI 底座通用能力建设

- 云原生底座实现了多租户强隔离、大规模集群支持（最大达 2.7w）、弹性调度、降本增效等能力，支持了公司内外大数据、广告、模型推理等多个业务，管理千万核资源，节约了上亿成本；
- 自研高性能调度器，实现了高可扩展性，大规模场景下，单调度器调度速度达到 5.5k pod/s；
- 全场景在离线混部：通过混部全年节约成本上亿元。负责了资源隔离、资源干扰检测与处理、调度增强等模块的设计与实现，并推动混部在多个业务场景的落地。

CPU 算力平台，后台研发负责人

负责建设公司内的算力平台，挖掘出数百万核可用空闲资源，并实现了分钟级资源投放给业务使用

- 负责开发算力平台资源管理及上下线系统，实现全流程自动化；
- 从调度、驱逐、runtime 层等多方面优化提升低优算力服务质量，将不稳定的资源变得更可靠，满足业务的服务质量需求。

通用容器云平台 GaiaStack/TKEStack，后台研发负责人

负责容器平台和 Kubernetes 的开发与优化，建设成了当时公司内最大规模的容器平台，服务多个 BG

- 负责后台开发，主导设计和实现了容器服务、镜像服务（公司级镜像服务）等模块；
- 负责 Kubernetes 主要功能开发，包括：通用应用类型 TAPP、多种资源维度弹性管理、调度功能增强、应用管理等，并将调度性能提升 10 倍以上。

大数据调度平台 GAIA，子项目负责人

负责公司内大数据平台的资源调度，2014 年单集群规模已达 8800 台，每日调度上亿 container

- 负责多项重要特性的开发：多资源维度管理、NUMA 亲合性调度、作业优先级调度等；
- 优化自研调度器 SFariScheduler，提升调度性能 100 多倍，满足了公司内大规模场景的需求；
- 建设云化 GPU 集群，有效地管理 GPU 集群，支持了 Mariana 2.0 深度学习平台顺利上线。

教育背景

2009.09～2012.06	中国科学院	计算技术研究所	硕士（免试保送）
2005.09～2009.06	武汉大学	计算机科学与技术	本科