个人简历

基本信息

姓　　名：杨超　　快手职位：AI 异构计算架构师-K4
学　　历：西安交通大学本硕
现在公司：北京快手科技有限公司（孵化出创业公司：北京凌川科技有限公司）
联系方式：15210236393　　电子邮件：7017428@qq.com

核心优势

AI 大模型性能领域扫地僧：AI 老兵+系统级优化能力+大厂上线经验+国产化异构适配经验+模型架构微创新经验。

- **10 年**+AI 经验；**13 年**+系统优化；**9 年**+AI 算法加速器开发：CNN，LSTM，Transformer，LLaMA，OpenSora，DeepSeek（纵向）；AI ASIC，GPU，FPGA（横向）。
- **5 年大厂** AI 系统优化与**上线经验（MMU，音视频，搜推）。**
- **7 年+AI 加速器项目管理经验，负责完成近 10 个 AI 性能优化项目。**

技术特点

专注方向：AI 算法优化加速和模型架构微创新。优化界里最懂算法的；算法圈游走的优化侠。

提出系统—>算法—>模型—>数据流—>编译—>结构—>硬件多层次的 AI 系统优化思想。

技术能力：量化分析，系统能力，**持续创新力，技术决策判断力，**高成功率。

知识体系：深度学习原理，推理部署&训练，AI 优化技术，软硬件体系结构。深入理解大语言模型，文生图&视频，强化学习，深度推理模型，多模态，Attention 替代等各个方向的技术路线。

工作履历

2019/10 – 至今：北京快手科技有限公司。异构计算中心**高性能计算架构师**。负责 AI 加速引擎的方案和微架构设计（包括**国内首批 Transformer 类 AI 加速引擎，首批 AI 大语言模型加速器**）。

北京凌川科技有限公司（快手孵化的 AI 创业公司，2024 中国 AI 芯片新锐企业 **TOP10**。专注大语言和生成类模型）。现任 **AI 解决方案负责人，**AI 模型**性能架构师，芯片核心设计成员**。

2018/02 – 2019/09：深思考人工智能机器人科技（AI 语言模型/AI 医疗。2017 最佳人工智能创业公司 **TOP10**）。负责**国内首个医疗专用 AI 加速器**研发：模型改进，压缩，架构，深度学习框架。

2016/01 -- 2018/01：Falcon Computing Solutions（中国工程院院士&美国工程院院士丛京生教授创立的异构编译器创业公司，被 AMD-Xilinx 收购）。**早期创始成员**，负责人工智能算法加速优化。

2009/07 -- 2015/12：北京四方继保（中国电力自动化行业龙头企业）。负责电网装置的嵌入式软硬件系统设计开发与性能优化。2012 年开始**研究机器学习**，并报考中科院自动化所人工智能博士。

项目成果

快手&凌川期间：

1、 凌川优化（**模型切分推理** 202404~202506）：自研 AI 大模型性能优化&自动化切分框架

（项目负责人&设计开发）

项目内容：把关优化大模型性能，指导项目方案设计。

- 基于 TensorRT-LLM，vLLM 和 SGLang，优化大模型在 4090&H100 GPU 上的性能。
- 设计性能优化方案（算子融合，系统，数据流，多卡多机互联，自动存储规划，计算，Pipeline）。
- 自研 AI 大模型自动化**混合并行切分框架**（TP&DP&SP&PP&EP 融合），提出各大模型的推理**最优切分策略**。
- 开发性能分析&Profile 工具 PerfSim；Op 级 Profile&瓶颈分析，模型级性能仿真&效率评估，分析数据量分布和最佳算力/带宽比，指导芯片参数设计。
- 基于自研 AI 芯片开发类 CUDA 编程模型框架。

项目成果：

- 深入研究分析 DeepSeek-V3 优化方案，创新优化 MLA 和 MOE 的切分，提升吞吐。
- 优化 Lightning Attention，MiniMax-Text-01 吞吐提升 110 倍。
- 优化混合切分，最小化卡间传输，LLaMA 8B 单卡&70B 8 卡：FTT<2s，吞吐 X tokens/s。
- 混元 1024*1024 单卡 latency 15s，OpenSora（可灵） 720p 4s 视频单卡 latency 45s。

其中，**半 PD 分离，层内&层间并行联合优化，DeepSeek 最优 TP&DP 设计，LLM 效率评估指标等多项技术方案或思想早于业界类似研究。**

2、 训练（**后训练应用** 202410~202502）

（设计开发）

- 在 DeepSeek-R1 出世之前，以 SFT 方式 Lora 微调 MiniCPM（包括 Qwen2 和 Vision Encoder 部分），HunYuan，OpenSora，超分等模型；研究提升**模型推理和想象能力**的后训练方法。
- 对各模型的各 layer/step 的重要性和贡献值进行分析，研究 layer/step 层面的剪枝优化策略。
- 设计针对高效训练的加速方案，包括混合精度，反向数据流，多机互联，Checkpoint 存储 Pipeline 机制等。
- 研究并尝试用 Dify 应用平台快速搭建 AI Agent 服务，提升公司基础业务工作效率。

3、 快手 MMU（**业务上线** 202010~202110）：自动语音识别（ASR）&音乐歌词生成 TDNN+LSTM/GPT2/Conformer（Transformer Decoder 为主的模型）加速

（项目负责人&设计开发）

项目内容：

- 主导/组织项目组完成 GPU/异构器件全场景语音识别服务并上线部署。
- 研究性能最优系统方案，开发业界领先的异构加速框架，4 个技术突破点：软硬协同设计（系统），定点量化（算法），基于 OpenCL 的**多模型负载均衡调度框架，类似但早于 NV 的 Triton**（软件），NPU（硬件）。

项目成果：

- TDNN+LSTM FPGA 系统吞吐提高 5 倍，平均延时降低 37%，TCO 为 0.29。
- GPT2 等 GPU 系统吞吐提升 3.5~12 倍。
- Conformer ASIC 系统吞吐提高 2.4~4.8 倍。**总收益共 1.6 亿元。**
- 机器之心发表文章：https://mp.weixin.qq.com/s/QrH_a2SVieLHm4844Y6cUQ

4、KwaiNN 大模型推理框架（**Infra 平台** 202010~202306）：软硬协同优化快速部署一体化平台（方案设计&开发）

项目内容：联合快手 Y-tech 和 MMU 开发兼容 GPU 和 AI ASIC 的高性能通用部署框架。

- 研究项目整体优化方案。
- 主要负责后端 Transformer（Decoder 为主）加速引擎设计，开发 CUDA 底层加速库。

项目成果：在音视频，MMU，搜索各业务模型上加速 2~5 倍。

5、快手音视频（**AI 加速引擎** 202204~202403）：AI 大模型加速引擎的整体方案和微架构设计（架构&设计开发）

项目内容：

- 针对 Transformer、Diffusion 类大模型的 DSA（领域专用加速器）整体方案设计：自研定制 **Fast Attention Engine**：固定数据流；多粒度 Pipeline；高带宽通用矩阵引擎；**软硬结合 Flash Attention 引擎**；**GQA 多 head 融合**；高效计算阵列。
- 微架构总体设计和 GPE（多精度矩阵乘阵列）微架构设计：指令 Tile 机制；混合精度 MAC 复用；精简 Transpose 前处理单元。

项目成果：单核推理性能达到 4TOPS FP16。

深思考期间：

研究视觉深度学习模型的压缩&优化，设计 AI 医疗专用 DPU（项目负责人&设计开发）

项目内容：

- 研究细胞分类算法，目标检测算法 Wisenet-SSD，Yolov3 等模型的结构化剪枝，量化，编解码压缩方法。
- 针对各模型特点设计 DPU 架构和深度学习框架；研究存储和计算优化方案。

项目成果：模型计算量平均减小到 35%。**做成癌细胞检测 DPU**，各模型分别加速 10.7~60 倍。

峰科计算期间：

OpenCL 异构编译器开发。

- 基于 Caffe 框架的 CNN 等 AI 算法在异构器件上的高性能计算。各算法平均加速 60 倍。
- 为编译器**探索性能优化关键 Pass**，完成相应后端优化。

专利、个人荣誉

- 主导的 ASR 项目获得**快手 2021 年研发线技术突破奖**；深思考 2018 年度优秀员工。
- **十几篇** AI 性能优化相关发明专利：
  一种高效支持 Flash Attention 的硬件架构；一种最小化数据传输量的 TP 与 DP 混合切分方法；
  一种提升 LLM Attention 硬件计算效率的算子融合方法；一种最小化数据传输的切分轴选取方法等。
- 主编《ZigBee 技术实践教程》一书，由北京航天航空大学出版社出版。
- 第六届西安高新“挑战杯”陕西省大学生课外学术科技作品竞赛科技发明类一等奖。
- 华罗庚全国数学竞赛三等奖（估计全国前 500 名）；全国数学竞赛山西赛区二等奖（全省前 50 名）。

理想状态：激情、和谐、智慧、艺术