319bb62face53f021Xx92tW9FVVSwI62V_6cWOaqmfDSPhRn

王泽鸿

15871751448 | zehong.wang@outlook.com | 上海

个人总结

- **7年大数据实际工作经验**，其中包含2年大数据算法开发优化、数仓ETL建模和数据挖掘经验；5年Azure云平台Data&AI产品(HDinsight, Databricks, Synapse等)解决方案经验, 获得过数学建模国二奖
- **精通Azure云平台Data&AI产品**，具备丰富的解决方案经验，擅长使用Spark, Hive, Hbase, Kafka 等大数据相关产品进行数据处理和数仓搭建，熟悉ML,DL常用算法，能够快速搭建模型和部署(eg:MLflow,AML,TF serving)

工作|项目经历

微软中国有限公司 2020年02月 - 2025年08月
微软云cloud senior engineer Data&AI 上海

- **职责：**负责Azure HDInsight，Databricks，Synapse等大数据产品，为跨国企业(Starbucks,Intel,Tesla etc)提供数据平台云架构方案设计，技术支持和咨询等服务。主导内部技术培训会40+场，团队效率提升15%，输出技术文档80+篇，推动内部流程优化时间缩短30%, 参与过重大客户(SCB, AIA)数据迁移项目与数据平台设计搭建工作
- **基于HDI数据迁移项目**：HDI不支持原地升级，需要将HDI3.6迁移到HDI4集群。作为核心人员参与客户前期业务评估(共200+表，TB级数据量)，解决Hive兼容性问题(2.x->3.x) Kafka 升级中数据积压，一致性问题，HBase集群数据复制容灾方案设计，以及制定滚动性迁移策略，回滚计划，性能基准测试，确保最小化业务中断。 最终实现项目在规定停机窗口周期迁移成功，关键表的数据一致性和准确性达到99.9%+以及Hive/Spark作业的日均成功率达到98%以上，系统响应时间保持在SLA范围内。
- **基于Databricks数据平台搭建**：旨在基于 Databricks平台，为客户构建一个统一(UC)、可扩展、高性能(delta table)的数据与人工智能平台。作为主要负责人，参与客户平台调研，根据客户真实的业务场景，设计一套基于autoloader, 和使用external location, kafka 的数据读入到delta table(bronze), 利用数据仓库理念对Bronze层数据进行ETL 操作形成符合业务规则的、干净的一致性维度表和事实表(silver)，并根据客户金融行业的场景和数据分析需求，对Silver层数据进行聚合，形成可直接用于报表、仪表盘(Gold层)，协助客户前端用PBI展现。后期协助优化delta table查询性能(z-ordering,optimize,vacuum 查询扫描数据量减少50%以上) 并帮客户的data sicentist从Gold层获取特征数据，使用 MLflow Tracking记录注册到MLflow Model Registry, 实现模型的版本控制和生命周期管理，并将结果写到Delta Table供downstream应用使用。最终帮客户实现了在实现低延迟(<3s)的ETL作业(SLA>99%)，同时集群的空闲时间降至20%以下, 降低了成本(30%)
- **构建DocUpdatenotificationbot项目**：解决Azure Databricks等官方文档中文档更新频繁、关键信息易遗漏的问题，独立设计并开发了基于AI的智能文档追踪与通知系统。通过构建**GitHub**爬虫监控目标仓库，利用比对Commit ID与**Cosmos DB**中记录的方式精准检测文档变更。一旦发现更新，系统即自动调用**GPT-4** API对变更内容进行智能分析与摘要，生成简洁的更新说明。随后，通过我开发的Microsoft Teams Bot将摘要实时推送至用户，并将最新状态持久化至Cosmos DB以确保状态同步。此外，系统还实现了周期性（每周/月）的自动化总结功能，主动为用户梳理阶段性的更新重点。该系统成功将文档更新的发现与理解从手动、滞后转为全自动、实时化，使用户跟踪文档动态的效率提升了**70%以上**，通过定期总结报告帮助团队把握技术演进趋势

四达时代 2019年09月 - 2020年01月
数据算法工程师 BI大数据部门 北京

- **视频推荐系统研发:** 对视频进行精准投放，增加用户粘性。负责Startimes On视频软件推荐算法模块pipeline搭建和算法的优化: 主要包括构建用户画像，视频节目画像，数据仓库；APP事件埋点日志数据利用Spark, HiveSQL进行ETL清洗分析用户增长和观看行为；利用Embedding, word2vec，TF-IDF等挖掘标签向量特征; 部署了 CF, LR, FM, xgboost等基模型预测点击率实现精准节目推荐; 建立召回，排序层，使用ES为Web前端提供检索数据，使得节目A/B Test结果点击率CTR达到了0.68。**难点与解决方案**：熟练使用spark ML/mlib 降低算法的训练时间和满足代码的兼容性；针对new视频item冷启动问题尝试TF-IDF和word2vec等多种方法来挖掘其标签向量特征: 使用word2vec模型，将视频标签转化为128维向量，提升推荐准确率12%；针对降低算法的训练时间，使用Spark ML/mlib 降低算法的训练时间20%，并满足代码的兼容性。

网信集团 2018年07月 - 2019年08月
数据工程师 AI/大数据部门 北京

- **报表系统迭代开发：**为业务部门提供数据平台报表服务。日常编写pyspark SQL 脚本满足业务团队数据提取需求，交付自定义报表和企业微信，短信推送。**难点与解决方案：**业务方单个报表需求字段维度多(>=20)，涉及十几张table join 查询，数据量级几十GB(会使用Spark 1.x rdd高级api，优化数据仓库层DWB,DWS)；Spark1.x 平台API不统一，内存易溢出(Spark SQL 性能调优，通过调整Spark SQL的shuffle分区数，将报表查询时间缩短15%)
- **构建用户画像系统:** 实现用户分类基础数据建设，便于后期建模实现精准投放营销策略。从用户的基本信息数据，投资偏好，账户情况等多维度构建画像，收集专家系统的业务规则对其打上"活跃用户"，"流失用户"等标签，利用邀请码及用户归属地等信息，构建用户间的多度关系，形成用户的知识图谱标签。**难点与解决方案：**采用hbase 列存储特点节约储存空间和快速读取；使用CF可扩展性解决用户画像的多维度标签的迭代开发和存储，支持100+个标签的扩展；主动向身边同事以及manager寻求建议和支持来解决跨部门合作中遇到沟通障碍问题
- **流失用户召回系统构建**：发掘即将流失用户，吸引再次投资。建立全链路数据ETL清洗(pandas)建模(ML中sklearn聚类, xgboost，DL keras框架)监控(A/B Test)模型, 给与高利率投资券奖励。两个月的A/B test投资率从0.62提升到0.84。**难点与解决方案：**熟悉pandas预处理技巧解决来自多个业务系统数据不规整问题；利用imblearn库中over_sampling和under_sampling解决正负样本不均衡(1:10)；结合业务场景界定预测目标(确定三个月内活跃用户作为训练集X,一周内投资用户为预测目标Y, weekly迭代训练模型)等
- **网信黑客马拉松比赛：**在33小时内实现一个创意demo。作为队长，带领4名队员实现了前端采用ECharts，后端tornado提供ajax请求api，采用nlp的中文分词分割（结巴分词）和命名实体识别(NER)技术将前端传入的如“5月份新增用户数据折线图”解析成SQL语句查询数据后返回前端可视化展示，并获得冠军称号。**难点与解决方案**：使用分词和NER技术去解析中文并建立强规则引擎实现功能以及快速构建前后端分离web架构和调试

教育经历

上海交通大学 2025年09月 - 2027年06月
MTT 硕士 安泰经管学院 上海

湖北经济学院 2013年09月 - 2018年06月
软件工程 本科 武汉

【学术成绩】GPA：3.5/ 4.0（专业前10%），荣誉/奖项包括国家励志奖学金（2015）校级优秀毕业生（2018）2015全国大学生数学建模比赛本科组二等奖