蔡华翔

手机/微信：(86)18868105824;
邮箱：595941178@qq.com
浙江杭州;

工作经历

2021.11-至今　**华为技术有限公司**　计算技术开发部　**大预言模型**推理优化　17A

研究课题：面向 Alagent 的分布式架构设计与系统优化，推理加速

1、基于形式化+建模仿真的分布式集群**量化系统**；**LLM算子建模**；

- ✧ 评估通算/智算场景不同配置及LLM优化技术的收益，支持方案设计和性能工程
- ✧ 提出一套多维并行的 cycle 级低损仿真加速技术，大幅提高仿真效率；
- ✧ DSv3 中各项优化技术的建模仿真，设计超节点部署方案；

2、MoE **推理加速**技术；**混合模型专家模型稀疏推理加速**；

- ✧ **EP 通信**：相比于幻方分层流水方案，单算子提升 XX%，TPOT 提升 X%；
- ✧ **负载均衡**：通算联合优化求解，基于二次路由的动态调整，TPOT 提升 X%；
- ✧ **激活稀疏+补偿**：通过专家内稀疏+外补偿方案，TPOT 提升 X%；

3、**分布式异构检索**算法（进行中）；

- ✧ 通过 NPU+CPU 异构流水、分布式全局图等技术，提高检索吞吐；
- ✧ 设计创新性的分布式全局图冗余备份机制，提高检索 QPS；

荣誉：奖项*8，重大贡献*1，发明专利*4，技术秘密*2，潜高专利*1，十佳 idea*2；

教育经历

2017.09-2021.08　**香港大学**　**博士**学位　电力系统（机器学习）

2013.09-2017.06　**浙江大学**　**学士**学位　电气工程及其自动化

获奖经历

香港大学　研究生奖学金，**香港大学研究奖学金**

浙江大学　**国家奖学金**，浙江省**优秀毕业生**，**美赛一等奖** 等 10 余；

科研经历

博士研究 — AI技术在电力系统中的应用

- 设计**强化学习**框架，实现多控制器自适应性协调控制：*IEEE Trans. Power Syst.* (顶刊)
- 退火算法优化拓扑排序，电力系统**可视化**与 **3D-CNN**：*Int. J. Elect. Power Energy Syst.*
- 建立域混淆网络，实现电力图像的**迁移学习**：*2020 IEEE PES APPEEC*
- 改进**时空图卷积**网络，实现短期电压稳定性预测：*IEEE Trans. Power Syst.* (顶刊)
- **图注意力机制**建立**分布式**框架，**对抗机制**知识迁移：*IEEE Internet of Things J.*(顶刊)
- 设计**强化学习**，实现多段**柔性机械臂**的自适应性控制：*IEEE Robot. Autom. Lett.*

技能水平

- **Python，Java，C++**