20e842fe0552c8851HV-39i1F1tUwIW2UvOdWOaqmfDSPhRn

阎裕石

13521023588 | jackyan1999@163.com

教育经历

- **中国科学院软件研究所 并行软件与计算科学实验室** 计算机科学与技术专业 **硕士** 2022 年 09 月 - 2025年06月
- **北京科技大学** 物联网工程专业 **本科** 综合排名：1/63 获人民特等奖学金 2018 年 08 月 - 2022年06月

工作经历

- **金山云 智算云售前解决方案架构师** 2025 年 07 月 - 至今

  工作概述：承担客户需求沟通调研、售前解决方案设计、POC测试等工作

解决方案典型项目经历

1. 某车企项目：

①客户需求：VLA模型训练算力及配套RoCE网络组网、高性能文件存储、专线互通

②解决方案设计及POC测试：

A) 算力卡选型：完成智驾VLA模型训练场景B300、H200、H100、H20性能对比测试，为客户提供选型指引

B) 智驾VLA模型训练性能优化思路沟通：分析客户训练脚本和框架源码，结合nsys、ncu排查性能瓶颈为D2H流量和Attention算子性能弱，给客户提供优化建议

C) RoCE组网方案：结合公司交换机库存给出B300、H200 RoCE组网方案，其中B300采用双平面组网架构

D) 其他产品方案：根据客户需求给出高性能文件存储和对象存储选型指引

2. 某互联网公司项目：

①客户需求：Qwen系列3B、4B模型SFT训练、AI平台模型在线服务部署、大模型API MaaS服务

②解决方案设计及POC测试：

A) 训练框架选型：客户仍采用原生torch进行SFT训练，性能较低，推荐客户使用Megatron系列框架

B) 算力选型：根据模型尺寸为客户推荐H100、A100作为训练机型

C) POC测试：支持客户使用金山云AI平台进行训练测试，完成迁移脚本编写，保障客户使用体验

D) 模型在线服务部署架构：提供基于服务网格的推理部署架构方案，保障高性能、高可用

研发项目经历

1. **美团 Longcat推理引擎组**（offer后实习） 2025年03月- 2025年04月

   Attention算子性能优化：跨request的KV cache重用，多level attention融合（此项工作未完全完成）。

2. **字节跳动 seed-foundation** 2024年03月- 2024年06月

   云存储性能压测工具开发：开发自动化存储性能压测工具，提升存储压测效率

3. **智谱AI** 2023年08月- 2023年11月

   Attention算子性能优化：在VLLM pagedattention kernel基础上进行 split-k修改，提升长序列性能约40%

4. **澎峰科技** 2023年02月- 2023年05月

   RISC-V CPU向量化优化：使用RISC-V向量指令优化FFmpeg中的热点计算函数，性能提升1~3倍

5. **中科院软件所（实验室课题）** 2022年09月 - 2025年06月

   ①批量高瘦矩阵矩阵乘法和批量矩阵向量乘法库开发：相对cuBLAS提升性能10%~80

   ②异构计算系统复型线性方程组LU求解器开发：实现国产GPU上多机LU并行求解器

求职意向：解决方案架构师

个人优势：

1. 熟悉大模型训练框架、推理引擎原理，有一定开发经验
2. 具备与客户沟通能力和公司内部沟通对齐经验