脉脉
成就职业梦想

刘松伟

男 | 5年工作经验

求职期望

期望职位：性能优化工程师、高性能计算工程师、深度学习图像算法工程师 | 期望城市：上海、浙江杭州 | 期望月薪：45k-70k/月

工作经历

字节跳动 大模型系统工程/训推加速 2021.03 - 至今

工作内容

智创 AI平台 高性能计算

1. ByteNN 模型优化方向负责人，CUDA推理引擎和模型压缩能力矩阵核心研发，擅长通过算法-工程协同优化，降低AIGC/LLM模型推理成本，经验覆盖端云，同时主导建设了ByteNN端侧大模型优化和早期的推理能力。

2. Seed量化稀疏加速：实现业界性能SOTA的多架构GEMM/Attendtion量化稀疏加速方案，覆盖N卡/xx卡，实现Seedance/Seedream系列模型线上INT8无损全量，xx卡无损INT4全量，助力实现国产卡性价比超过L20，系列能力带来1000万/月成本收益。

3. Seed模型层优化: 牵头训练了AIP 轻量化2D/3D VAE轻量化模型，构建业界领先的Cache优化方案，高效率MOE压缩，Token压缩方案，支持Seedance/Flux等系列模型加速，相关能力累计调用超千万。

4. ByteNN端侧大模型: 23年开始推动LLM模型在字节的端侧落地，构建了领先的端侧模型压缩能力，协同推理侧完成主要业务线的端侧LLM/VLM业务突破，首个业务即将全量。

5. LLM/AIGC推理: 构建LLM/ AIGC推理能力，支持kvcache/tp/pp/量化推理等关键能力和业界主流模型，支持多个LLM类保密专项，负责SeedVLM多模态模型推理优化约一年。

6. 核心算子优化: Flash Attention，GEMM, DwConv mma/ wmma/ ptx级深度优化，int4/int8量化kernel实现. 熟悉cutlass, tensorrt, fasttransformer, triron库

7. 研究: 熟悉算法和系统协优化,多篇顶会一作， 代表作ERTACache，TCEC，ABQ-LLM，GQSA，RLFN等，NITRE 2022 Efficient SR 赛道全球冠军.

海康威视海康研究院 Research Intern 2020.06 - 2020.09

工作内容

对抗神经网络，自动化数据增强，领域自适应

腾讯科技 Research intern 2019.11 - 2020.06

工作内容

模型压缩加速，并行计算，神经网络结构搜索

杭州飞步科技有限公司 cv算法实习生 2019.04 - 2019.07

工作内容

ADAS系统开发。 自动驾驶感知算法研发和算法层优化，异构/并行加速

教育经历

浙江大学 电子科学与技术 硕士 2018.01 - 2021.01

华中科技大学 电子科学与技术 本科 2014.01 - 2018.01

光电学院电子系