王辉

1919cc@gmail.com, +86 180 18699231，上海，中国

工作经历

2025.08 – 现在

上海阶跃星辰智能科技有限公司 AIOS 系统架构师

负责 AIOS 系统架构：软硬芯算 AI 系统一体优化方案推进和落地。设计调度系统和推理，端侧基础模型+端侧 LoRA 的高效 AI 一体化系统计算架构，OS 计算架构调度策略包含两层调度系统 ： 系统资源动态调度系统 + 模型计算动态调度系统。动态负载感知模块：实时采集系统资源使用率、任务队列长度、能耗状态等指标，建立资源负载模型。端侧 AI 系统 AI Runtime 架构设计，包括支持 Agent 运行时，上下文管理服务，记忆服务，推理系统，端侧离线模型训练，端侧模型管理，隐私安全等模块。

2025.01 – 2025.06

上海歌尔科技发展有限公司 Tech lead/资深工程师

负责 AI 平台技术研发，提供完整的智能硬件 AI 解决方案，包括端云结合的 AI Infra 平台的搭建，并在平台上开发多 Agent 系统应用 – 健康应用 Mult-Agent 系统。该多智能体应用包含卡路里计算 Agent、健康指导 Agent、饮食建议 Agent 等模块，采用边缘设备与云端混合部署架构：边缘侧部署，搭载 7B LLM 模型与 llama.cpp 推理引擎，支撑意图识别智能体的端侧计算；云端部署 70B MLLM，通过 Dify 框架结合 vLLM 引擎，实现其余智能体的后端服务化部署。

2020.03 – 2025.01

上海瑾盛通信科技有限公司(OPPO 研究院) Tech lead/资深工程师

带领前后端团队负责边缘计算的 AI 小模型原生开发与部署，以及端侧模型训练和推理性能优化等，Android framework 系统，Web 前端，后端服务的开发。Android 移动端主要是应用，框架，性能优化，NDK 等开发，具体落地业务是移动边缘 AI 小模型的原生开发和部署，端侧模型训练的开发和性能优化。后端服务主要是基于微服务架构的云原生开发，落地业务是基于大规模端云协同模型训练和聚合的平台：

1. 基于图片分类算法的大规模端侧训练模型的联邦学习平台，支持 2000+台设备同时参与训练，服务器端聚合模型梯度信息，然后再分发聚合的模型到端侧重复训练，优化模型效果。
2. 移动端轻量小模型的开发与落地 -- 基于隐马尔可夫模型 HMM 的手表表盘 APP 列表推荐功能，虚拟数字人 APP 应用，基于模型优化的手机背光功能。
3. 端云互融计算框架 – 为了保护用户数据隐私的大规模端侧模型训练（MNN）的端云协同计算框架，提升端云协同效果，支持多种聚合算法，个性化联邦算法，调度和策略管理。
4. Android 系统优化 - 高效帧压缩技术，场景感知的动态内存分配优化，CPU 和 GPU 动态联动的调节策略等；提交 8 篇专利。

2019.07 – 2020.01

Amazon Canada Fulfillment Services, ULC. (AWS-Amazon Webservice) SDE II

负责亚马逊云计算的云支付服务功能，该服务基于微服务架构；开发一个基于优化云计算资源账单的微服务，该服务聚合基础云资源等的账单信息，然后分析使用数据，优化客户的云资源配置策略，帮助用户更好的订阅和配置云资源产品；服务使用 AWS 的 CloudWatch, CloudFront 工具和 LPT 框架实现微服务的监控服务，包括监控该服务的软硬件性能，预警等。

2012.01 – 2019.07

高通企业管理(上海)有限公司 高级工程师

负责 Android Framework/APP 的软件架构，软件开发和稳定性问题的修复和定位，包括系统重启，定屏无响应，内存溢出，性能和功耗问题等。在线调试系统问题，包括系统异常，系统崩溃，系统黑屏无响应，系统卡顿，进程死锁等。开发 Android 原生应用，包括 Launcher，Call/Telephony 双卡支持，无线投屏，系统 UI 和设置，等模块，开发运营商和 OEM 定制软件需求的功能。

2010.01 -- 2011.09

三星电子(中国)研发中心 工程师

负责 Samsung Galaxy Phone 的 Android 原生应用的功能开发和定制，本地软件开发。开发模块涉及到 Dailer, InCallScreen, MiniDairy, MyFiles, WriteToGo 等应用，电信运营商的本地化配置等。

技能

- 熟悉智能硬件 AI 解决方案的研发和产品落地，端侧推理引擎开发和优化，模型下端，端云大小模型协同推理服务
- 熟悉 AI Agent 技术解决方案，包括 Agent 应用，上下文服务，记忆服务，主动服务，推理系统，异构算力等
- 熟悉 Android APP/Framework 的开发和优化，了解部分 Android 框架原理，包括 AMS, PMS, WMS, SystemServer 等，能够对 Android 框架和系统 APP 进行稳定性分析，调试，和性能优化
- 小模型的边缘 AI 开发和部署，包括基于 Android NDK 原生开发小模型端侧训练（集成 MNN），端侧部署模型和推理
- 了解微服务架构，能够使用 Spring Cloud，容器技术，Istio，K8s 等框架搭建大模型分布式训练，部署，分布式推理平台
- 较强的编程能力，熟悉 Java 语言，能够一般使用 C/C++, Python
- 熟悉基于敏捷软件开发模式的全栈技术团队管理，对技术，产品，业务敏感，较强自我驱动和执行能力

学历

2013.03 -- 2015.06 复旦大学 计算机科学技术 硕士 (在职学位)

2006.08 -- 2010.06 南京大学金陵学院 计算机科学与技术 本科