[redacted]

个人简介

- 三年 NLP 工作经验，热爱技术，有大模型预训练及继续预训练相关研发经验。
- 工作期间绩效优异，作为部门核心算法开发人员近两年获得高绩效，并获得 2023 年度微博集团优秀个人。
- 微信同手机号

工作经历

Shopee 2025.03 – 至今

Shopee Search　NLP 算法工程师

评论总结 2024.06 – 至今

主要开发者

- 利用搜索积累数据和 LLM 构建困难负样本，训练 Shopee 域内 embedding 模型，为下游业务提供支持。
- 相较于开源模型和原生的相关性 embedding 模型，在域内评估集上分类任务高出约 10 个百分点，召回任务评估高出 19 个百分点。
- 为下游推荐和广告等业务提供 embedding 支持。增加 embedding 后，下游推荐业务 GMV 提高 3% 左右。广告的 shop 点击提高约千分之一。目前还在进一步优化。

LLM for Search Relevance 2025.03 – 至今

- 利用 dpo，kto 等技术训练 LLM 模型，用以判断搜索相关性，提高相关性 F1 指标。

新浪微博 2021.07 – 2025.03

微博内容算法　NLP 算法工程师

评论总结 2024.06 – 2025.03

参与者，负责微博评论区评论内容总结相关模型开发。

- 参与开发长文生成模型，构建长文训练指令集及长文评估的标准测试集。用于评论区评论内容总结和观点分类。
- 基于 embedding 模型服务和余弦相似度增加去重与优质评论筛选功能。
- 增加投机解码用于长文推理加速，提速越 1/3 左右。

评论罗伯特 2023.06 – 至今

参与者，主要负责微博评论机器人–评论罗伯特的算法优化。

- 参与评论罗伯特模型微调优化及评估。利用微博域内评论数据训练初版评论生成模型，及混合开源指令、角色特征的评论生成模型。
- 针对模型趣味性与安全性方向进行特定的模型微调及优化。
- 为评论罗伯特提供检索支持，支持了美妆及海信罗伯特及风格样例检索服务。

微博虚拟人– AI 小助理 & 微博通用 RAG 平台 2023.11 – 2024.10

负责人：利用 RAG 技术，将博主历史微博及外部数据构建为知识库。通过检索博主历史微博，代替博主回复粉丝向博主的提问及粉丝在评论区的回复。

- 负责微博数字人整个相关开发流程及算法侧优化。
- 完成整个对话及评论意图识别–> 策略分流–> 知识检索–> 检索生成功能。

- 知识库检索：利用自研 embedding 模型及开源 embedding 模型，及 Elasticsearch 搭建多路召回检索服务。支撑约 2000 万文档向量检索服务。峰值 QPS 为 15 左右，平均 QPS 在 2 左右。
- 根据业务情况。增加 LLM agent review 模块及优化 prompt，针对性微调模型。微调开源模型提升评论生成质量。降低 Bad Case 比率从 20% 到 5%。
- 2024 年 9 月 24 日已支持开通约 800 名大 V，日均互动回收比例 65.3%。AI 评论次数 29759 次，AI 互动人数 26079 人，带动互动次数 15567 次，带动互动人数 4445 人。
- 基于本项目设计微博域内通用 RAG，为多业务线提供提供图文，视频等知识库检索与生成服务。提供基础文档 chunk 切分，摘要总结，及写入检索等功能。

知微大模型训练及平台建设 2023.01 – 2024.01

- 完成微博自研大模型预训练及继续预训练探索。
- 7B 13B 级别的知微大模型从零预训练。7B, 13B 及 32B 级别的基于开源模型的继续预训练。
- 配合架构部门推进微博内部多机多卡训练平台相关工作。
- 基于知微大模型和开源模型，微调大模型并在业务上应用。
  - **博主助手：**基于知微大模型和 BloomZ 等模型进行微调，学习博主发言风格，生成特定风格的微博和续写微博。
  - **通用物料生成：**生成时效性相关性低、无害且主题弱化的通用物料。
  - **前主编：**时政新闻类主题博文风格仿写。

微博 CLIP 模型 2021.07 – 2023.07

- **训练微博 CLIP 模型:** 采用域内预训练 Bert 与 ViT encoder，使用 Contrastive Leaning 算法，对数百万级微博文图数据，文本视频数据，开源检索数据，博文及话题标签数据数据，进行微博多模态 Embedding 模型训练。经时任绩效负责人张俊林整理发表于知乎专栏文章（https://zhuanlan.zhihu.com/p/370782081）。
- 随后使用 Mini Batch 聚类算法将其离散化为层级化 ID 标签。为下游推荐提供支持。在微博推荐流各项指标中均取得较佳正向效果。人均曝光 +1.59%，在线时长 +2.34%，互动 +7.62%，点击 +3.05%。在新浪新闻场景中，人均阅读 +1.86%，人均 vv+2.94% 人均 APP 时长 +0.63

微博内容标签 2022.09 – 2023.03

参与者

- **微博内容标签：**负责优化微博内容一级标签分类模型。
  - 使用半精度训练，微博域内预训练 Bert，大规模训练数据组织及清洗，Onnx 加速，FGM，伪标签等方式，优化微博一级标签分类模型的训练与部署流程。
  - 在哈工大 Roberta 基础上进行微博 Bert 预训练模型训练。作为后续微博标签模型的基模型。相比哈工大开源模型，在保持准确率一致的情况下，召回率分别提升 6.33%/2.37%。
  - 为一级标签模型增加了多外部特征输入，基于博主等级，博主兴趣、能力标签标签，博主性别、擅长领域，博文长度、等多维度特征。增加图片相关特征。对其他特征采用了 attention 的聚合方式。
  - 经过上述优化，维持一级标签准确率不变的情况下、召回率从 85.65% 到 94.53%、覆盖率从 83% 到 92%（2022 年 5 月到 2023 年 3 月）
  - 对标签分类模型采用 onnxruntime 等推理优化方案。提升标签推理服务（Bert-Large）推理速度到 T4 单卡 180qps
- **微博拓展标签：**在内容标签的基础上，增加拓展标签体系，构建了 NER 模型，策略挖掘，TF-IDF 及词性挖掘等多路挖掘机制。每日挖掘新增标签词汇，建立基于人工辅助的标签挖掘及自动化补打机制。
- **新热挖掘：**完成标签新热挖掘流程。基于上述多路挖掘机制，增加了基于热度和热度上升趋势的快速挖掘方式，及时微博中出现的新词热词，进入标签库。已挖掘出如山上彻也、高启强、燃冬、灵动岛、电锯人、黑暗荣耀、性缘脑等新热词汇。

前沿 NLP 相关技术探索 2021.0

- 探索前沿长文本生成的相关研究。使用 bart 及 T5, T5-Pegasus 进行长文本生成相关研究。

- Sentences embeddings 相关研究。在 SimCSE 的基础上改进自监督句向量表示。产出一篇 CIKM。
- 探索跨模态检索与预训练模型相关研究，完成了微博域内 CLIP 模型训练。

论文

DebCSE: Rethinking Unsupervised Contrastive Sentence Embedding Learning in the Debiasing Perspective

Pu Miao, Zeyao Du, Zhang Junlin, **CIKM '23**: Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. 2023: 1847-1856. 2023

Analyzing the Evolutionary Characteristics of the Cluster of COVID-19 under Anti-contagion Policies

Pu Miao, Hu Tian and Xiaolong.Zheng, in 2020 IEEE International Conference on Intelligence and Security Informatics (ISI) 2020

教育经历

中国科学院大学, 北京 2018.09 – 2021.07

硕士 计算机科学，人工智能学院，导师：郑晓龙，GPA (3.35 / 4)

复杂系统管理与控制国家重点实验室, 中国科学院自动化研究所.

武汉纺织大学，武汉 2014.09 – 2018.07

学士 机械设计制造及其自动化

其他

- 2023 年百度搜索创新大赛 RAG 生成赛道机评第六名、人工评估第二名，综合评估第四名。
- 2023 华为域见杯医学问答赛第六名
- 开源了基于 llama 架构的训练的 0.8B 模型及相关训练代码，从 tokenizer 到基础模型权重均为从头预训练。获得了 130 左右的 star。
- 2022 "阿里灵杰" 问天引擎电商搜索算法赛第九名 (9 / 2771)
- 2021 天池 NLP 中文预训练模型泛化能力挑战赛 (52 / 1673)
- GitHub: https://github.com/enze5088

技能

- 平台与框架: 较为熟悉 Pytorch、熟悉并了解 Megatron、Deepspeed、transformer 等框架。会使用 onnxruntime，vLLm,sglang。熟悉 docker 和 linux 常见操作。