谢湘晋

[redacted]

性别：男 · 籍贯：湖南 · 年龄：26

教育经历

清华大学 2020.09 - 2023.06

- **专业:** 计算机技术, 硕士
- **研究方向**：搜索推荐、LLM、Agent、RL、Text2SQL

中国地质大学 2015.09 - 2019.06

- **专业:** 土地资源管理, 本科

工作经历

阿里云：Text2SQL，多轮对话 Query 改写 2023.7 -

- 主要负责 LLM 的相关工作，包括 SFT、RL、Agent、RAG 相关的工作，同时负责部分搜索相关的内容。
- 提出的 **OpenSearch-SQL** 方法在 BIRD 榜单上取得**世界第一**（2024.8），超过 google、IBM、字节、斯坦福等诸多公司、高校。成果沉淀为论文，当前 **SIGMOD** 条件 Accept。同时取得 Text-to-SQL 专利一篇。
- Text2SQL 算法实现工业级的成果，处理申通、天眼查等公司**千万记录**级别的任务
- 实现多轮对话的 query 改写新的应用场景，已在 hupu、安利场景上取得成果
- 阿里集团内部比赛：AI 无限中取得**冠军**，负责 LLM 算法部分-SmartArxiv
- **BU 季度优秀个人奖**
- 技术上负责 Text2SQL、搜索、Query 改写三个方向，熟悉 LLM 的 SFT、RL 等技术

Apple：Text2SQL 2022.6 - 2023.2

- 构建针对复杂问题的问答系统：基于编辑距离、向量构建提供相似问题预测，基于树形问句处理实现 Text2SQL 完成问题查询。服务于 Apple 内部的销售服务的问答系统。
- 对问答系统语句进行标准化，构建可复用和向后兼容的搜索树, 实现精准问答。

腾讯：GNN、基于图的推荐算法 2021.11 - 2022.6

- 用户画像和用户数据等分析：处理用户信息和视频信息字段, 与腾讯视频主端比较用户年龄、城市、性别、观看时长等信息，分析用户群体和行为等。
- 图神经网络训练：使用分布式处理腾讯视频及子业务片多多的千万级用户和视频数据构建 user-item 图结构，参与推荐算法的维护、优化、评估及数据分析: 使用 Plato 框架对 user-item 图结构进行分布式训练，包括用户观看序列处理，节点映射及模型训练、模型评估。
- 论文、专利产出：**基于软连接的采样方法论文及专利一篇**（服务于图推荐算法，优化 GNN 的采样过程）, 使用软连接捕捉更精细的图结构信息，同时使用基于凸组合的数据增强方式应对冷启动的问题。

研究经历

NLP, OpenSearch-SQL，Text-to-SQL，第一作者 2024.10 -

- OpenSearch-SQL: Enhancing Text-to-SQL with Dynamic Few-shot and Consistency Alignment
- **SIGMOD（CCF-A）2025：长文，under review，条件 Accept**
- 一种基于对齐、SQL-Like、动态 Few-Shot 的 LLM 驱动的 Text-to-SQL 方法，提交时在 BIRD 任务上取得三项指标的第一

NLP, Global Mixup，文本分类，第一作者，ORAL 2021.0[illegible]

- Global Mixup: Eliminating Ambiguity in text classification with Clustering
- **AAAI（CCF-A）2023：长文，acceptance rate ：19.6%. 被选为会议 ORAL 论文**

- 提出一种新的**数据增强范式**，将传统一段式的数据增强变为标签和样本独立生成的两部分：基于样本间的关系生成虚拟样本并依据全局关系矫正标签, 在五个数据集上达到 SOTA,。
- 使用语义关系重新决策标签：数据增强中标签直接伴随随样本生成限制了生成样本的分布空间，使用 Global Mixup 可以使得样本生成和标签生成过程解耦，基于这样的方法优化数据增强。(一种普适意义上的增强方法)

推荐系统，MixDec Sampling，图推荐系统，第一作者, ORAL 2021.11 -2022. 5

- MixDec Sampling: A Soft Link-based Sampling Method of Graph Neural Network for Recommendation
- **ICDM（Data Mining 顶会）2022: 长文，acceptance rate: 9.77%**
- 对图推荐算法的**采样过程**进行优化，负采样中存在着图结构信息表现不清晰，节点关系区分度不高的问题，针对这个问题我们提出一种新的基于软连接的采样方法。
- 创新点：1. 将采样的过程视为节点间的连接程度表示进行 link2label 的转换 2. 更清晰的图结构表达和映射构建节点间的软连接 3. 通过 Mixup 组合生成合成节点和链接。
- 这种方法在三个公共数据集上证明了效果，在 Last-FM（音乐推荐）上取得了超过 40% 的 MRR 提升。

其他项目

NLP, 搜索引擎和问答系统 2021.2- 2021.5，2024.10-

- 构建微信的问答助手，基于 LLM 实现个人微信端的问答机器人，可以实现问答以及 func call
- 构建基于 TF-IDF，粗排、精排的搜索引擎

其他介绍

- 语言：Python、C++ , SQL
- **codeforces:** rank：1500+（c++)
- 熟悉深度学习、LLM、SFT、RLHF 等算法的理论基础
- 清华大学综合奖二等奖学金
- 阿里集团 AI 比赛-冠军
- 阿里云计算平台季度优秀个人奖
- 热爱运动，校运会上取得过奖牌