教育经历

浙江大学（推荐免试） - 人工智能 硕士 2022.09 - 2025.03

山西大学（Rank 2/112） - 计算机科学与技术 本科 2018.09 - 2022.06

实习经历

月之暗面（MoonShot AI） - 推理框架实习生 2024.06 - 至今

- 学习推理相关知识，阅读vLLM源码。协助开发大规模推理服务框架MoonCake，实现组件mock，多级通信的优化和测试，构建scheduler的Unit test。开始独立负责视频模型的推理加速。

上海稀宇科技有限公司（MiniMax） - 训练框架实习生 2024.04 - 2024.06

- 调研和分析了：Transformer Engine的offload方案；Bpipe等PP并行的显存平衡方案；GPU-GPU通信计算串扰，CPU-GPU的通信竞争。
- 设计并实现了一套基于TorchDispatch的针对激活值的自动重计算和swap组件。

上海期智研究院（清华大学交叉信息研究院夏令营） - 指导教授：周冬 2021.07 - 2021.11

- 学习和调研强化学习框架，优化不同agent之间的存储和通信细节，提高强化学习通信效率和计算性能。

竞赛经历

世界大学生超级计算机竞赛（ASC20-21）一等奖 + AI赛题第一名（on-site） 2021.01 - 2021.05

- 作为队员独立负责AI赛题，并协助团队进行集群监控和集群功耗(3000W)控制，最终获得**团体决赛一等奖。（7/20）**
- 作为AI赛题负责人，优化大模型训练，实现分布式训练、量化、剪枝和进程池技术，将模型训练速度提升17倍，**全场第一**获得AI赛题应用创新奖。（**1/20**）（Github）

研究经历

Adding NVMe SSDs to Enable and Accelerate 100B Model Fine-tuning on a Single GPU 2023.06

- 实现了SSD-CPU-GPU的多级数据预取流水，多SSD协同，优化器和反向并行，实现在单张消费级显卡训练千亿参数模型，同时达到100%GPU利用率。收录在Hugging Face daily paper, 目前SIGMOD 2025(CCF A) 在投。
- 作为**第一作者**，实现了整个框架的代码，负责了论文的整体内容。

An In-Network Optimizer for Fine-tuning A Trillion-Scale Model on Distributed GPUs 2023.03

- 采用non-colocated的PS架构，FPGA做智能网卡，P4 Switch广播参数和聚合梯度，实现Trillion级别的大模型微调。目前NSDI 2025(CCF A)在投。
- 作为**共同一作**，负责整体baseline的调研和测试，包括ZeRO-Infinity，BytePS，SwitchML。辅助训练框架的代码设计。

基于Offload和Pipeline Parallelism的单机多卡训练框架(8张RTX 4090微调70B模型) - (in-progress) 2024.03 - 至今

- 多GPU之间通过PP划分模型，减少CPU-GPU通信压力。并聚合micro-batch使得计算和通信overlap。
- 设计CPU Adam使得优化器更新和反向传播并行，并通过D2H和H2D改造P2P通信，避免IPC干扰NCCL的P2P。

荣誉奖项

全国并行应用挑战赛（PAC20）决赛 并行基金奖（on-site） 2020.09

蓝桥杯全国总决赛（国赛三等奖，省一等奖） 2020.11.15

专业技能

- Python，C/C++，Git，Shell，Haskell。
- 熟练使用Nsight System，PLX，PCM等性能监测工具，对大模型训练任务进行Profile。
- 掌握使用Pytorch，Deepspeed，Megatron等开源训练框架，掌握使用NVIDIA，AMD系列GPU的硬件。