教育经历

硕士, 计算机科学与技术, 复旦大学 2022/09 – 2025/06（预计毕业时间）

- 研究方向: LLMSys, AI4DB

本科, 计算机科学与技术, 复旦大学 2018/09 – 2022/07

工作经历

美团 2025/01 – 至今

大模型架构研发实习, 多模态大模型预训练团队 上海, 杨浦

- **Vision Encoder 长序列训练支持 (in-progress):** 设计并实现长序列并行（Context-Parallelism）策略，支持多模态大模型视觉编码器 var-length 长序列训练。

字节跳动 2023/12 – 2024/04

数据库开发实习, ByteHouse Runtime 团队 上海, 杨浦

- **地理数据聚合查询 benchmark:** 开发并基准测试了基于 NYC Taxi 数据集上的地理空间聚合查询，发现了不同数据库平台（StarRocks, ClickHouse, PostGIS, DuckDB, ByteHouse-CE）之间的性能差异，并提出了优化建议。
- **CNCH 地理数据类型支持:** 利用 geos 库将地理数据类型 (geometry data type) 集成到 ByteHouse-CNCH (Cloud Native ClickHouse)。
- **CNCH 地理类型主键索引设计和实现:** 在 CNCH 中增加地理数据主键索引支持, 同时设计多级缓存 (disk cache, memory cache) 加速索引查询。相较于原生 ClickHouse，CNCH 地理数据聚合查询延迟降低近 50% 。

研究经历

Computation Efficient LoRA [Paper] 2024/03 – 2025/01

指导教师: Prof. Binhang Yuan 和 Prof. Kun Yuan HKUST Relaxed System Lab

- **CE-LoRA 算法设计:** 设计了 CE-LoRA，一个用于提高 PEFT 方案中冻结层反向计算效率的算法。该算法结合 AMM (Approximated Matrix Multiplication) 利用结构化稀疏来近似并加速高维矩阵计算；并通过 Double-LoRA 策略保存冻结矩阵的低秩部份，只针对残差矩阵做 AMM 从而在理论和实验上限制了误差的传播。
- **收敛性理论分析:** 提供了严格的收敛性分析，证明了 CE-LoRA 在减少计算开销的同时，能够保持与 LoRA 相同的收敛速度 $\mathcal{O}\left(1/\sqrt{\#\text{ steps}}\right)$。
- **实验结果:** 实现的 CE-LoRA 相比 LoRA 反向计算速率提升 3.39×，同时在多个推理任务中准确率同基线保持一致（误差在 1.58% 以内）。

Learned Range Filter [Code] [Paper] 2023/02 – 2023/12

指导教师: Prof. Siqiang Luo 和 Dr. Meng Li NTU Data Management Research Group

- **Oasis:** 设计并实现学习型范围过滤器 Oasis，其依据照理论分析，将键值空间划分成不相交的多个区间，并利用线性模型模拟的 CDF 作为 hash 函数将各区间数据映射到 bitmap 中；同时 Oasis 利用 bitmap 的稀疏性采用 block-based Elias-Fano 压缩算法在不牺牲查询效率的前提下进一步减小 filter 的空间开销。
- **Oasis+:** 设计并实现 Oasis+, 一种结合 learning-based 和 hash-based 方法的混合型范围过滤器，其通过结合两者的设计理念增强了过滤器在各种工作负载下的适用性和鲁棒性。
- **集成到 RocksDB:** 将 Oasis 和 Oasis+ 整合进 RocksDB 中，并测试了在只读工作负载下各个过滤器的平均查询相应以及 FPR。查询响应时间和 SOTA range filter 相比提升了 6.2×。

Text2SQL [Code] [Paper] 2021/07 – 2022/02

指导教师: 王晓阳 Fudan DASLab

- **参与模型设计和实现:** Generate-And-Rank 是一个 Text2SQL 框架，其假设给定了一组针对数据库的样本 SQL，利用 parser 把这些 SQL 拆分成数个单元，同时 generator 会将这些单元重新组合成 SQL set，后通过 SQL2Text 模型为集合中每一条查询生成对应 text，最终利用 retrieve 策略从集合中找出同用户查询匹配最高的 SQL。
- **构建复杂语义 Benchmark:** 构建含有自连接 (self join) 语义的复杂 Text2SQL benchmark，基于此 benchmark 分析 GAR 同端到端 Text2SQL 模型的能力差异。

发表论文

1. CE-LORA: Computation-Efficient LoRA Fine-Tuning for Language Models **[preprint.]**
   Guanduo Chen*, Yutong He*, Yipeng Hu, KunYuan, Binhang Yuan
2. Oasis: An Optimal Disjoint Segmented Learned Range Filter **[VLDB 24]**
   Guanduo Chen, Zhenying He, Meng Li, Siqiang Luo
3. GAR: A Generate-and-Rank Approach for Natural Language to SQL Translation **[ICDE 23]**
   Y Fan, Z He, T Ren, D Guo, L Chen, R Zhu, **G Chen**, Y Jing, K Zhang, XS Wang