+86 18616206308
18616206308@163.com
https://david0xbb.github.io/

朱 林

专业技能

精通 PyTorch框架及 CUDA 高性能计算生态（cuBLAS/cuDNN/TensorRT）；深入掌握大规模分布式训练底层架构，熟练运用 DeepSpeed/Megatron 框架，并结合 NCCL、Multi-Rail 及 Spine-Leaf/Fat-Tree 网络拓扑优化集群通信；熟悉vLLM 与 SGLang 高性能服务框架，实践 PD 分离架构设计，并结合 FlashAttention、PageAttention、KV Cache 及量化剪枝技术，实现从训练到推理的系统级性能跃升。

熟练掌握 BERT (Encoder) 与 GPT (Decoder) 语言模型范式；深入理解 Flamingo、LLaVA、BLIP 及 SigLIP 等多模态模型的模态对齐与推理机制；精通 DINO (v1/v2/v3) 视觉基础模型演进路线与 VideoMAE 时空表征学习，并具备 VAE (变分自编码器) 与 Diffusion (扩散模型) 等生成式模型的理论与实践基础。

掌握云原生 AI 基础设施构建，精通 Kubernetes (K8s) 生态（包括 Operator 开发）与 Docker 容器化技术。

工作经验

高性能计算研发工程师, Pony.ai, 广州, May 2025 – Oct. 2025

- 自动驾驶推理引擎优化和车载模型量化
  1. 主导自动驾驶端到端推理体系在 NVIDIA Orin/Thor 平台的工程化落地。设计统一的 TensorRT 推理引擎框架，将感知 (BEV)、预测、规划整合至同一 Runtime，实现跨模块显存共享与动态算力分配，显著提升系统资源利用率。
  2. 设计并落地基于 TensorRT 的 INT8 PTQ 自动化量化流水线，实现 FP32/FP16 模型一键量化至 INT8，覆盖校准、FP/INT8 对齐验证及车端部署；通过构建精度回归与性能评估机制（逐输出误差、Cosine Similarity、PSNR、Loss/Metric），在保证感知精度可控的前提下显著降低推理延迟并提升车端稳定性。
- 自定义 TensorRT 插件与 CUDA Kernel 优化
  1. 针对 BEVFormer、Occupancy Network 及 VLA 多模态大模型，研发高性能 TensorRT 算子库。设计实现Flash Attention、BEV Pool、Voxelization 等关键插件，解决高并发访存瓶颈，显著提升了生成式与感知模型的推理吞吐率。

Principal Software Engineer, Dell EMC, 上海, March 2020 – Apr. 2024

- 算法实现与 GPU 加速优化
  1. 主导 Transformer 核心模块（MHA/FFN/LayerNorm/RoPE/KV Cache）的算法级重写与 CUDA Kernel 优化，通过减少访存、优化寄存器使用、并行度调度、

operator fusion，提升计算效率，加速训练与推理。

2. 以 FlashAttention 为基础实现多项定制 Attention 加速策略（FlashAttention-like Kernel、Block-sparse Attention、上下文拼接 KV-cache fusion），减少 访存瓶颈，使 context 长度翻倍时仍保持线性可扩展性。
3. 在Hopper架构上深度利用 TMA、Warp-level producer–consumer pipeline、Register Reallocation 等架构特性重写 Attention/FFN 热点 Kernel。

- 非凸优化算法与大规模训练数值稳定性设计
  1. 解决 LLM 大批次训练中的梯度爆炸/消失、损失震荡、数值不稳定的问题。
  2. 提升BERT/GPT 系列模型的收敛速度，使得大批次（64K ~ 256K）训练更稳定。
- 大模型与分布式训练算法设计
  1. 参与构建大模型训练框架，负责并行策略的设计与优化，包括 Data Parallel、Tensor Parallel、Pipeline Parallel 的调度，以及通信/计算 overlap 的算法设计。
  2. 基于 NCCL/RDMA/RoCE/InfiniBand 深入优化 AllReduce、AllGather、ReduceScatter，优化拓扑感知（topology-aware）通信路径，降低梯度同步延迟。
- 参与策略梯度方法（PPO、A2C）在大规模并行环境中的训练框架实现，负责训练 loop、advantage 计算、 value 网络更新的底层算法优化。

Software Architect, 万得信息技术股份有限公司, 上海, June 2018 – Jan. 2020

- AI Infra 开发.

IC5, 英伟达半导体科技(上海)有限公司, 上海, Dec. 2017 – May 2018

- CUDA 开发.

Lead Software Engineer, TD Tech, 上海, Feb. 2017 – Oct. 2017
Lead Software Engineer, 泰乐通讯技术（上海）有限公司, 上海, August 2012 – Jul. 2016
Software Engineer, VeEX Inc, 北京, September 2009 – September 2011

- C++ 开发。

Software Engineer, Beijing BlueSky Technologies, **北京,** May 2008 – Sept. 2009

- C++ 开发。

教育背景 西安电子科技大学

电子科学与技术 – 学士, 2002/9 – 2006/7