魏雍
Github

weiyong1024@gmail.com
(+86) 173-7657-1024

教育背景

- **硕士 - 北京航空航天大学 - 电子与通信工程** 中国，北京
  保研; 研一上学期发核心期刊达毕业标准; 北京市优干 *2016 年 9 月 – 2019 年 1 月*
- **本科 - 北京航空航天大学 - 电子信息工程** 中国，北京
  沈元荣誉学院 (入学 top50/3000+); 北京市三好; GPA 3.7 *2012 年 9 月 – 2016 年 6 月*
- **高中 - 大连育明高中** 中国，大连
  CPhO（全国中学生物理竞赛）省一等奖获高考免试保送资格 *2009 年 9 月 – 2012 年 6 月*

编程竞赛

- **Google Code Jam Kickstart (谷歌 2017 全球校招赛)**
  全球 108th, 中国 18th, 前 5% ***计分板链接 (id - WeiYong1024)***

工作经历

- **心识宇宙（天使轮加入，国内 LLM 应用先驱创业团队）** 中国，杭州
  基础设施技术主管，领导 4 人团队，构建大模型应用的 AiInfra+DataInfra+DevOps 体系 *2022 年 6 月 - 至今*
  - **公司代表产品**
    - **MeBot**：启发型个人助理，Web 版于 2024.8 获 ProductHunt 周榜第二，App 版已上苹果 AppStore。
    - **MindOS**：国内早期 LLMAgentPlatform，2022.10 上线，2023.7 获 ProductHunt 周榜第一。
  - **公司技术设计**
    - **LPM(Large personal model)**：基于 Lora 与用户在线数据训练个性化 LLM，可用于生产环境。
    - **MindOS**：国内最早的 LLM Agent Platform，比字节 Coze 平台上线时间早 17 个月。
    - **UMM(Unified mind model)**：统一心识模型，比 OpenAI 首次提出 AIAgent 概念早 16 个月。
  - **Infra 技术职责**
    - **AiInfra ——打造 LLM 应用基础设施最佳实践**
      - **MLOps 平台**：设计并实施包含数据采集、数据增强、LLM 训练、LLM 部署的全链路自动化 MLOps 平台。结合开源工具 ClearML 的模型观测能力，用于支撑 LPM 实时训练并做生产部署。
      - **LLM 统一接入层**：前期使用 Java 自建基础服务，实现 OpenAI、AzureOpenAI、GCPVertexAI、Claude 等模型的统一接入、部署管理、多账号池化、探活、权重分配、成本统计与可视化等功能。后期迁移至 LiteLLM 作为提供上述功能的最佳实践。
      - **LLM 工程平台**：使用 Langfuse 标准化算法离线实验管理、Prompt 资产管理、资产版本管理、线上 LLM-Tracing 等功能。
    - **DevOps ——高效、安全生产**
      - **生产环境管理**：设计并搭建 Prod/Pre/Test 等多套生产环境，包含严格 CodeReview 流程的可伸缩 GitServer、CI/CD 流程、零信任设备管理等基础设施。涉及技术：Gitlab、Helm、Java、Jenkins、JumpServer、Kubernetes、Octant、Python、Rancher、Shell 等。
      - **系统可观测性**：选型、设计并构建公司后台系统使用的分布式配置、分布式限流、分布式调度、应用性能监控及日志监控内部生产等基础设施。涉及技术：Apollo、Datadog、Grafana、Loki、Nacos、Prometheus、Sentinel、Skywalking、xxl-job、腾讯云 CLS 等。
      - **云及三方服务管理**：公司内部用户权限管理，精细化管控用云、用三方服务的成本，设计、制作及维护成本大盘。涉及技术：Azure、GCP、CronJob、TencentCloud 等。
    - **DataInfra ——管理数据资产、提供实验工具、数据驱动决策**
      - **在离线数据体系**：设计、构建并维护包含 OLTP->CDC->OLAP->DataVisualization 的在离线数据流用于离线数据开发，包含消息队列-> 埋点服务的异步数据流用于用户行为数据分析等场景。支撑各类指标的大盘、运营 BI 报表等需求。涉及技术：MySQL、Clickhouse、Debezium、Superset、RocketMQ 等。
      - **A/BTest 工具体系**：选型、设计、构建并维护包含实验配置/结果分析平台（GrowthBook）+ 前端埋点（GoogleAnalytics）+ 后端埋点（Springboot 实现，包含工程和算法）的全链路实验工具体系。实现前端页面、后端算法的功能开关和 A/B 实验。涉及技术：GoogleAnalytics、GrowthBook、Java、NodeJS、Python 等。

        - **产品隐私合规**：构建一系列隐私合规标准，包括但不限于数据脱敏、内部培训等，使公司产品达到北美 USDP 和欧盟 GDPR 隐私合规标准。
    - **业务层研发——提供业务开发依赖的基础服务**
        - **中台基础服务**：设计并构建中台基础微服务，为业务系统提供后端加密存储、用户隐私数据库、Web 爬虫、离线数据舒仓管理等通用基础服务，并以 RestfulAPI、二方库 +RPC 接口等形式输出。
  - **支撑业务**
    - 主导移动端小程序万物总动员、Web 端产品 MindOS、App MeBot 及各种子系统的全链路压测、发布过程重保；准备并制定 toB 公有云/专有云/私有化产品交付 SOP；服务架构随业务跨国/跨云地域迁移等。
    - 在全公司横向推进 blameless postmortem 文化，组织安全生产周会。

- **阿里云** 中国，杭州
  高级工程师、后端、Java、Springboot、阿里云 *2020 年 8 月 - 2022 年 5 月*
  - **流量调度中间件**: 在集团高可用团队负责阿里云内部流量调度中间件。基于阿里内部的 PandoraBoot（Springboot 加强版）提供集群上容器粒度秒级健康指标监控、3σ 离群点检测，依托阿里内部 RPC 框架 HSF(Dubbo 内部版) 的权重表机制实现微服务的分钟级流量调度与恢复链路。防单点故障引起的集群雪崩，也可用于 JIT 预热。任职期间推广产品纳管了阿里集团全部核心应用，支撑 40w+ 容器，作为核心安全组件护航 2020 双十一 60wQPS 流量洪峰。
  - **私有云管理平台**: 时年 P8 团队目标建设政务场景下的专有云管理系统。基于 Java 框架 Springboot 开发，该系统分应用运维、资源运营、总集管理三个子系统。我负责其中应用运维中心子系统的后端开发。应用运维中心底层构建云资源列表、监控巡检、用量统计、自定义接口巡检、SQL 巡检等原子能力，并在上层此构建了慢 SQL 统计分析、业务大盘、体检报告等专家报表。该系统目前在全国超过 6 个局点商业化输出，重保护航 2021 某省会城市小学入学等项目、2022 春节核酸检测等项目。
  - **政务云管轻量化交付**: 时年新 P9 团队目标交付 7 个地方政务私有云，早期由开发同学使用 Rainbond 界面化地将来自原不同团队的微服务组合部署在客户 K8S 集群上，配置繁琐导致交付周期长。为解决该问题我基于 docker-compose 搭建单机版轻量化部署交付方案，基于通用的环境初始化脚本与交付步骤文档，仅通过维护不同客户现场的环境变量以中心化管控，纳管来自各个老团队的 20+ 个微服务。编辑 WBS 和 SOP，组织外包同学培训交付流程，单个经过培训的外包可以在 2 日内交付/升级一个现场。基于该方案，团队技术产品簇的单月商业化输出能力从个位数据点上升到两位数。
- **小马智行(L4 自动驾驶解决方案)** 中国，北京
  工程师、Infra、C++、Python、Linux、Bazel、严苛的代码质量标准 *2019 年 2 月 - 2020 年 3 月*
  - **行车录音工具链**: 无人车路测需要一位跟车工程师通过外接键盘描述记录路测 issue，为去掉跟车工程师构建行车录音工具链，以麦克风和物理按钮作为硬件方案。首先在 Bazel 项目中引入基于 BSD 软件许可的输入设备接口库 evdev，并基于该库和 Linux 的 ALSA 音频驱动编写守护进程，负责硬件检测、监听来自外部按钮的信号和车载系统进程的管道信息、触发与停止麦克风录音，在行车过程中将 issue 信息存储为工控机上的音频文件。在数据处理阶段，首先在 GCP 上搭建语音转文字服务，并用 Python 脚本将音频文件的内容提取出来，然后使用 Google 的 Protobuf 工具将原信息序列化汇入 QA 数据流。
  - **车载语音系统**: 原车载语音模块使用 Google 的 Pico TTS 库在行车过程中将硬编码的语音内容文本实时播放，从而导致语言单一和 TTS 过程重复消耗计算资源的问题。新的车载语音系统使用基于音频文件的工作流程，旨在减少车载工控机的计算量并支持语音 I18N。为此 1. 研发环节用 Python 编写内部 CLI 工具 `car_sound_utils`(以下简称 CLI)，供内部工程师创建和变更现有语料库、管理语音包版本：首先在 CLI 中基于 AWS 上用 CloudFormation、Lambda 函数计算搭建的整套 TTS 服务封装音频创建命令，然后在 CLI 中添加上传、下载语音文件和上传语音包到内部 storage server 的命令，以及缓存机制加速上传下载。2. 车载系统环节，主进程初始化语音模块时使用 Linux 的 ALSA 驱动将音频流加载进内存，并在语音模块接到播放请求消息时播放。

实习经历

- **爱彼迎**: 2018 年夏，爱彼迎发力中国市场，作为大陆首批 8 个实习生，全栈开发了当年国内版房东年度回顾页。
- **旷视科技**: 2018 年初，旷视和 VIVO 合作期间，参与 X21 机型人脸识别模组的研发，做基于 InceptionV3（一种 CNN）移动端模型搜索优化。

系统经验与技术栈

- **系统经验**：MLOps、LLM 应用、Prompt 工程、超大规模分布式系统、高可用、可观测性、自动驾驶等
- **技术栈**：Java、Python、Kubernetes、Shell、C++、国内外主流云、主流运维工具等