教育经历

燕山大学 2022年09月 - 2025年06月

计算机技术 硕士 秦皇岛

中国计量大学 2017年09月 - 2021年06月

信息与计算科学 本科 杭州

全国大学生数学建模浙江省二等奖、浙江省数学竞赛（数学专业）省一等奖、浙江省物理竞赛省二等奖、CET-6

专业技能

编程语言: 掌握 **Python** 编程，熟悉**Java**、**C++**。

框架与工具: 掌握 **PyTorch** 框架，熟悉 **Langchain** 框架，了解 **LlamaIndeX** 框架，熟悉**Llama factory,**了解 **DeepSpeed** 进行分布式训练、了解**VLLM**框架进行推理加速·。

大模型理论: 熟悉大**语言模型的基础理论**包括预训练、微调、对齐、**强化学习（RLHF，PPO，DPO）微调、模型蒸馏。**

了解DeepSeek，了解**多模态**相关理论。**Prompt 工程**: 掌握 Prompt 设计与工程实践。
微调与部署: 掌握使用Llama factory**模型微调**（LORA，Full Fine-tuning，P-tuning，DPO，PPO等）过程，包括数据集构造、模型部署。了解**模型量化**理论和**推理加速**技术。
检索增强生成（RAG）: 掌握 RAG 相关知识，优化生成效果，包括分割的**索引优化、embedding微调，Rerank模型微调，query改写，多路召回**等方式。
Agent 开发: 掌握 Agent 理论与开发技术。包括**Function calling**，多种**记忆机制**，**反思机制，推理机制，以及多agent 进行交互技巧。**
其他大模型有关技术：了解**Dify、Coze工作流**相关的工具，了解**NL2SQL、长文本**相关技术。熟悉**自然语言处理、推荐系统、搜索、知识图谱、图神经网络、以及多种传统机器学习。**了解多模态技术**Stable Diffusion**、**ControlNet。**

搜索与数据库: 掌握使用 **Elasticsearch**、**MySQL**、**Redis**、**MongoDB**、**Milvus**、**Neo4**j进行数据管理。
其他技术: 熟练使用 **Linux**、**Git**、**FastAPI**、**Docker**、**Django**、**Selenium** 等开发。

实习经历和项目

北京智谱华章科技有限公司 2023年08月 - 2024年06月

算法实习生 AminerAIGC事业部-平台部 北京

- 基于大模型的论文对话检索方法系统 主要负责人
  基于**Self-Instruct**框架的指令数据自生成技术，构建高质量多任务训练数据集，结合**LoRA等参数高效微调**方法，优化ChatGLM3-6B模型在**函数调用**（**Function-Calling**）任务中的泛化能力，实现10类核心函数**解析准确率**提升。系统采样**多级响应机制：**融合意图识别、大模型解析函数，融合用户对话记录，以及多种回复策略，实现精准高效的论文交互服务。首先通过**意图识别**模块对用户输入进行分类（实体相关问题还是概念相关问题)，**用户对话上下文**生成最终提问。使用微调后的ChatGLM3-6B模型能够解析出**json形式**函数名称和参数，根据调用**相关API**结果并与用户的输入问题进行**流式回复**，对于解析正确但是API结果为空的内容，获取**谷歌联网搜索信息**然后进行回复，对于API解析失败的的情况直接使用大模型进行回复。同时从日志中提取badcase进行**增量训练模型**机制，不断提升线上回答准确性。
- 基于大模型的社交机器人Agent养殖系统 主要负责人
  基于**Agent**技术和**Selenium**框架，开发了一套自动养殖账号的系统。首先对于Agent构建基本人设，然后从社交媒体首页推荐、热门信息以及大V账号首页中，抓取推文的**多模态信息**（使用**ChatGLM-4V**将图像转为文字信息、原始推文文字和评论内容）。结合预设的**账号人设**和**记忆信息**，利用ChatGLM-6B返回账号**json格式的动作列表（点赞、转发、评论）**，使用Selenium执行相关动作。通过改写原始推文**生成原创的推文**，使用**CogView**生成图像，产生多模态推文，并**生成#关键词和#热门关键词**，以提高内容曝光率。设有**大模型判别和关键词判**别作为**风控模块**，用于确保输出内容的准确性，对合格内容执行相应操作。对热门信息推特和大V账号执行以上的操作。将Agent行为数据用**知识图谱、文本、关键字形式存储于记忆中**，形成**短期、中期、长期记忆**，最后**动态凝练修改人设。**基于短期记忆，Agent执行推特平台**搜索功动作**，行深度挖掘和互动。在养殖的同时，针对某些时效性较低的内容（旅游、美食）构建**多模态素材向量库**，使用向量检索为不同准确的多模态素材。
- 基于Langchain框架的个人RAG文档问答助手
  该项目是一个基于 FastAPI 和 Langchain 构建的高效智能问答系统，支持**私有知识库**（如 PDF、DOC 等格式）与**公有知识**

据集）的灵活问答。同时，使用**Query改写**功能进行 **SerperAPI 实现联网检索**功能，确保用户可以获得实时更新的知识库信息。系统使用了**BGE模型**（用于文档内容的向量化）和**多路召回**策略（包括**稀疏检索和密集检索**的 RAG 方式），同时使用**假设性文档嵌入（HyDE)和React**方式进一步增强检索，精准匹配用户问题和文档内容。通过 **Reranking** 技术对召回的内容进行重新排序，进一步优化问答的相关性与准确性。此外，并支持在本地模型和在线模型之间切换，提供实时、准确的回答。

- 基于大模型的AI写作系统 参与者
  AI写作助手，该助手利用大型模型的函数调用能力，识别相关的函数接口，从而召回相关学术文献。使用思维链**COT**的方式，从文献中提炼出关键的研究问题和创新点，以及**生成论文的大纲**。根据用户提问生成**多视角Agent**对于题目进行生成内容，使其能够从**多角度生成多样化**的研究子主题，以增强写作的深度和广度。利用这些子主题，对子问题进行文献检索。在最终生成作文的时候，引入了**反思评估器**，通过大模型进行**投票和筛选机制**，确保了最终输出结果的学术价值和准确性，显著提升了AI写作助手的性能。
- 维护优化Aminer推荐系统 主要负责人
  负责了Aminer推荐系统的优化工作，对原有代码进行**解耦和模块优化**，成功提升了系统的推荐效果和用户体验。构建了根据用户关注进**行跟踪学者时间轴**的功能。通过大模型对联想词和实体数据进行清洗，优化了信息检索的精准度，对不同embedding模型进行性能测试与评估。**探究大模型和推荐结合**的算法。

论文研究

- Learning-Based Link Anomaly Detection in Continuous Time Dynamic Graphs 学生一作 返修

  通过**快速傅里叶变换**（FFT）在频域中捕捉时间序列数据的全局和周期性变化，然后利用频域解耦卷积层和残差线性增强技术来提炼和增强节点的时间感知特征。在边预测任务中，使用**KAN网络**代替了传统的MLP进行分类预测进一步提高下游任务的准确率。通过在多个真实世界动态图数据集上验证了其在**动态图**表示学习中的优越性能，特别是在捕捉时间依赖性和预测未来节点属性或链接关系方面。

- Long-Short Embedding Framework for Cross-Domain Recommendation 学生一作 在投

  使用**对比学习**的方式将用户的兴趣和物品的特征**解耦为长期特征和短期特征**两种类型，然后结合不同域的特征，能够更准确地捕捉和表征用户不同域上的特征进行**跨域推荐**。

- Enhancing LLMs for Universal Sequence Representation in Recommender Systems 学生一作

  采用**LoRA**（Low-Rank Adaptation）微调技术对通用序列模型进行优化，通过LoRA微调，模型能够快速细致地捕捉物品的语义特征，通过**大模型增强数据集文本**的内容，同时使用将图像信息转为文字内容，引入了**MOE**（Mixture of Experts）模型来融合物品的多种属性和多种模态的信息。使用对比学习的方式进一步提高预训练模型的能力。模型能够更快速且准确地学习到**序列推荐**的通用知识。该方法在多个数据集上的表现优于现有技术，在下游任务中展现了优越的推荐效果。

专利

- 一种问答式论文检索方法 专利号 202410765324.8 智谱公司
- 一种利用知识图谱增强检索文本和推理的方法 专利号 202411150364.8 智谱公司
- 一种生成论文推荐列表的方法 专利号 202410686246.2 智谱公司
- 一种结合大语言模型和对比学习的增强跨域顺序推荐方法 专利号 202410535156.3 燕山大学

软著

至今

- 基于JAVA的停车场收费系统 软著号2024SR1152394
- AI辅助写作系统 软著号 2024SR1171323
- AI科研助手系统 软著号 2024SR1214556
- 基于Vue和springboot的药物管理系统 软著号 2024SR1706817

个人总结

具备不错的动手能力，并对前沿技术充满热情。通过深入阅读和研究开源项目的源码，不断提升自身的技术水平和理解力。对新技术保持着强烈的求知欲，积极探索并实践最新的技术趋势，力求将最先进的知识应用于实际项目中。无论遇到多大的挑战，始终保持积极向上的学习
术领域中不断成长与突破。