[redacted]

[redacted]

github.com/youhengchan

应届生 | 大模型算法工程师

教育经历

湖南大学 2021年09月 - 2025年06月

控制工程 硕士 电气与信息工程学院 长沙

- 发明专利：ZL 202410381335.6 一种文本生成方法、装置、计算机设备和存储介质 第一发明人（大语言模型安全护栏算法）
- 软著：2024SR0427925 基于大语言模型的医疗软件 V1.0 第一作者
- 论文：Easy for Children, Hard for AI: The Limits of Multimodal LLMs in Early Childhood Learning (AAAI 2026，CCFA，第三作者) (关键词: 大语言模型，多模态，空间推理，评测基准)
- 论文：CN-SarcasmBench: A Chinese Benchmark for Contextual Sarcasm Understanding and Response (NeurIPS 2025，CCFA，第三作者) (关键词: 大语言模型，思维链，上下文学习，位置偏见，评测基准)
- Kaggle：LLMs - You Can't Please Them All 银牌 Top 4.3% 主题: 大语言模型评价竞赛
- Kaggle：March Machine Learning Mania 2025 铜牌 Top 7.5% 主题: 篮球胜率预测竞赛
- 开源项目：MOHU: 基于 AC 自动机和编辑距离的中英文模糊词匹配库，支持中英文/文字/拼音混合模糊匹配 (安装: pip install mohu， 源码: github.com/youhengchan/mohu)
- 学位论文：基于大语言模型的医疗诊断研究 记录医疗大模型的数据准备、训练、评测、量化、部署上线全流程

湖南大学 2017年09月 - 2021年06月

数字媒体 本科 信息科学与工程学院 长沙

- 国家奖学金，英语六级 511，TOEFL 84 (口语流利，可全球出差)
- 机器人校队算法组组长 负责队员招新、培训、选拔和调度，并和电控组与机械组协作（良好的组织、沟通、协作能力）
- Robomaster 全球大学生机器人竞赛 算法组二等奖 (大疆创新与共青团中央联合举办)

实习经历

唯品会(上海)电子商务有限公司 2025年02月 - 2025年07月

Agent 开发实习生 智能客服部门 上海

唯品会商家智能助手（Vip Bot）

- 概述: 面向电商商家的经营智能体系统，探索层级化 Multi-Agent 架构以提升平台规则问答、店铺经营诊断与归因、跨系统复杂任务编排和营销内容生成，显著降低人工决策成本并提升可规模化运营能力。
- 技术栈: Multi-Agent System、ReAct Framework、Hierarchical Agent Architecture、SFT、Function Call、Vector Search、Full-Chain ReAct Monitoring
- 核心贡献
  - 1. 数据工程: 整合超 1000 万条在线服务/运营文档/操作日志，完成清洗去重与业务专家知识库构建；联合产研沉淀 50 万+ 高质量 SFT 样本（含 [问题, Thought, Action Code, 最终答案]），对齐复杂任务的推理路径。
  - 2. 推理检索: 基于 ReAct 范式实现 Thought → Action Code 的可解释链路；通过 Thought 驱动的查询重构，将“小香风”归入“女装”平台分类并生成精准 Search Query，化解实体不匹配导致的检索失败。
  - 3. 训练与对齐: 在电商语料上持续预训练以注入隐式垂域知识（如“价格波动/库存显示规律”），再以 SFT 强化 Thought → Action 决策与跨工具编排能力。
  - 4. 监控评估: 自研全链路 ReAct 监控，对在线 [Thought, Action, Observation] 逐步打分；当低于阈值时提前中误扩散，将无效任务资源消耗降低 65%。
  - 5. 多智能体编排: 设计 Master Agent 负责意图理解、任务拆解与调度；定制 Consulting Advisor（平台知识顾 Analyst（数据分析）等 Domain Agents，配套专属工具集，完成跨 10+ 后台系统的自动化编排。

- 量化成果
  - 1. 知识命中率/问题解决率: 由传统 RAG 的 55.2% / 48.7% 提升至 95.8% / 92.3%（Consulting Advisor Agent）。
  - 2. 时延与效率: 入驻咨询响应时长由 5 分钟降至 10 秒；“店铺经营诊断”类复杂任务由 1 小时降至 3 分钟。
  - 3. 覆盖与节省: “招商入驻 Agent”承接 60% 常规入驻咨询；全链路 ReAct 监控将无效任务资源消耗降低 65%。
  - 4. 自动化能力: 通过 Master Agent 统一调度，打通并自动化跨 10+ 后台系统的操作流程。

北京智谱华章科技有限公司 2024年07月 - 2024年12月

多模态算法实习生 大模型应用部门 北京

“Retail-Pulse”——基于 VLM 与 RL 的细粒度顾客行为智能分析平台

- 概述: 面向线下零售场景的“人-货-场”行为智能分析平台，将微观人-物交互转译为结构化行为与可操作决策。以视频大模型（VLM）进行时序动作分割与 HOI 检测，叠加强化学习（RL）挖掘高转化决策路径，服务于陈列优化、导购干预与营销 A/B 测试，显著缩短实验周期并提升转化率与运营效率。
- 技术栈: Video-LLM（GLM-4V）、TimeSformer、GRPO、Reward Shaping、OpenCV、Kafka、PyTorch、ONNX Runtime/TensorRT、Tableau
- 核心贡献
  - 1. 数据与样本工程: 汇聚公开数据集（含 CARR）与合作商场 5000+ 小时匿名化监控视频；搭建人机协同标注平台，基于 12 类细粒度零售行为分类法完成时序与交互对象标注；沉淀 20 万+ 高质量标注视频片段，构建统一事件模式 <顾客ID, 行为, 商品ID, 起始帧, 结束帧> 与数据质量基线（抽样复核/一致性校验/跨标注员重叠对比）。
  - 2. VLM 时序动作分割与 HOI: 以 GLM-4V 作为视频理解骨干，结合 TimeSformer 捕获长程时序依赖；在 20 万样本上进行监督微调（SFT），输出结构化事件流；实现跨摄像头目标关联与轨迹跟踪，配套时间维度的非极大值抑制与片段合并策略，提升片段边界与跨人/跨物体消歧能力。
  - 3. RL 决策模式发现: 构建“顾客行为序列→下一步高价值行为预测”的环境；以“Place_In_Cart +10 / Compare_Products +3 / Pick_Up_And_Return -5”为密集奖励塑形，缓解购买支付信号稀疏；用 GRPO 训练策略网络，学习最大化累计意图分数的最优行为路径，产出可解释的高转化模式库。
  - 4. 监控与评估: 建立从“感知→抽取→推理→决策”的全链路评估与可视化看板（Tableau）；对比启发式基线（目标检测+停留时长）并进行离线/在线一致性校验；引入数据漂移与性能阈值告警，支持按门店/货架/时段的细粒度切片评估与回放定位。
  - 5. 架构复用分析: 以 Kafka 为事件总线，摄像头→解码→VLM 分割→事件标准化→RL 推理→指标落库的流式加工链；封装原子能力（人-物交互检测、行为序列建模、路径打分、A/B 分析）与复用任务模板（陈列 A/B、导购策略评估、动线诊断）。
  - 6. 模型压缩与边缘部署: 在店端进行 INT8 量化与图优化，落地 NVIDIA Jetson AGX Orin 边缘设备；边缘优先推理、云端回补复核的混合部署，带宽与时延可控并降低云端依赖与成本。
    - 注意力/时序模块融合 Plugin：将 TimeSformer 的注意力与时序池化融合为单个 TensorRT 插件（FP16/INT8），减少 kernel 启动与显存往返；模块级约 1.8–2.3× 加速，端到端时延降低约 35–50%。
    - 图优化与多 Profile 量化引擎：ONNX 图折叠与布局统一，INT8 PTQ（per-channel）构建 240p/480p/720p、T=8/16/32 多 Profile 引擎；Jetson Orin 稳定 30 FPS，并支持 ORT↔TRT 自动回退。
- 量化成果
  - 1. 预测与识别: 微调后 VLM 在 12 类零售行为上的识别准确率 91.5%，F1=0.90；端到端“VLM+RL”对高转化路径的购买预测准确率 88.9%（相较基线 45.3% 有显著提升）。
  - 2. 部署与性能（概括）: 注意力/时序融合插件 + GPU 侧后处理一体化 + 图优化/INT8 多 Profile，引入后关键通路加速 1.8–3×、端到端时延 -35%～50%，GPU 利用率 +20pp；Jetson Orin 720p/16 帧稳定 30 FPS。
  - 3. 周期与效率: 商品陈列 A/B 测试周期由 2 周缩短至 3 天，支持多门店并行评估与在线回放定位。
  - 4. 经营成效: 试点店铺高价值商品区顾客主动交互率 +25%，相关品类销售额 +15%。

博世长沙汽车部件有限公司 2024年01月 - 2024年06月

NLP 算法实习生 智慧物流部门

跨境货物清关审查助手

- 概述：面向跨境物流场景的合规审查与风控系统，支持合规查询、风险分析、多单据联审、多语言转义与流程指导；线、检索-重排-生成链路与评估体系。

- 技术栈：MinerU (OCR)、bge-m3、BM25 (Elastic Search)、Milvus、Neo4j、bge-reranker-large、Qwen1.5-14B/7B/1.5B（CPT+SFT+DPO）、FastAPI、Docker/vLLM、Prometheus/Grafana、Langfuse
- 核心贡献
  - 1. 数据工程: 5TB 原始文件清洗至 270GB 纯文本；按源类型设计递归/聚类/知识图谱/LLM 分块，构建父子文档索引与丰富 metadata。
  - 2. 检索融合: 稠密（Milvus+bge-m3）/ 稀疏（BM25）/ 图（Neo4j）三路召回，各取 top20，经 RRF 粗筛至 top20，使用 Cross-Encoder 重排至 top5。
  - 3. Embedding 微调：基于 bge-m3 在 120 万对“海关法规/申报要素/合规问答”语料上做领域对比学习微调，优化向量语义与跨语种表述对应。
  - 4. Reranker 微调：基于 bge-reranker-large 在 20 万条召回候选对上做二值相关性标注 + pairwise 排序微调，有效提升相关文档排名稳定性。
  - 5. 生成与代理: 基于 Qwen1.5-14B 搭建检索增强生成与工具调用（图查询、规则计算、翻译、表单校验），输出结构化 JSON（结论/风险/材料/步骤/证据）。
  - 6. 微调与改写: 对 Qwen1.5-7B 进行持续预训练（物流+关务语料）与 15 万条问答全参微调；以 Qwen1.5-1.5B 进行槽位填充与 Query Rewrite。
  - 7. 规则与风控: HSCode 一致性、禁限清单、危险品、要素缺失、价值异常、术语/运输匹配等可解释规则；叠加 Isolation Forest 等统计检测。
  - 8. 多语言与可追溯: 德语、英文、中文多语统一向量空间，按用户语言输出；全链路审计（召回候选、重排分数、证据引用、模型版本、图查询）可回溯。
- 量化成果
  - 1. RAG 评测：Recall@20 从 64.8% 提升到 82.4%；Precision@5 从 75.2% 提升到 91.6%；Task Acc 从 63.1% 提升到 92.5%。
  - 2. 时延与效率: 单次审查时长由 3 分钟降至 30 秒；复审由 10 分钟降至 1 分钟。
  - 3. 成本优化: 知识压缩 60% 方案将 Token 用量降低 35%，任务准确率仅从 89.7% 微降至 87.2%。
  - 4. 体验指标: 端到端 P95 < 2.5s（单机 1×A800 GPU），可水平扩展。

专业技能

- 训练框架：熟悉 LLama-Factory，Unsloth，Deepspeed，Megatron 等主流（分布式）框架
- 推理框架：熟悉 vLLM，SGLang，Ollama，TGI，Llama.cpp 主流推理框架
- Agent 框架：熟悉 Coze，Dify，FastGPT（在线 Agent）以及 LangGraph 本地 Agent 框架
- 模型复现：复现 Transformer，BERT，GPT，Llama，Qwen，DeepSeek 等模型结构
- 强化学习：复现 DPO、PPO、GRPO、DeepSeek-R1 等经典强化学习算法和模型训练
- 开发工具：熟悉 Linux，Docker，Git，VSCode，Cursor，Trae 等（AI）开发工具