清华大学计算机系26届硕士

[illegible]

教育背景

清华大学 | 计算机科学与技术 | 全日制工学硕士（在读） 2023.09 - 2026.06

- 大模型安全与对齐、强化学习

哈尔滨工业大学 | 计算金融 | 全日制第二学位 2022.09 - 2023.09

- 中途转赴清华大学攻读工学硕士

哈尔滨工业大学 | 物联网工程 | 全日制本科 2017.09 - 2022.06

- 主修数据结构与算法、计算机体系结构、计算机网络、编译原理、数据库、信息物理系统等

论文发表

SafetyBench: Evaluating the Safety of Large Language Models with Multiple Choice Questions ACL 2024 Main Conference

Zhexin Zhang, **Leqi Lei,** Lindong Wu, Rui Sun, Yongkang Huang, Chong Long, Xiao Liu, Xuanyu Lei, Jie Tang, Minlie Huang | 一个影响广泛的评估大语言模型安全性的数据集，目前谷歌引用量已达172次

工程项目

AISafetyLab: A Comprehensive Framework for AI Safety Evaluation and Improvement

已投稿至ACL 2025 demo | GitHub 117 Stars

Zhexin Zhang*, **Leqi Lei*,** Junxiao Yang*, Xijie Huang*, Yida Lu, Shiyao Cui, Renmiao Chen, Qinglin Zhang, Xinyuan Wang, Hao Wang, Hao Li, Xianqi Lei, Chengwei Pan, Lei Sha, Hongning Wang, Minlie Huang

一个为研究者提供的全面的安全研究工具框架，涵盖攻击、防御和评估，我主导了其中大模型攻击模块的设计和开发

Attacker-v0.1: A red-teaming model that jailbreaks the safest LLMs

计划投稿至EMNLP 2025

作为第一完成者开发训练的性能强大的红队模型，支撑组内某涉密国家重点研发项目，支撑部委重大业务需求，模型与推理评估代码业已开源，已吸引来自Virtue AI（美国著名AI安全研究机构）、美国东北大学、英国华威大学、浙大、电子科大、上科大等机构的研究者申请使用；论文正在撰写中，计划投稿至EMNLP 2025

MTPhysics: Try to Improve the Knowledge Extraction Ability of LLMs by Using Multi-token-prediction

在著名工作《Physics of Language Models: Part 3.1, Knowledge Storage and Extraction》的基础上做的探索工程。首先提供了该项工作在开源社区第一个较为完整的复现版本（上述工作并未开源），其次在其基础上创新地探索MTP相对于NTP范式在知识抽取任务上的作用，取得了任务设置下的巨大提升。未来将补全为正式论文。

科创竞赛

AI Singapore Global Challenge for Safe and Secure LLMs | Track 1 | **团体第三名**

Zhexin Zhang, Junxiao Yang, Shiyao Cui, Renmiao Chen, **Leqi Lei,** Yida Lu | 大模型攻击赛道第三名

实习经历

聆心智能 | 算法实习生 2023.04 - 2023.09

算法实习，先后参与了预训练数据的清洗、模型微调数据的构造；清洗的预训练数据被采用至哈工深张民教授团队训练的立知大模型以及组内与企业合作训练的大模型

智谱华章 | 多模态算法实习生 2025.03 - 至今

算法实习，主要负责提升模型的多模态能力

研究兴趣

深入研究如何进一步提升AI的**通用智力**。具体来说，我对如何让AI完成**复杂系统**的构建（如代码仓库、研究流程、非常感兴趣，我认为这是制约现在大模型能力的**瓶颈**。具体来说，我可能会想要探索：**基础模型能力的提升、Age建**；研究的方法可能包括：强化学习、**life-long learning**、**life-long memory**；此外，我认为视觉是通往AGI必一项基础能力，所以如何进一步提升**VLM**的智能至人类水平乃至融合多模态能力而不损害彼此的性能，也是我感兴内容。**总而言之，我希望关注于AGI中重要且想象力巨大的领域，无论难易。**