♂ 男 · 出生年月:1997.12 · 生源地: 广东深圳

[redacted]

求职意愿

大模型应用：后训练、Agent（例如 DeepResearch）、AI for Health/Science 相关岗位

教育背景

清华大学 / 自动化系 / 博士 2021 – 2026

- **研究方向**：基础模型，人工智能，生物信息学
- **导师**：古槿　副教授

清华大学 / 自动化系 / 本科 2017 – 2021

- **GPA**: 3.7/4.0，排名：31/173（前 20%）
- **主修课程**：人工智能基础，概率论与数理统计，数据结构，数值分析，自动控制理论
- **荣誉奖项**：北京市优秀毕业生（市级，2021）清华大学综合优秀奖学金（校级，2019, 2020）

实习经历

智谱 AI / 基础模型算法研发 / 北京 2025.03 – 至今

基于多智能体的深度研究报告 (Deep Research) 项目

基于 Skywork 开源框架开发了 Multi-agent 深度研究报告生成项目，可自动化生成高质量深度研究报告

- **模型评测**：主导构建了一套完整全面的深度研究报告评测方法，包括文章质量、引用质量、主观一致性等维度，评测结果与人类专家相关性达到 73%
- **模型训练**：基于 ReAct 范式蒸馏高质量数据，使用 Qwen3-30B, GLM-Z1 模型进行监督微调 (SFT)，有效提升了报告质量。目前正进行强化学习（RL）训练
- **框架开发**：参与多智能体框架的开发与测试，确保系统稳定性与协同效率
- **项目成果**：生成的报告质量超越了先前公司的同类产品，模型经 SFT 后在文章质量上有所提升

多模态模型训练场

CogVLM 多模态基础模型的后训练（SFT、RL）操作流程复杂，且有较高代码技术门槛，不易于交付客户使用。为此提出一套标准、闭环的自动化微调训练方案

- **自动化数据预处理**：对给定图文数据集自动进行数据清洗与格式标准化
- **一键训练、推理、评测工具链**：仅通过一行命令就可以进行从训练、推理到评测的完整流程，也支持不同环节之间的解耦运行。用户仅通过配置参数即可快速上手运行
- **最佳实践案例**：通过该项目成功使用 CogVLM 88B 模型进行了三个典型场景（图像注释、几何推理、文本识别）的后训练实践，后模型的专项精度均有提升
- **项目成果**：经评估可节省原有 80% 的时间和人力成本

腾讯 IEG 天美工作室 / 游戏客户端开发 / 深圳 2020.06 – 2020.09

游戏开发中经常存在 Lua 语言调试困难、内存占用高以及代码规范性问题，为解决这些难点，开发了以下工具和优化方案

- **调试工具**：开发了 Visual Studio 插件，通过即时窗口执行 Lua 指令，实现 C++ 环境下的 Lua 调试功能，提升开发效率
- **内存优化**：设计了 lightDict 数据结构，优化内存对齐并结合 zlib 压缩算法降低 Lua Table 内存占用。优化后内存占用可最低降低至原 Lua Table 的 28%，显著减少内存消耗
- **代码规范检查**：将代码解析为结构化数据，检测循环关键字和全局变量使用情况，优化代

中国商飞民用飞机试飞中心 / 虚拟试飞研发 / 上海 2023.06 – 2023.08

基于知识图谱的发动机故障信息问答系统

针对虚拟试飞监控效率低、决策慢的问题，开发了自动化问答系统 [illegible] 拟试飞监控智能化水平

- **自动化数据预处理**：批量解析非结构化 PDF 文本数据为表格数据 [illegible] 工重复劳动
- **知识图谱构建**：自顶向下设计了一个简洁且可扩展的知识图谱，清晰关联不同实例与属性
- **问答系统开发**：开发问答系统实现故障信息快速查询，并引入大语言模型提升灵活性

研究经历

针对空间转录组的生成式预训练基座模型研究 2024.01 – 2025.05

- **背景**：空间转录组提供了带有空间位置的基因表达量，对于揭示细胞间的空间关系具有重要意义。目前公开数据集规模不断扩大，为构建预训练基座模型提供了基础。
- **方法**：提出一种针对空间转录组的基座模型（GeST），该模型通过创新设计的空间信息引导的生成式任务进行预训练，其核心思想是根据近邻细胞的相关信息，预测给定位置的基因表达量。具体实现了：1）用于高效训练的空间注意力机制；2）将空间转录组数据转换为序列的灵活有序化方法；3）降低数据噪声的细胞“分词”方法。
- **结果**：在大规模空间转录组数据集上进行预训练后，模型在空间细胞生成任务中超越所有现有方法，能够零样本提取空间细胞特征，并可针对空间注释等任务进行微调至 SOTA。

整合空间转录组与图像的生成式预训练基座模型研究 2025.06 – 至今

- **背景**：很多场景中，空间转录组数据还有配对位置的图像，这为表征细胞提供了更丰富的信息。然而目前还没有基座模型同时利用这两种数据进行整合训练。
- **方法**：在 GeST 的基础上，提出了 3 个改进设计：1）加入图像信息作为条件生成，模型预训练任务为：根据近邻细胞的信息预测给定位置以及图像对应的基因表达量；2）针对转录组数据特性设计了一个零膨胀的 VQ-VAE 对细胞进行更好的“分词”表征；3）将因果自回归方式换为更适用于空间场景的双向掩码自回归方式。
- **结果**：目前已训练零膨胀的 VQ-VAE 模型，细胞表征性能超越 GeST 的“分词”方法。

交叉学科大数据分析：垂体瘤单细胞图谱构建与研究 2022.10 – 2024.12

- **背景**：垂体瘤是人类最常见的颅内肿瘤类型之一，目前单细胞层级的垂体瘤分子特征仍然没有得到完全刻画与分析。
- **方法**：与北京天坛医院合作，对多个垂体瘤病人进行单细胞测序数据分析，构建了一个完整全面的人类垂体细胞图谱，并对垂体瘤及其微环境进行分型与分析。
- **结果**：通过生物信息学分析发现了一个新的上皮细胞亚群，两个肿瘤相关巨噬细胞亚群，和一个高表达恶性特征基因的侵袭性肿瘤细胞亚群。这些结果为垂体瘤的分型、治疗提供了新的线索。

代表论文

- Minsheng Hao#, **Nan Yan#**, Haiyang Bian#, Yixin Chen, Jin Gu, Lei Wei*, Xuegong Zhang*. GeST: Towards Building A Generative Pretrained Transformer for Learning Cellular Spatial Context. Machine Learning in Computational Biology, 2025. (Spotlight oral, top 25%)
- **Nan Yan#**, Weiyan Xie#, Dongfang Wang#, Qiuyue Fang, Jing Guo, Yiyuan Chen, Xinqi Li, Lei Gong, Jialin Wang, Wenbo Guo, Xuegong Zhang, Yazhuo Zhang*, Jin Gu*, Chuzhong Li*. Single cell transcriptomic analysis reveals tumor cell heterogeneity and immune microenvironment features of pituitary neuroendocrine tumors. Genome Medicine, 2024. (IF=11.2, 中科院 1 区 top 期刊)

专业技能

掌握 Python/C++ 语言，熟悉 Pytorch 等深度学习框架
英语 TOEFL 103，具备良好的英文文献阅读与写作能力

校园经历

担任本科生与研究生课程的助教共计 6 次，并且全部获得优秀评级
担任清华自动化系男足队长，获得清华马杯足球赛季军