bb322d0830a15b871XJy29i_EFFVw466U_6XWO2qmPPVNRdi

陈浩

个人信息

陈浩
13381833071
3305766680@qq.com
南京

工作经历

奥看科技　2025.05-至今

AI效能提升总监 / 大模型应用研发部部长

- 行业智能体开发团队：22人
- 效能提升部：4人
- 宠物大模型推广团队：10人

上海优谦智能　2021.07-2023.05

NLP高级工程师

南京中科相生　2023.05-2025.05

AI架构师

这是同一个投资人的两家公司

教育经历

硕士	学校	复旦大学
	学院	工程与应用技术研究院
	专业	电子信息-人工智能
	时间	2020.09-2023-8
学士	学校	上海电机学院
	学院	电子信息学院
	专业	计算机-物联网工程
	时间	2016.09-2020.07

- **本科主修课程**

面向对象程序设计；　操作系统；

电路分析基础；

物联网控制技术；

计算机组成原理；

数据库原理；

数据结构；

计算机网络；

嵌入式开发；

数字逻辑电路；

线性代数；

复变函数与积分变换；

- **硕士主修课程**

神经网络与人工智能 ；　时间序列模型及应用 ；　机器学习；

深度学习；

计算机视觉；

强化学习；

大语言模型；

机电一体化系统设计；　现代信号分析与处理；　智能机器人前沿 ；

现代光学设计；

AI Leader-架构设计能力

1.负责AI Agent团队的技术规划与整体架构设计，搭建可扩展的智能体系统框架:

2.深入理解 大模型原理(LLM/多模态模型)

推动其在 智能导演、剧本生成、分镜解析、影像控制 等场景中的应用:

3.主导Agent的研发与落地，包括 多Agent协作框架、长时记忆机制、任务分解与执行、工具调用与工作流编排

4.把控工程质量，建立高标准的研发流程与工程规范;

5.跨团队协作，与产品、算法、前后端团队紧密配合，推动AI产品快速迭代上线

6.带领并培养工程师团队，推动技术创新与知识沉淀。

精通 大规模系统架构设计，有高并发、高可用动久

深入理解 大模型工作原理，熟悉 Transformer,RLHF、微调、RAG 等相关技术:

丰富的 Agent 开发与落地经验(Dify、MaxKB、RAGFlow、LangChain、NLP2SQL框架自研等)

熟悉 Python/GoNava 等至少一种主流后端语言，具备工程落地能力:

具备较强的团队领导力和跨团队沟通能力。

智能体平台架构设计

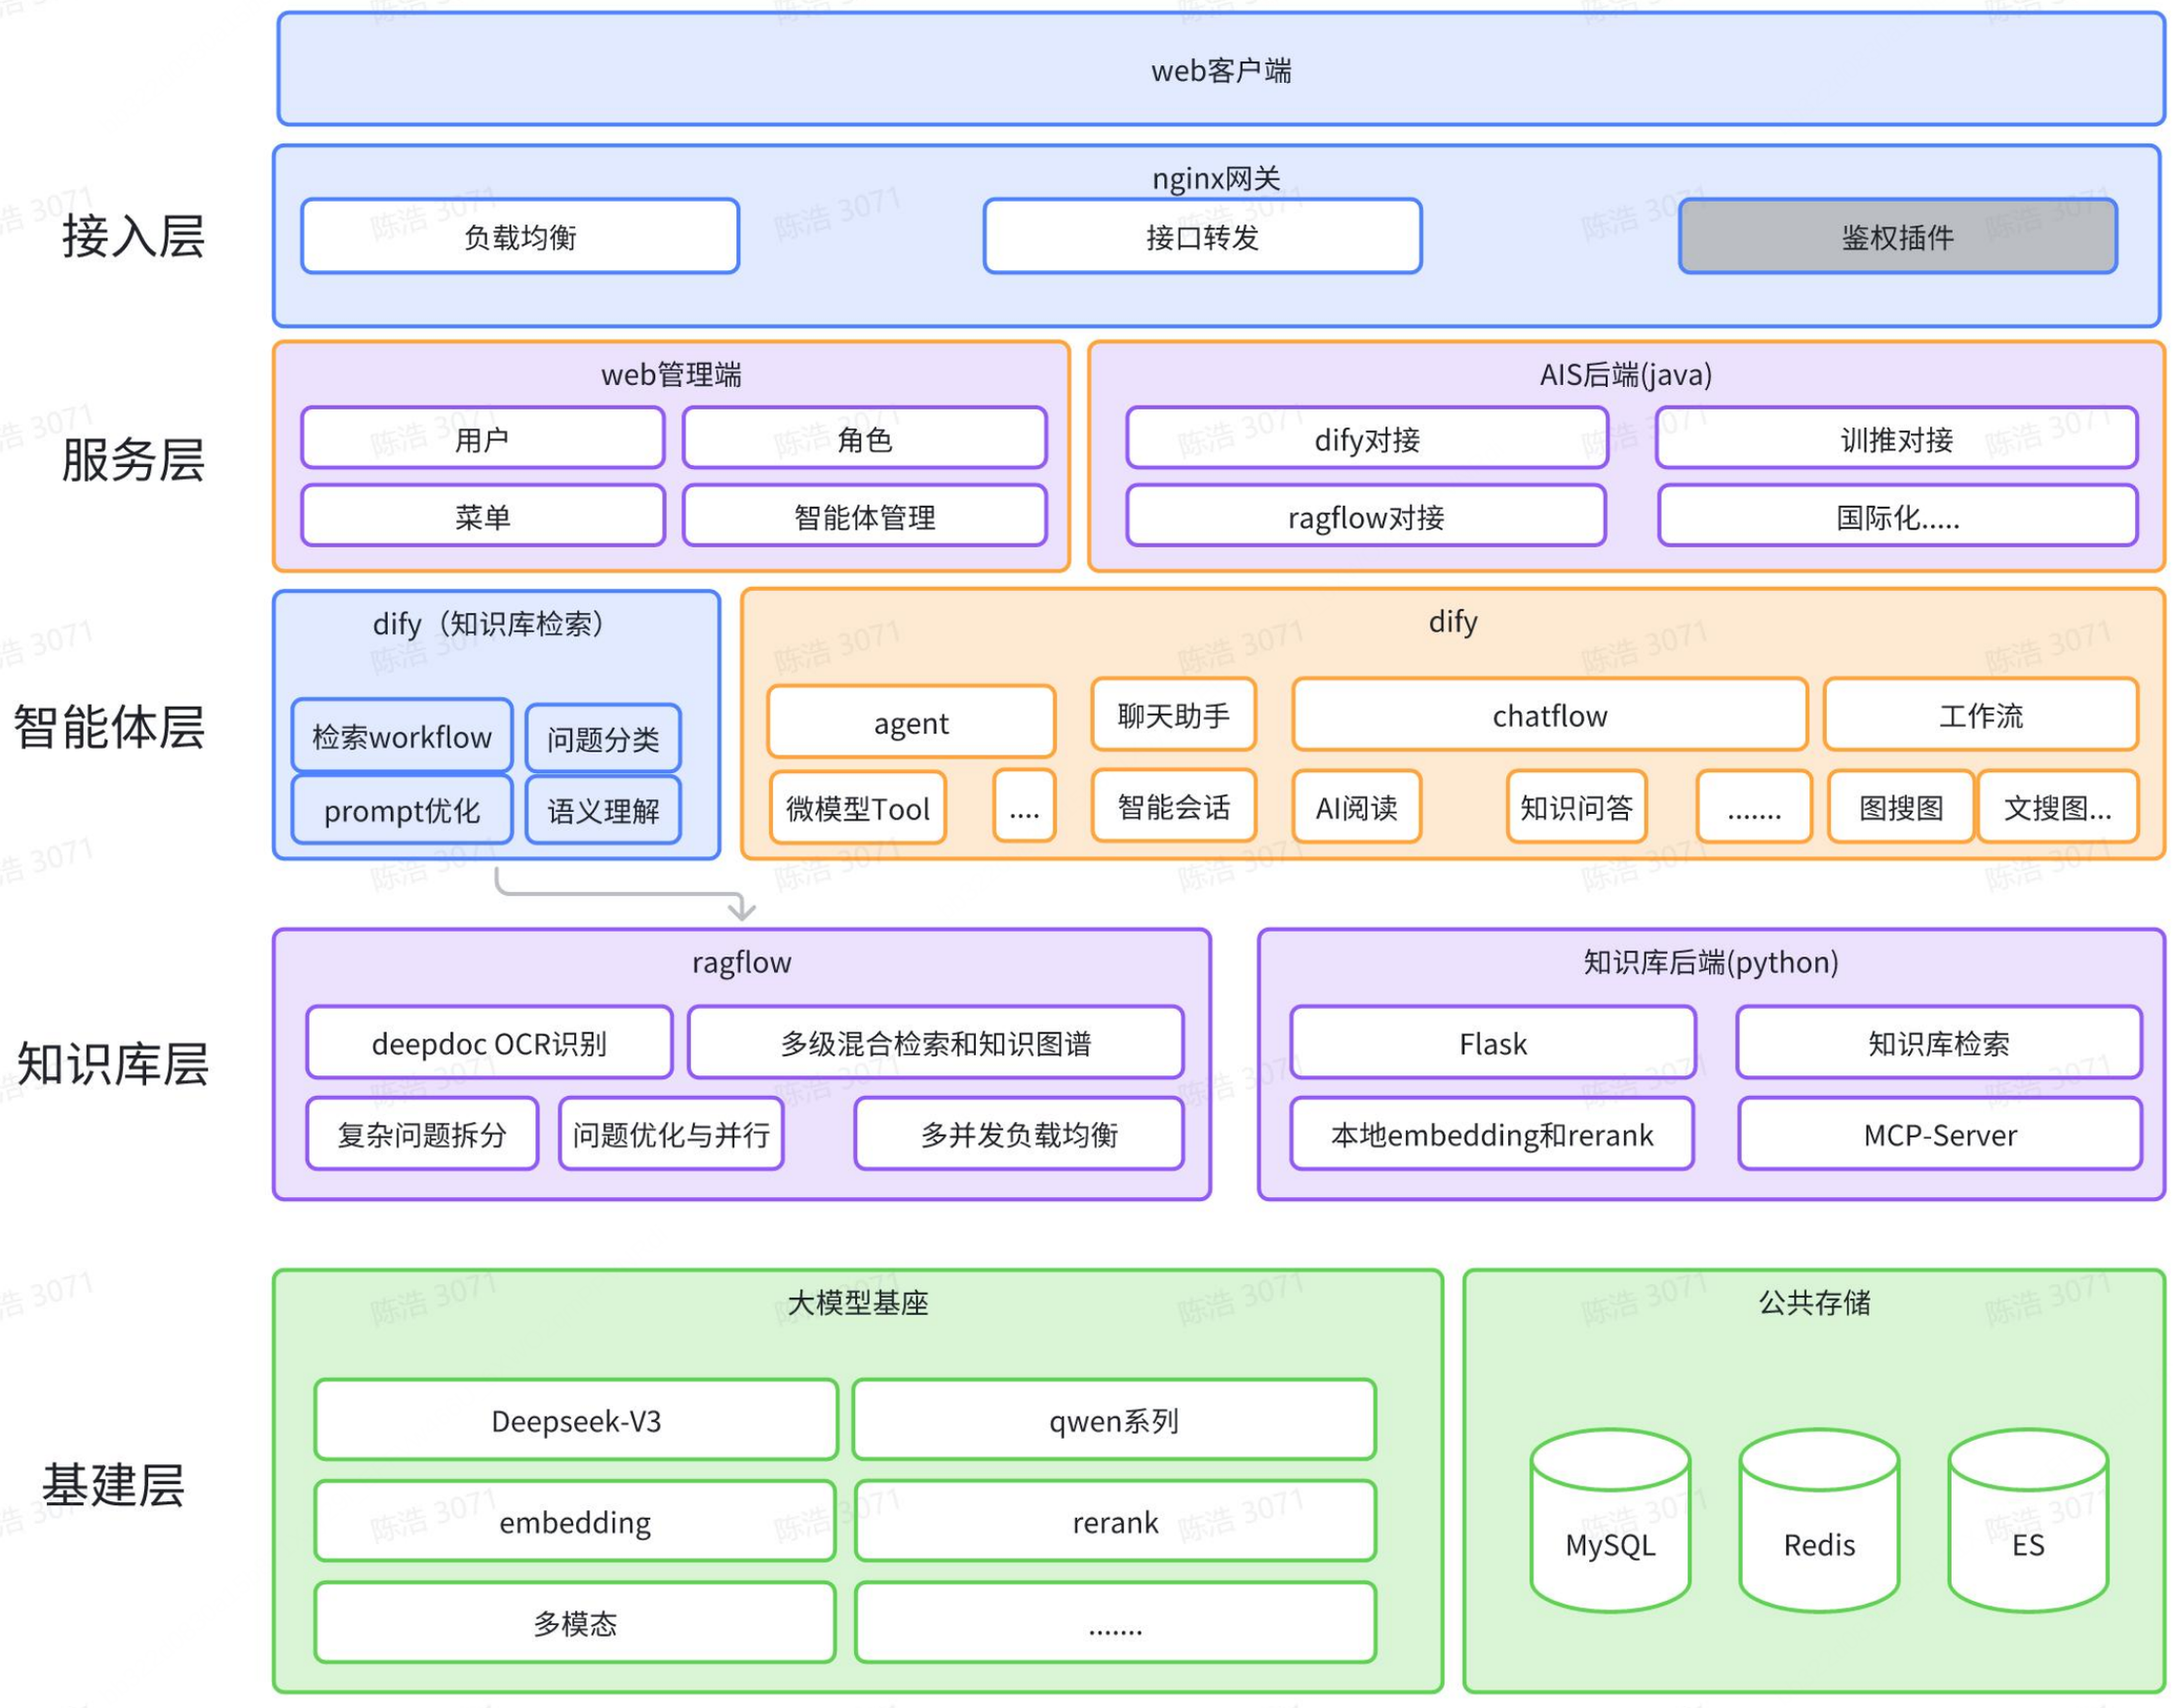

奥看信息科技有限公司

智能体平台-数据流向图

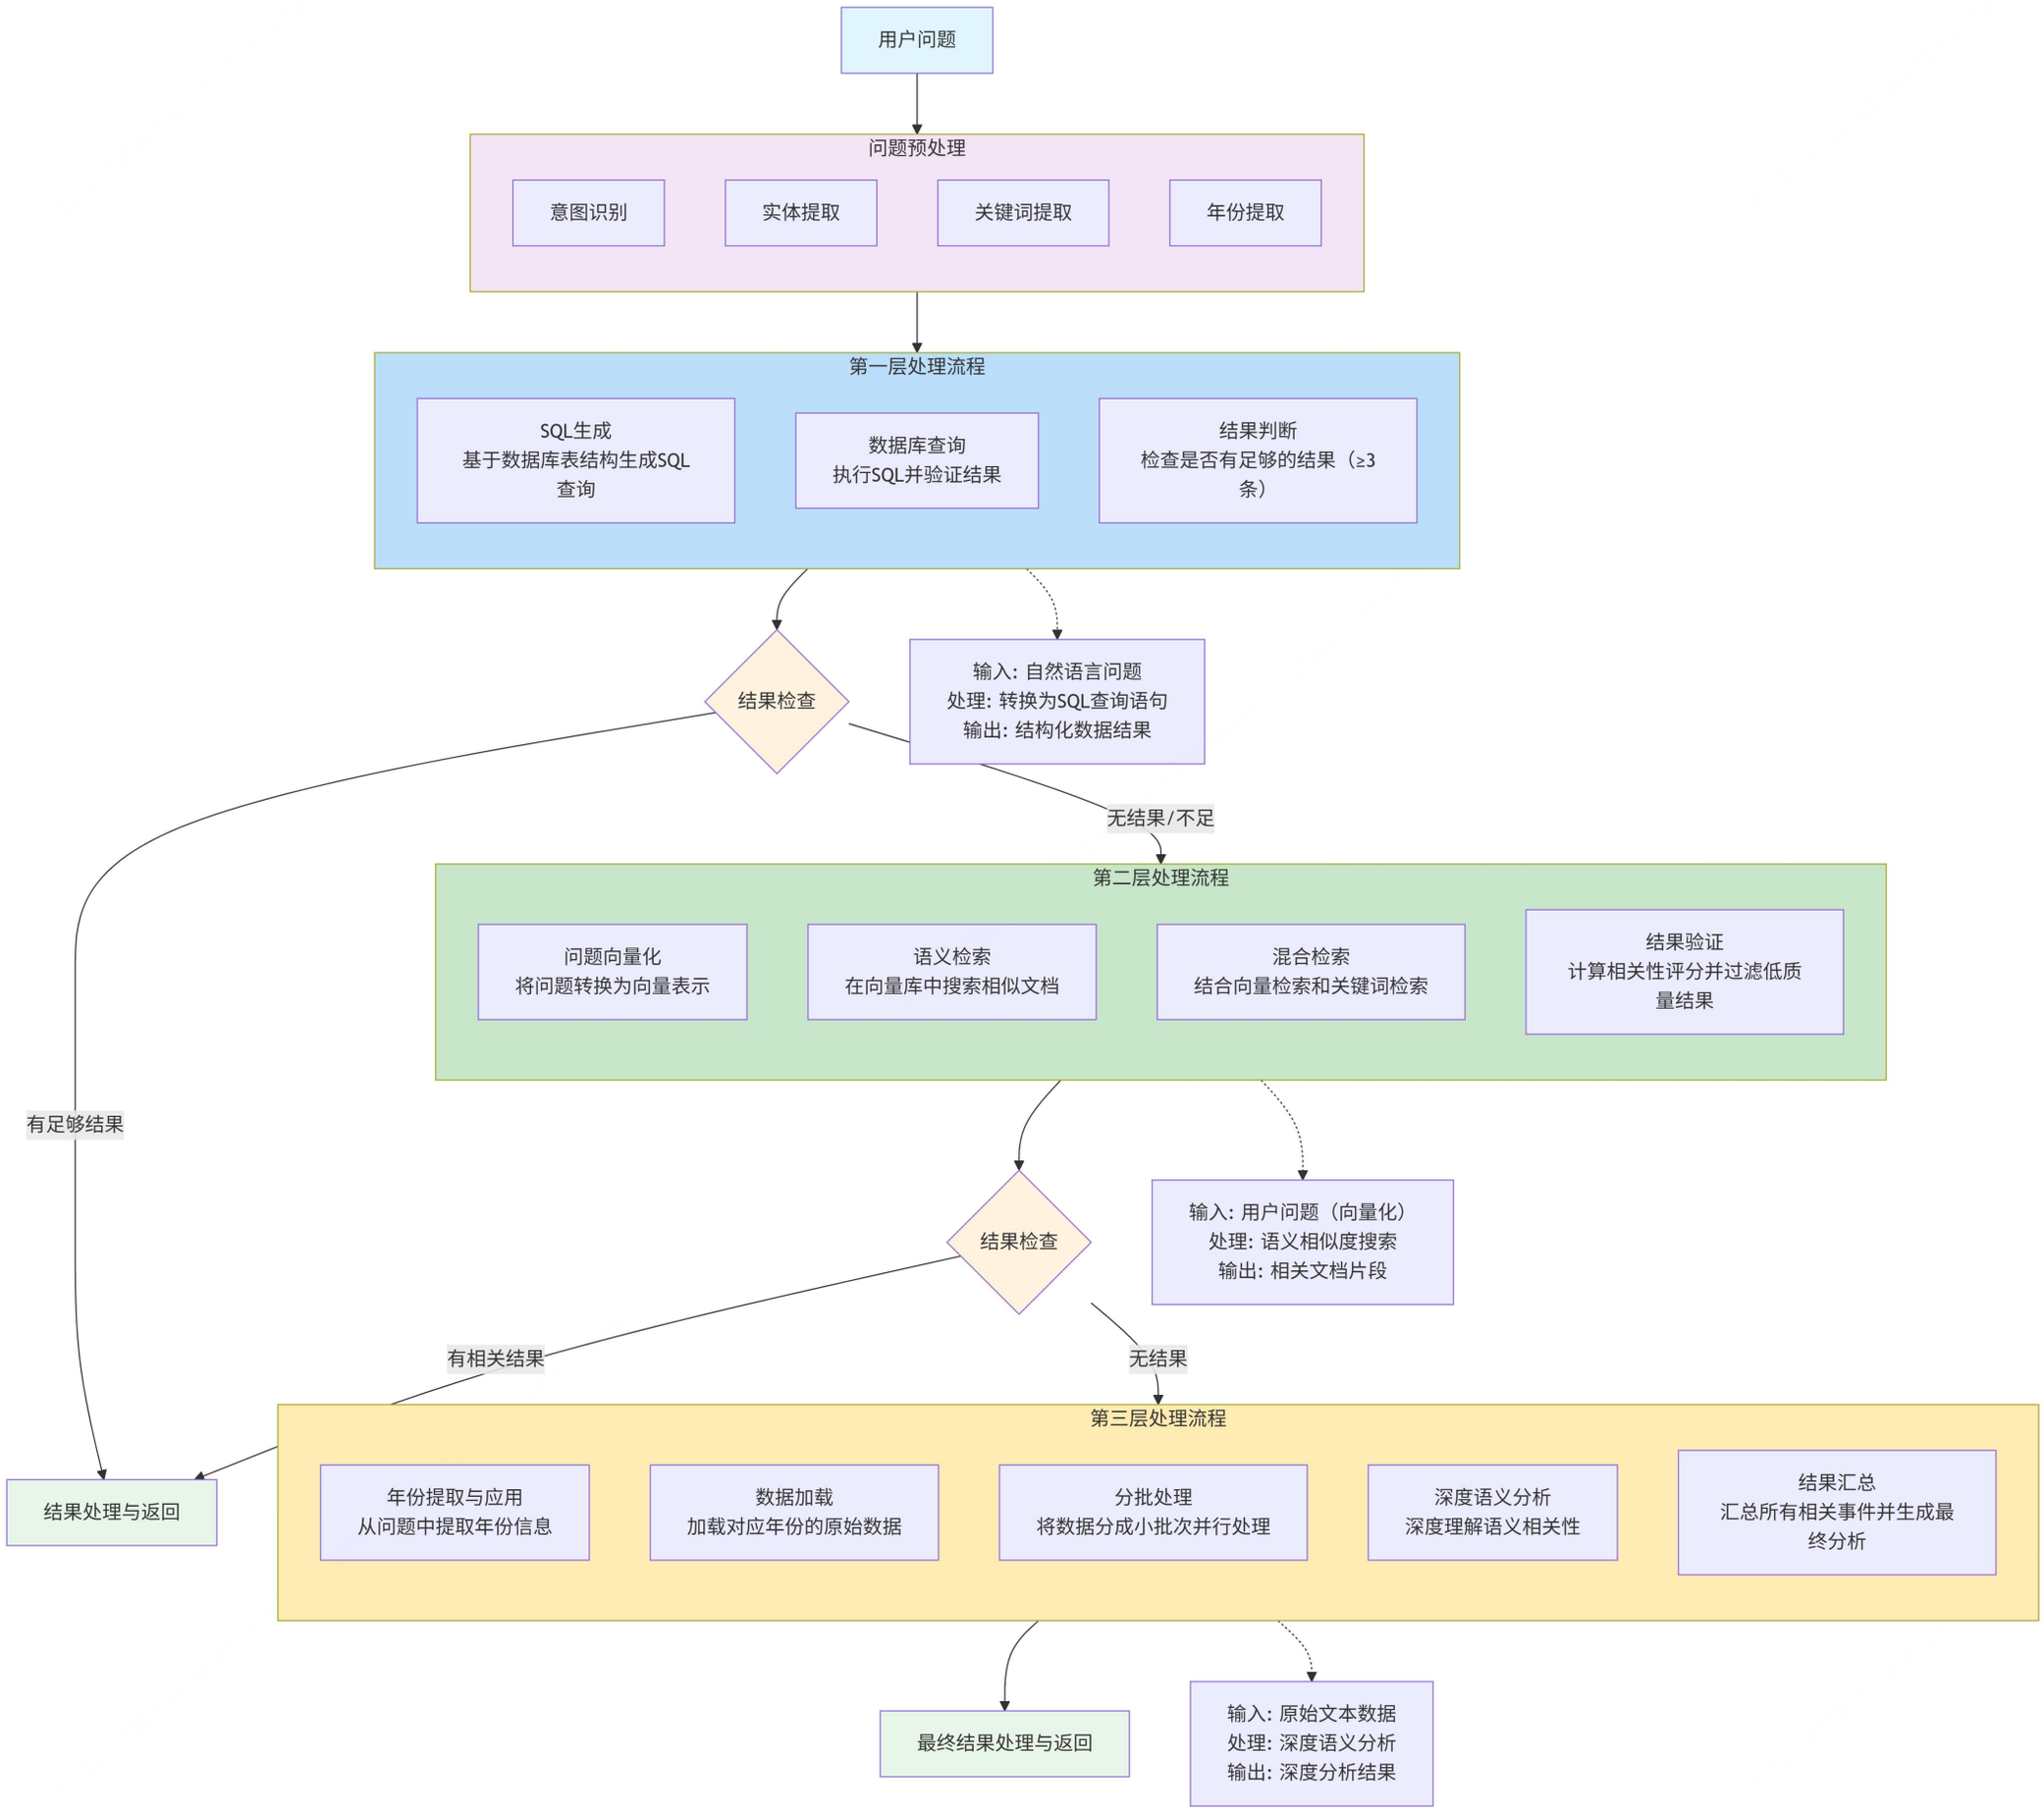

奥看信息科技有限公司

智能体平台

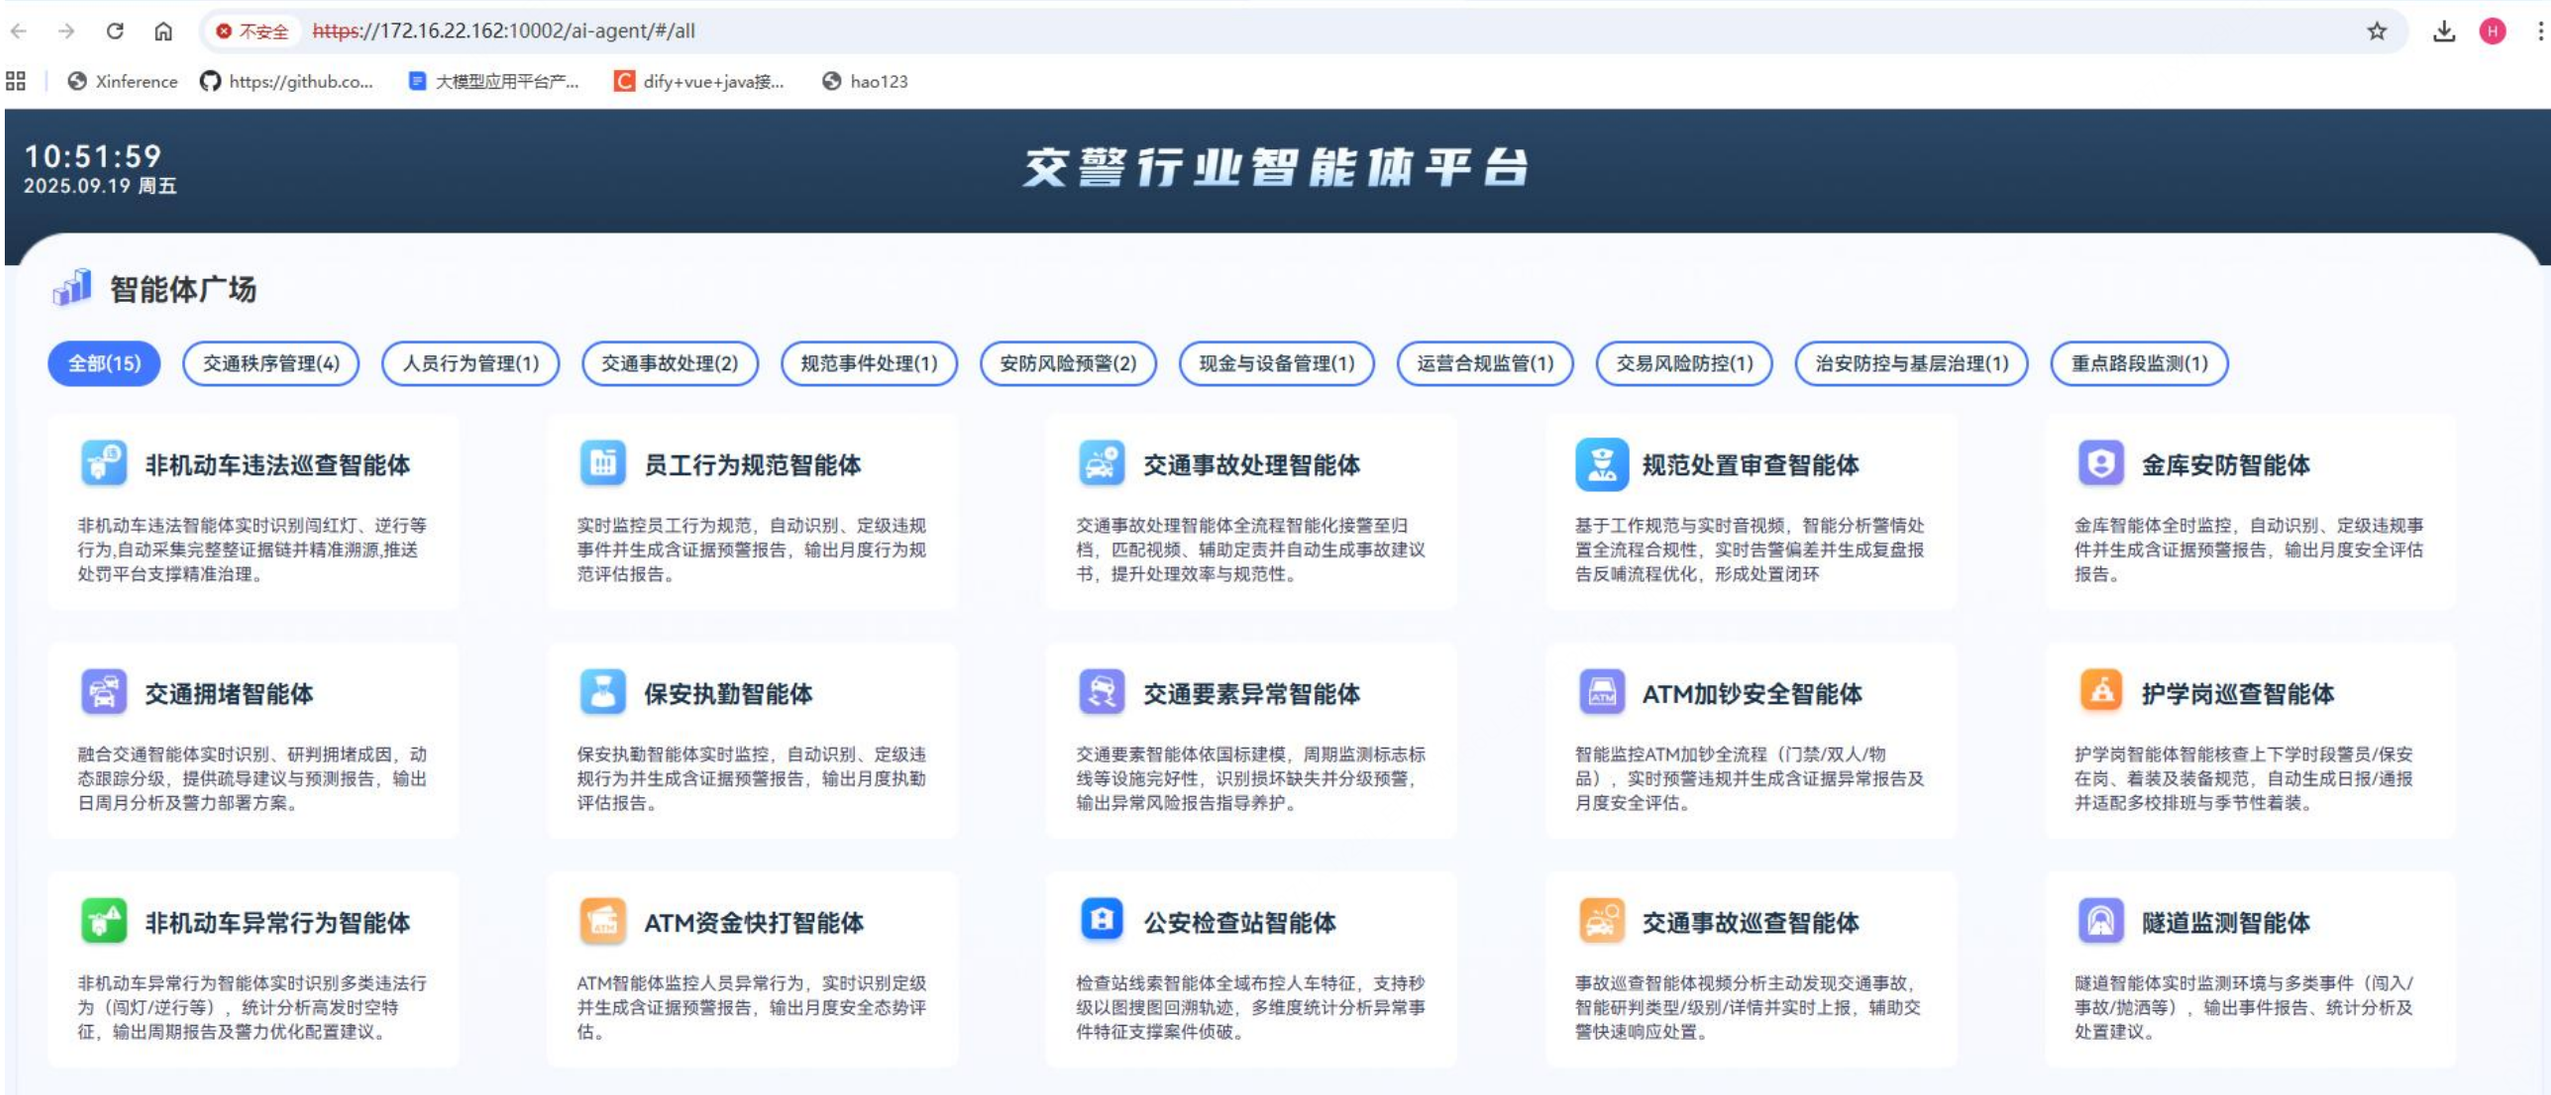

涵盖公安交警告诉金融四大领域，知识检索分层检索策略：

- 第一层：NLP2SQL结构化查询（精确、快速、资源消耗低）
- 第二层：RAGFlow文档检索（语义理解、文档内容查询）
- 第三层：深度语义检索（深度理解、全面覆盖）

渐进式处理：系统从最精确的查询方式开始，逐步转向更广泛但资源消耗更大的检索方法

智能路由：每层都有结果检查机制，确保只有在前一层无法提供满意结果时才进入下一层

资源优化：避免了不必要的深度处理，提高了系统整体效率和响应速度

智能体平台-规范处置智能体

奥看信息科技有限公司

智能体平台-非机动车异常行为智能体

奥看信息科技有限公司

智能体平台-非机动车违法巡查智能体

奥看信息科技有限公司

智能体平台-知识库-江宁公安局案例

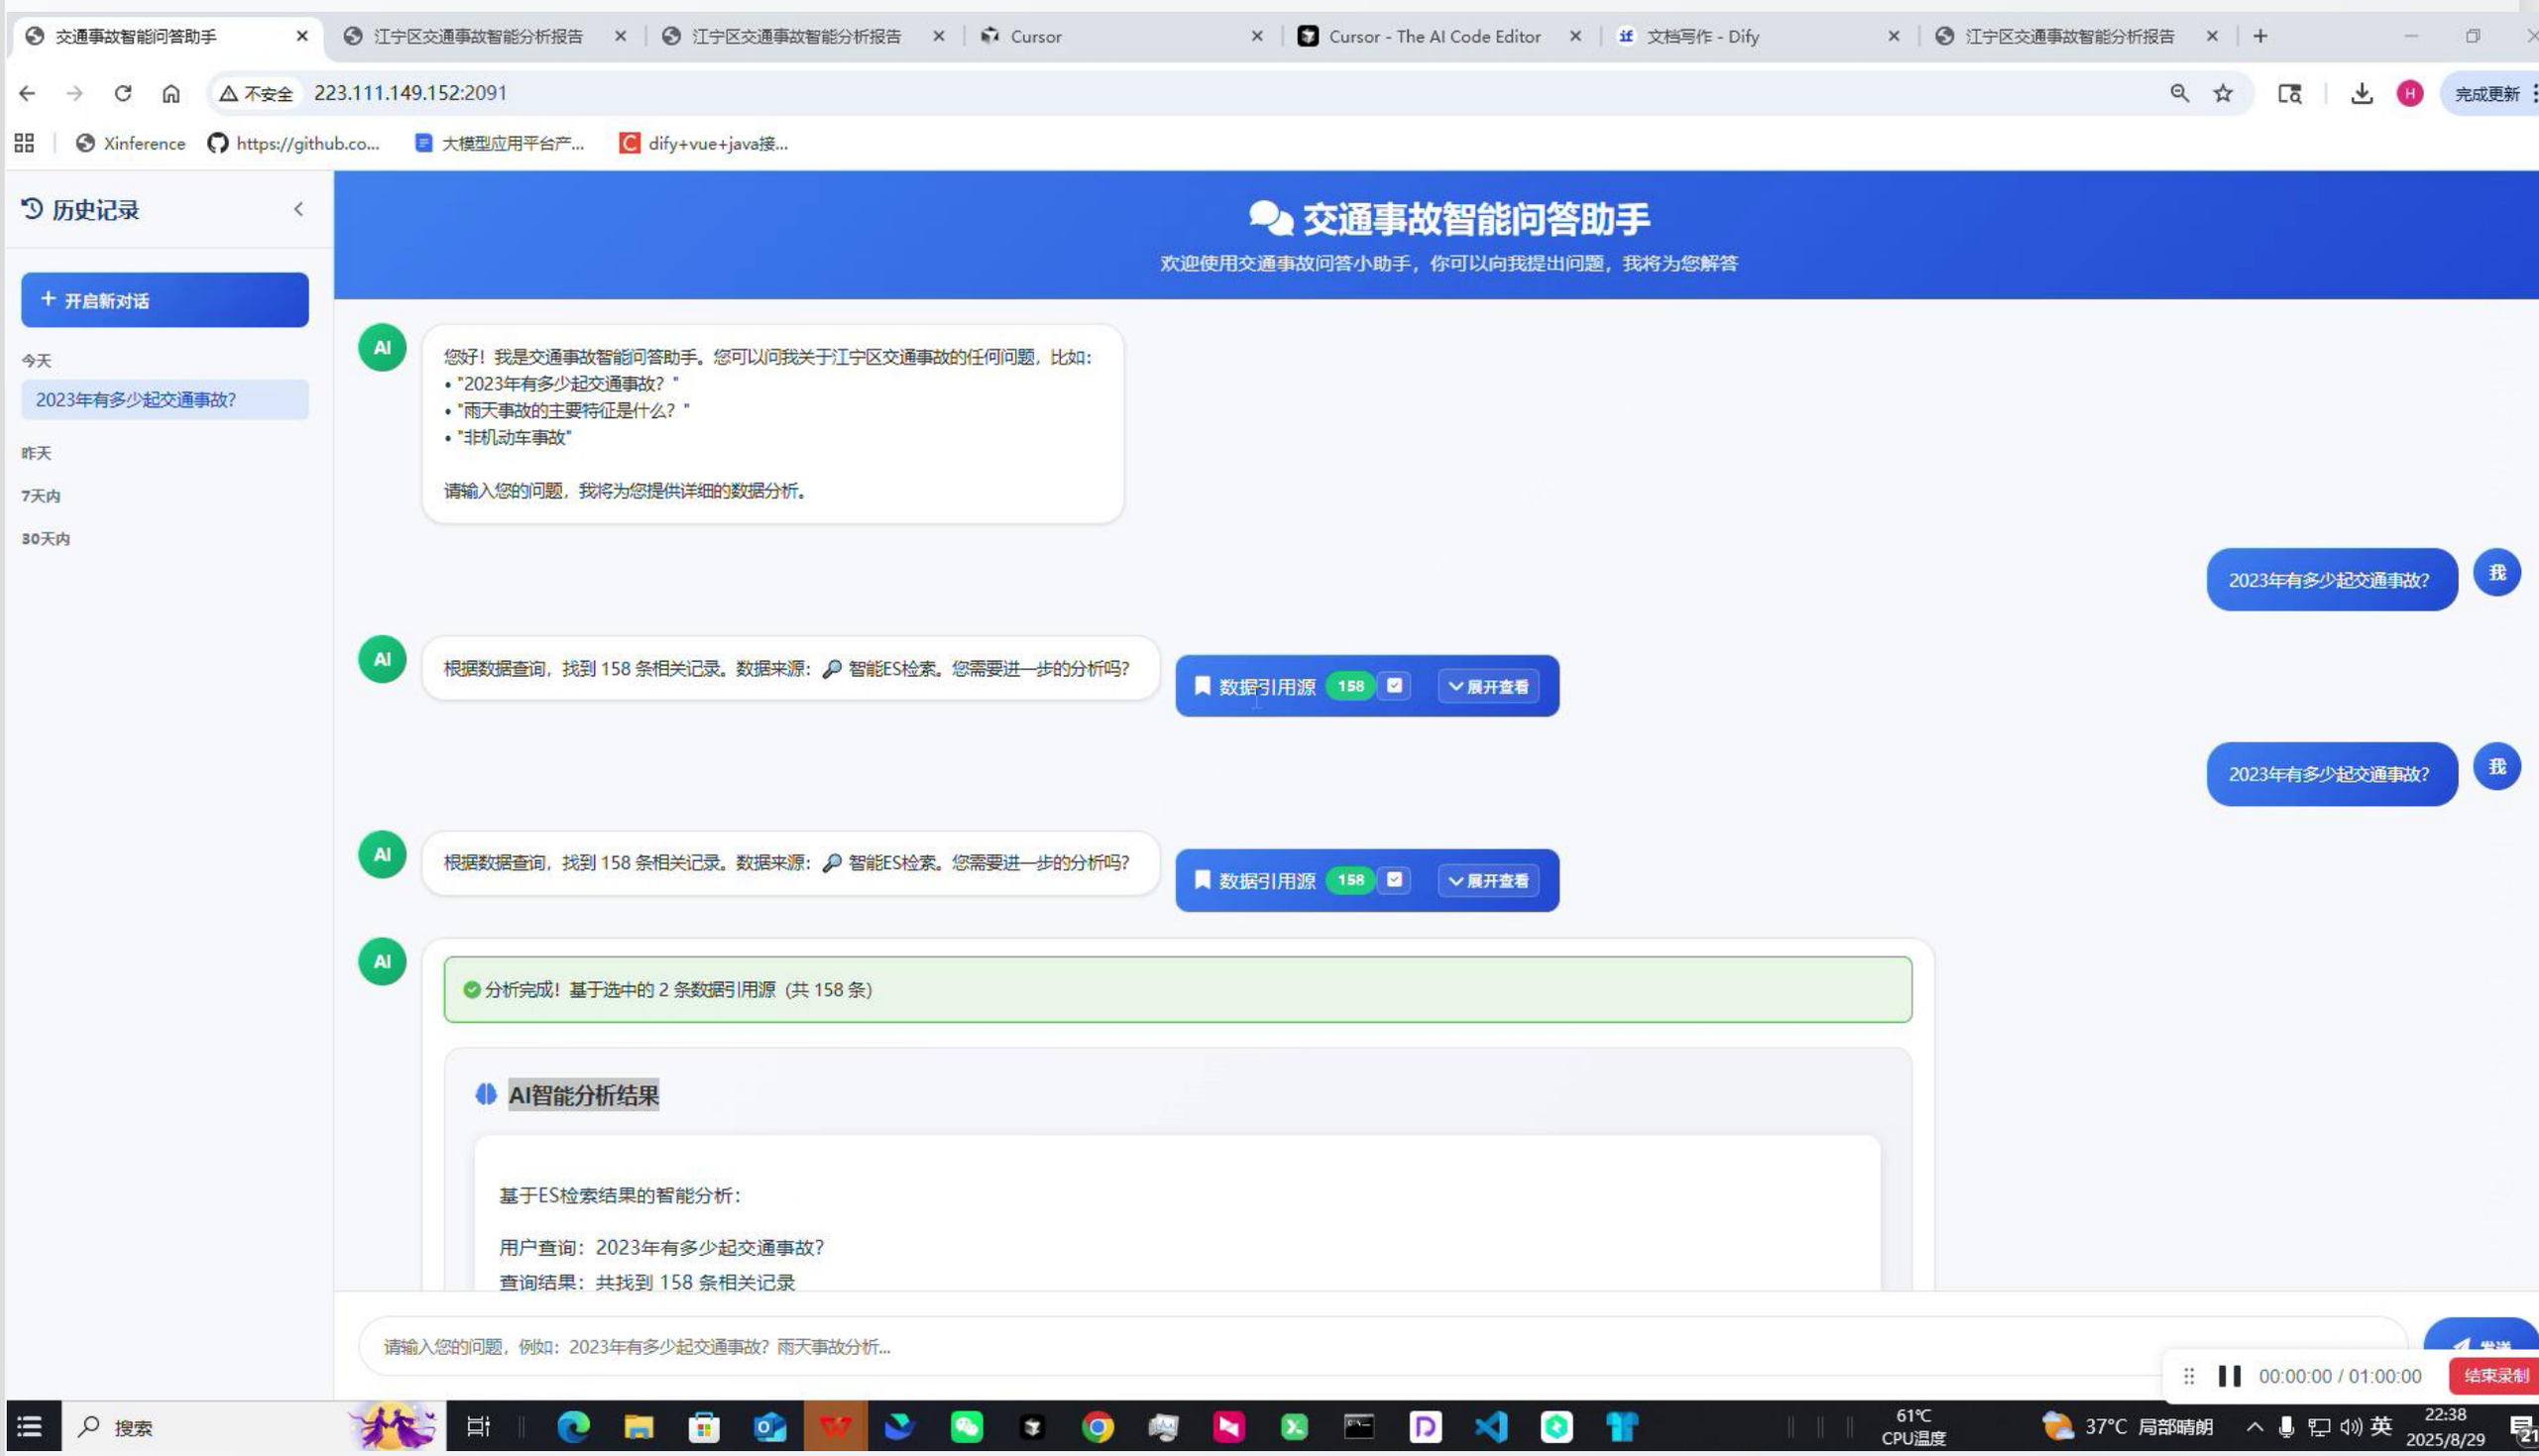

奥看信息科技有限公司

智能体平台-知识库-江宁公安局案例

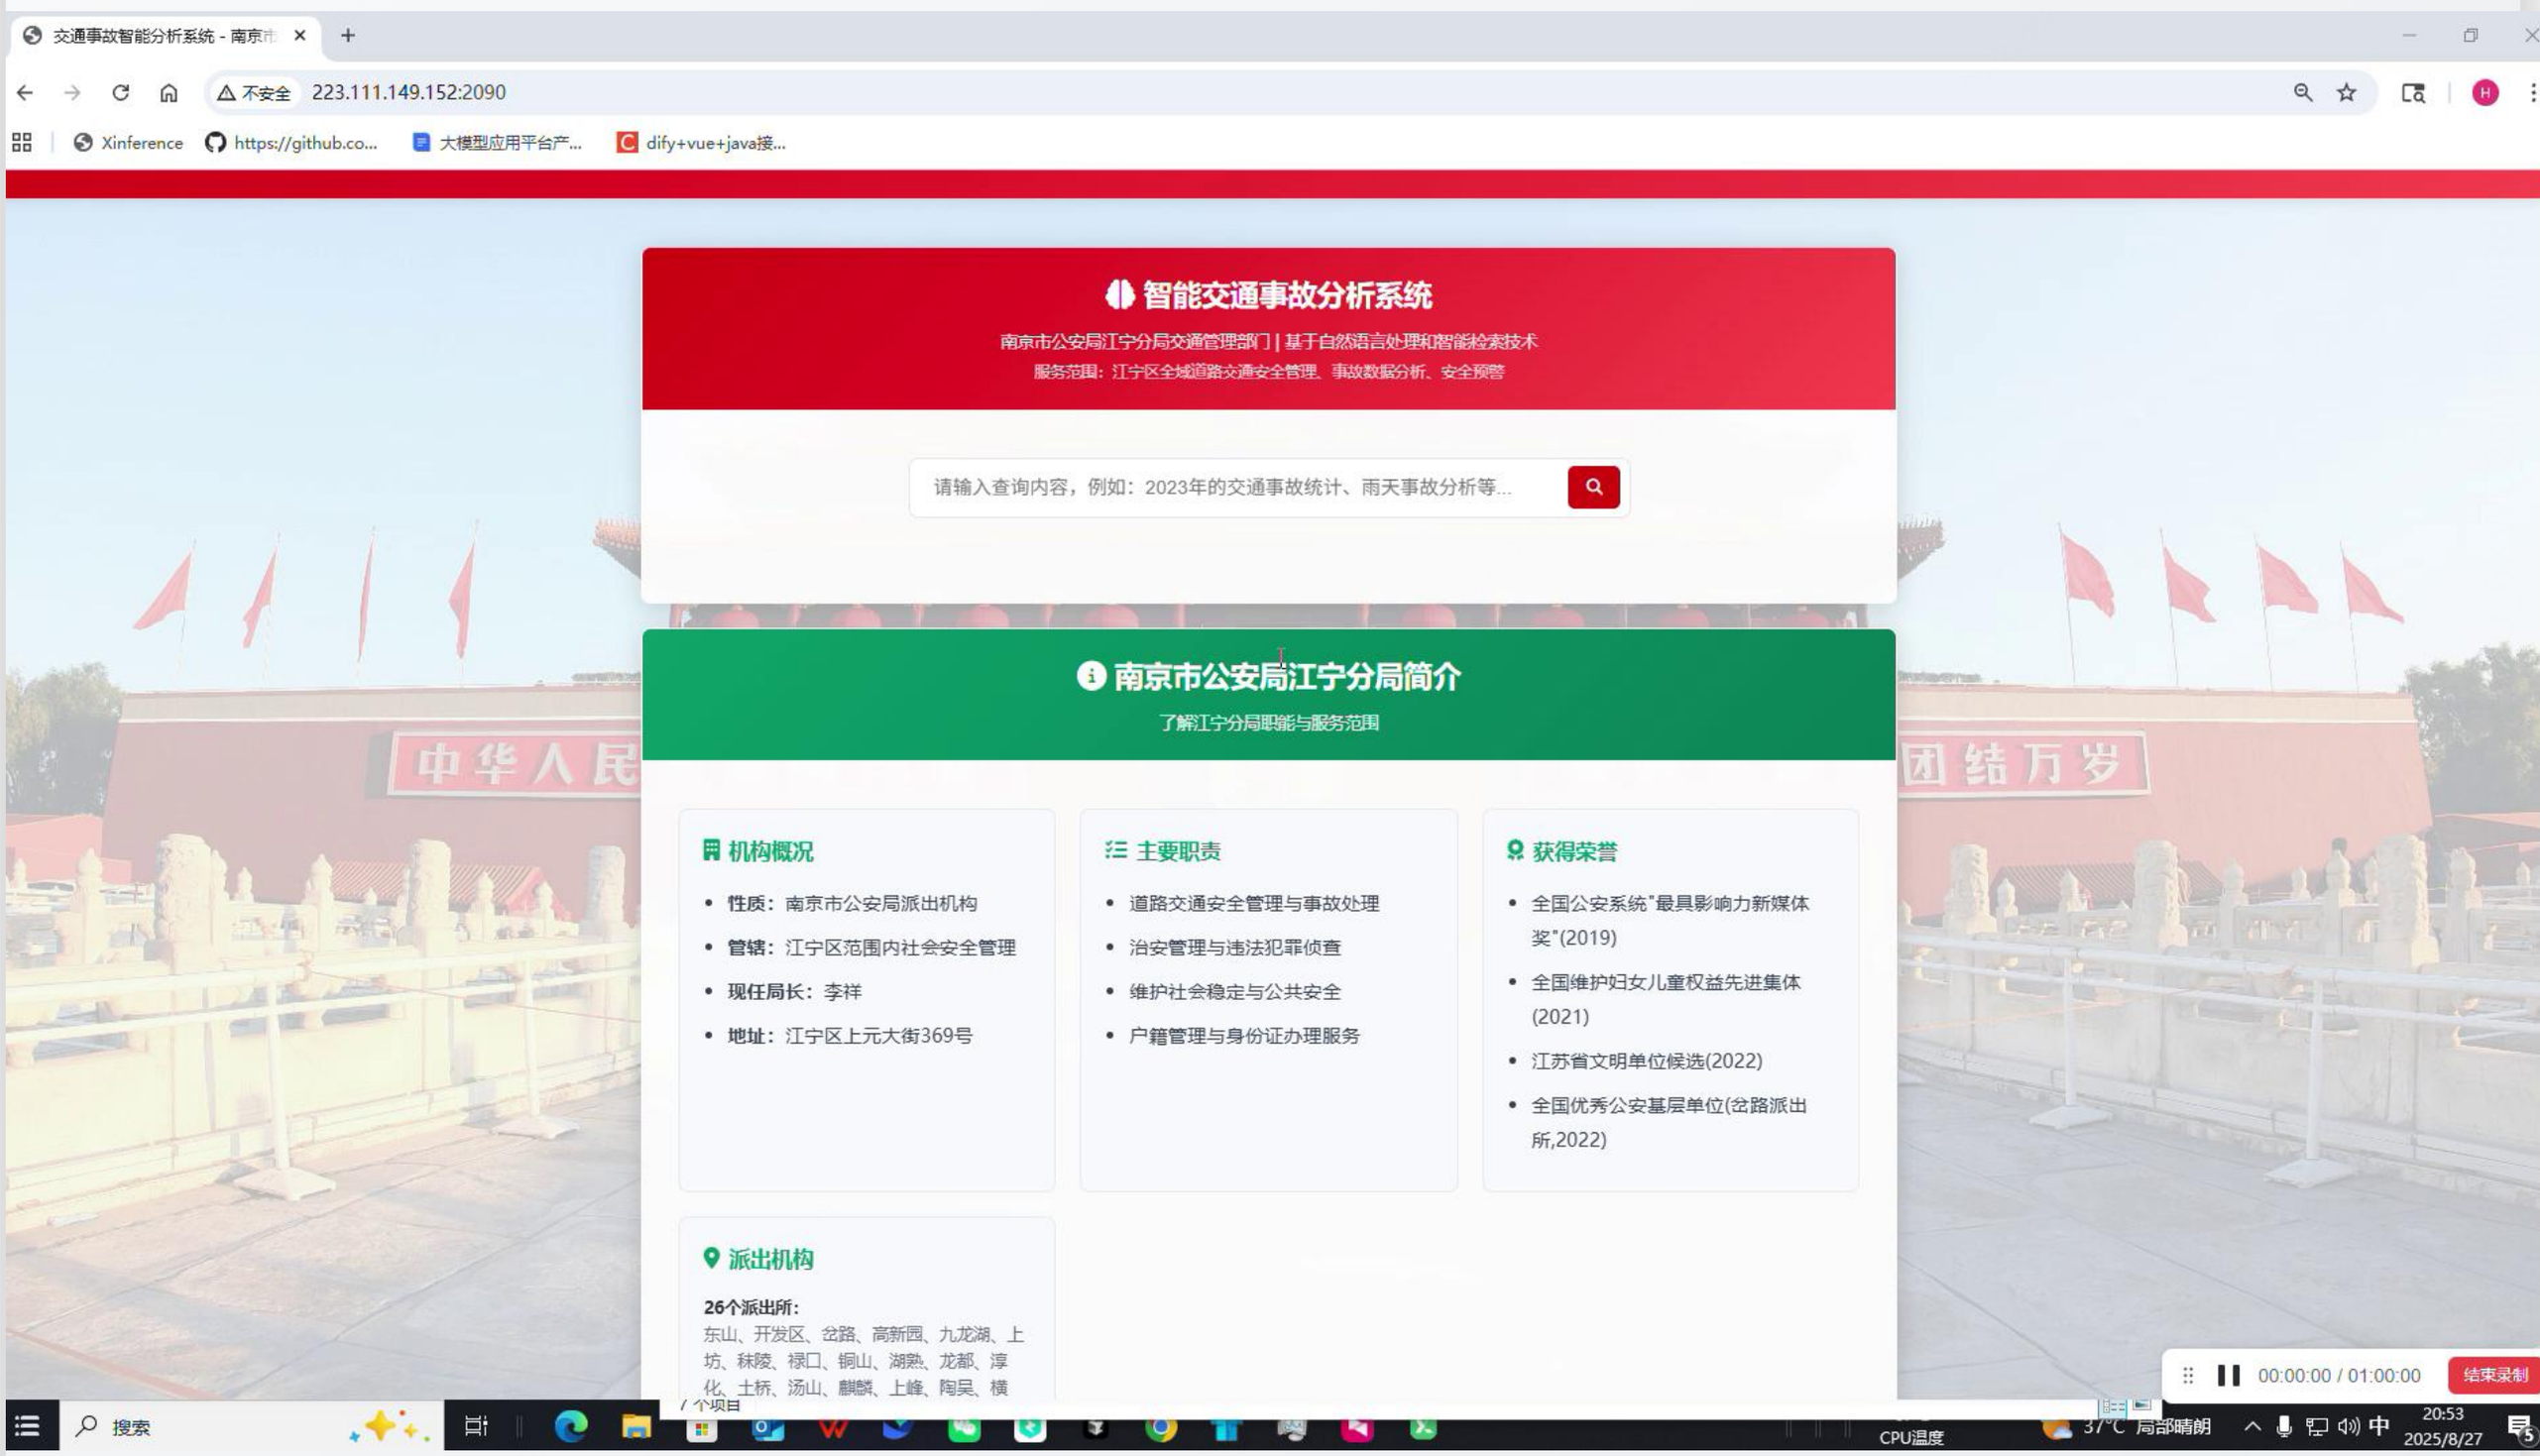

奥看信息科技有限公司

公安领域智能体开发

护学岗智能体

- 自动巡查上下学期间护学力量行为
- 检查在离岗/着装规范/装备器械佩戴情况
- 参照GBT 29315-2022安全防范要求
- 自动生成巡查报告并上报公安教育部门

核心部门

- 交警护学岗专班
- 治安管理大队
- 社区警务室

公安检查站线索研判智能体

- 全特征布控，记录经过检查站的人车信息
- 支持以图搜图，挖掘案件线索
- 人车特征及行为布控预警
- 按周期输出特征统计报告供分析

核心部门

- 治安管理支队
- 交警执法大队
- 特警安检专班

持刀持械巡查智能体

- 多模态监测：视频识别刀具特征
- 实时研判：计算暴力风险指数
- 分级响应：一级预警调度特警，二级预警推送巡逻民警
- 生成涉械案件数字档案，闭环管理

核心部门

- 治安管理支队
- 特警快速反应队
- 基层派出所巡逻队

人员上访智能体

- 多模态监测：识别聚集行为与异常情况
- 智能研判：评估事件风险等级
- 分级处置：根据风险等级调度相应警力
- 预警时间从事发后22分钟提前至事发前45分钟

核心部门

- 治安管理支队
- 信访维稳专班
- 基层派出所

公安领域智能体应用成效

45分钟	97%	73%	93分
群体性事件预警提前时间	涉访警情处置规范率	重大聚集事件下降率	少数民族信访满意度

交警领域智能体开发

交通拥堵智能体

- 融合视频资源识别交通拥堵
- 分析拥堵原因（事故/违停/施工）
- 实时跟踪拥堵变化情况
- 提供处置建议与警力配置

核心部门

- 交管指挥中心
- 交警大队

交通事故巡查智能体

- 主动发现事故并上报警情
- 事故智能分析与分级分类
- 识别事故特征（追尾/侧翻/起火）
- 警情发现时间分钟级变秒级

核心部门

- 交通指挥中心
- 事故预防科

交通事故处置智能体

- 报警匹配与录像回放
- 接入执法记录仪视频
- 提供执法辅助与归档
- 轻微事故处理时间1小时→10分钟

核心部门

- 交管指挥中心
- 事故处理中队

交通违法二次预审智能体

- 对违法图片进行二次识别
- 审核图片齐全性与有效性
- 提升违法处罚覆盖率
- 减轻人工预审警务压力

核心部门

- 法制科
- 案件审核中心

非机动车违法智能体

- 非机动车违法证据采集
- 人员车辆信息确认
- 自动截取违法前中后视频
- 涉非机动车亡人事故同比下降

核心部门

- 重点路口执勤岗
- 交警服务站

执法记录仪智能体

- 实时和离线音视频分析
- 识别执法不合规行为
- 事件分级分类与上报
- 投诉核查时效5天→2小时

核心部门

- 警务督察支队
- 法制科

交警领域智能体应用成效

40%	55%	50%	96%
重点路段通行效率提升	平均延误降低	警力资源节省	群众满意率

奥看信息科技有限公司

金融领域智能体开发

ATM资金快打智能体

核心功能

- 夜间监测ATM机异常行为
- 识别人员异常行为特征
- 自动预警并生成评估报告
- 7×24小时全天候监控

识别算法

- 深灰取款行为检测
- 遮挡面部特征识别
- 人员滞留异常检测
- 多人聚集风险预警

核心部门

- 自助银行管理中心
- 风险合规部
- 安保部

ATM防盗刷预警智能体

核心功能

- 实时监测盗刷设备安装
- 识别异常操作行为模式
- 自动生成预警报告
- 全天候智能监控防护

识别算法

- 盗刷设备动作检测
- 异常打砸行为识别
- 多人协作风险预警
- 长时间滞留异常监测

核心部门

- 自助银行管理中心
- 风险合规部
- 安保部

金融领域智能体应用成效

24/7	95%	60%	80%
全天候监控能力	异常行为识别准确率	风险事件提前预警率	安保人力成本降低

奥看信息科技有限公司

高速领域智能体开发

消防监测智能体

- 烟雾检测与明火识别
- 灭火器缺失与设施损坏检测
- 自动生成预警报告
- 7×24小时全天候监控

核心部门

- 总行安保部
- 网点安全员

环境监测智能体

- 门口积水与物品遗留检测
- 地面垃圾与车辆乱停识别
- 自动生成环境评估报告
- 实时预警环境异常事件

核心部门

- 后勤保障部
- 网点负责人

电力安全智能体

- 异常亮灯与屏幕未关闭检测
- 电力设备运行状态监测
- 自动生成安全评估报告
- 全天候电力安全监控

核心部门

- 科技部
- 设备管理科

应急车道监测智能体

- 占用应急车道行为识别
- 车辆逆行异常检测
- 输出事件报告与处置建议
- 结合视觉大模型智能分析

核心部门

- 交通运输管理部门
- 高速公路运营公司

车流监测智能体

- 车辆拥堵实时监测
- 车流量统计分析
- 生成交通状况报告
- 提供疏导建议与决策支持

核心部门

- 公安交管部门
- 高速公路运营公司

危化品车停放监测智能体

- 危化品车辆识别与跟踪
- 禁停区停放异常检测
- 超时停放自动预警
- 生成企业合规排名报告

核心部门

- 交通运输管理部门
- 危化品运输企业

高速领域智能体应用成效

94%	78%	65%	82%
敏感事件主动发现率	跨部门联动响应时间缩短	群体性事件下降率	公共空间秩序投诉减少

AI客服智能体、数字人、在线课程生成ppt智能体

2024.05-2025.05

使用开源大模型预训练、微调、提示词、RAG知识库等技术创建多模态AI聊天机器人，将其接入Messenger、Whatsapp、Instegram、X、LinkedIn、微信登社交媒体平台回复咨询我们广告上项目的客户。我们的项目是在线教育，目前上线了MBA、DBA、MCS等课程。我们的课程视频使用自己开发的数字人平台进行生成，我们的课程的文案和作图使用我开发的在线课程生成平台进行生成。接下来我逐一介绍：

（1）利用GoogleGenerativeAI模型生成图文并茂或者视频课程

https://course.x-me.ai/home

这是一个基于Node.js和Express的后端应用，支持用户认证、邮件通知、AI聊天、支付等功能，包含错误处理和服务器状态日志。技术栈包括：mongoose（MongoDB管理）、nodemailer（邮件）、GoogleGenerativeAI（AI文本生成）、Unsplash和YouTube API（图片和视频搜索）、stripe（支付）。通过Express和MongoDB集成，实现用户注册、登录、密码重置、AI聊天等接口。

（2） 生成数字人课程

https://app.x-me.ai/main

将（1）生成的图文课程文案发送至我搭建的数字人平台。首先，通过声音克隆技术（TTS）生成语音，然后将该语音传递给数字人模型，以生成口播课程。

（3）自动化注册和发证书

https://aclas.college/online-master-of-business-administration

通过设置注册表单，用户在咨询后将收到注册表单链接。完成注册后，系统会自动跳转至相应项目的支付页面，集成了支付网关（PayMyTution或PayPal）以处理付款。支付完成后，系统将自动开通课程，使用后端技术（如Node.js和Express）来管理用户的学习权限。用户在学习完课程并通过考试后，可以在其学习账户中自助下载学位证书、成绩单及推荐信，利用PDF生成工具自动生成并存储这些文件，确保用户体验流畅且高效。

（4）自动化发社交媒体

通过大模型提示词角色刻画等技术使用Claude和Openai大模型和Openai dalle3绘图模型自动化生成社交媒体的帖子，在meta旗下的facebook、Instegram、Whatsaapp以及LinkedIn和X上根据不同媒体对文字个数和图片尺寸的要求自动化发帖维护社交媒体，引流

（5）邮件助手

https://workflow.x-me.ai/webhook/1f83e8ac-d465-454a-8327-cef7f0149cb1/chat

在服务器上部署n8n，构建自动化邮件回复助手，通过大模型、RAG和提示词技术，实现邮件草稿生成和自动回复，助力解决用户的“最后一公里”问题。

测试链接如下：

（6）数字人平台

https://app.x-me.ai/main

根据wav2vec、ER-NeRF、Musetalk、V-Express、DH-Live等数字人模型的预训练微调推理

数字人开发

- **AIGC-数字人**

2021.07-2024.05

数字人项 目 已完成：
1.实时对话
2.上传本人或者任何二维图片克隆 自 己的数字人
3.大模型多轮对话
4.语音克隆 自 己的数字人
5.抖音等社交软件平台直播间搭建等工作。
具体自动语音识别ASR，大模型集成，文本转语音TTS，语音驱动生成数字人 THG等工作

它的核心是一系列高效的人工智能模型，包括 ChatterBot、GPT、Claude、langchain、chatglm、text-generation-webui、讯飞星火、智谱AI、谷歌Bard、 文心一言 和 通义星尘。这些模型既可以在本地运行，也可以通过云端服务提供支 持。

数字人的外观由 Live2D、Vtube Studio、xunireen 和 UE5 结合 Audio2Face 技术打造，为用户提供了一个生动、互动的虚拟形象。这使得 数字人能够在各大 直播平台，如 Bilibili、抖音、快手、斗鱼、YouTube 和 Twitch，进行实时互动直 播。当然，它也可以在本地环境中作为数字人客服与您进行个性化对话。

为了使交流更加 自然，数字人使用了先进的 自然语言处理技术，结合文本转语音系统，如 Edge-TTS、VITS-Fast、elevenlabs、bark-gui、VALL-E-X、睿声AI、 genshinvoice.top、 tts.ai-lab.top和GPT-SoVITS。这不仅让它能够生成流畅的回 答，还可以通过 so-vits-svc 和 DDSP-SVC 实现声音的变化， 以适应不同的场景和 角色。

此外，数字人还能够通过特定指令与 Stable Diffusion 协作，展示画作。用 户还可以 自定义文案，让 AI Vtuber 循环播放， 以满足不同场合的需求。

1. 数字人客服实时交互

（1）1.流式输出-metahuman-stream，基于Ernerf模型的流式数字人，实现 音视频同步对话。基本可以达到商业效果；（2）视频切割法-实现的双人直播数字人；（3）提前录制-伪实时， 虽然笨拙，但是成本低

具体的技术：

2. 生成数字人短视频

可输入文本、语音和视频的任意组合，生成相关内容的短视频。

3. 数字人直播

可在任意社交平台进行7*24小时不间断直播，可提前设置要售卖商品的播报 内容， 以及根据直播间的弹幕进行语音回答。

大模型本地部署、微调和研发

- **大模型本地部署、微调和研发**

2020.08-2023.7

1. 开源大模型本地部署和微调

（1）ChatGLM3-6B高效微调；（2）Qwen模型的批量推理与推理加速；（3）使用LoRA微调一个医疗垂直领域的Qwen模型；（4）LLaMA-Factory项目下Baichuan2、Qwen和ChatGLM3的微调；（5）Transformers库的使用及配置大模型开发环境；（6）LangChain使用Ollama接入本地化部署的开源大模型；（7）微调数据集构建以及高效微调PEFT金融项目；（8）借助LtM提示工程攻克SCAN指令翻译难题；（9）手动编写Qwen模型的Chat()方法并接入vLLM框架，实现多轮对话；（10）Qwen模型的ReAct原理介绍及流程拆解，进行外部工具API调用开发实践；（11）LangChain使用Ollama接入本地化部署的开源大模型

2. 智能体工作流以及RAG

在熟悉了围绕谷歌云Gmail API进行AI应用开发的流程之后，我围绕AI应用开发技术对两个方面进行探讨，其一是如何借助AI（大语言模型）构建一个高度自动化的AI项目开发流程，其二则是完成一些目前较为热门的AI应用开发项目的实现方法，如定制化代码解释器项目、外部知识库问答机器人项目等。

利用AI来进行AI开发的策略。将大语言模型应用于软件开发流程以提高软件开发效率，本身也是大语言模型目前非常热门的应用方向，借助大语言模型强悍的人类意图理解能力和代码编写能力，许多软件开发工程都能够在大语言模型的加持下大幅提高开发效率。

（1）基于Google API库的敏捷型AI应用开发

我借助当前这个简单的邮件AI应用的开发项目，来探讨如何利用大语言模型加快当前项目的开发效率。

（1）本地Chat模型代码创建、验证与保存流程；（2）全自动函数编写策略；（3）全自动代码审查流程与复杂任务管理方法；

（2）本地代码解释器

Code Interpreter性能瓶颈分析：数据安全性问题、Python及其第三方库的功能范围决定了Code Interpreter的功能范围、大语言模型自然语言编程性能瓶颈。因此个性化定制本地代码解释器有很大的应用前景。

（1）定制化代码解释器；（2）高阶代码解释器功能设计与实现；（3）定制化SQL与Python代码解释器；（4）将谷歌搜索接入Chat模型中，从而一定程度解决大语言模型本身知识库时效性和专业性不足的问题，这相当于是定制化知识库问答的一种实现形式

（3）外部知识库问答机器人

我们先围绕一组带有标签文本数据集尝试进行Embedding编码，并围绕此项量化之后的结果进行分析和建模，以此探究Embedding在语义分类问题中的表现，并探究语义分类在大模型开发中的实际应用；进一步探究更加复杂的开发场景下的Embedding技术应用，如借助Embedding提升用户意图识别准确率。

进一步尝试借助Function calling功能来解决本地知识库内容长度超出模型最大上下文限制的问题，训练定制化问答机器人。使用Embedding和微调这一全新的技术领域解决长文本问答机器人的非常核心的技术

实习经历

硕士科研经历

- **基于空间变换矩阵测量足部最小离地间隙的估计算法**

2020.09-2021.12

本项目的工作主要集中在三个方面：(1)提出并验证一种可准确测量步态中足部最小离地间隙（Minimum foot clearance, MFC）的估计算法；(2)采用敏感性分析方法理论上研究了摇摆鞋参数和髋-膝-踝关节角度对足部最小离地间隙的影响；(3)设计定制了四双不同摇摆半径的实验鞋具，并量化分析其对下肢关节生物力学和步行能耗的影响。技术细节如下：

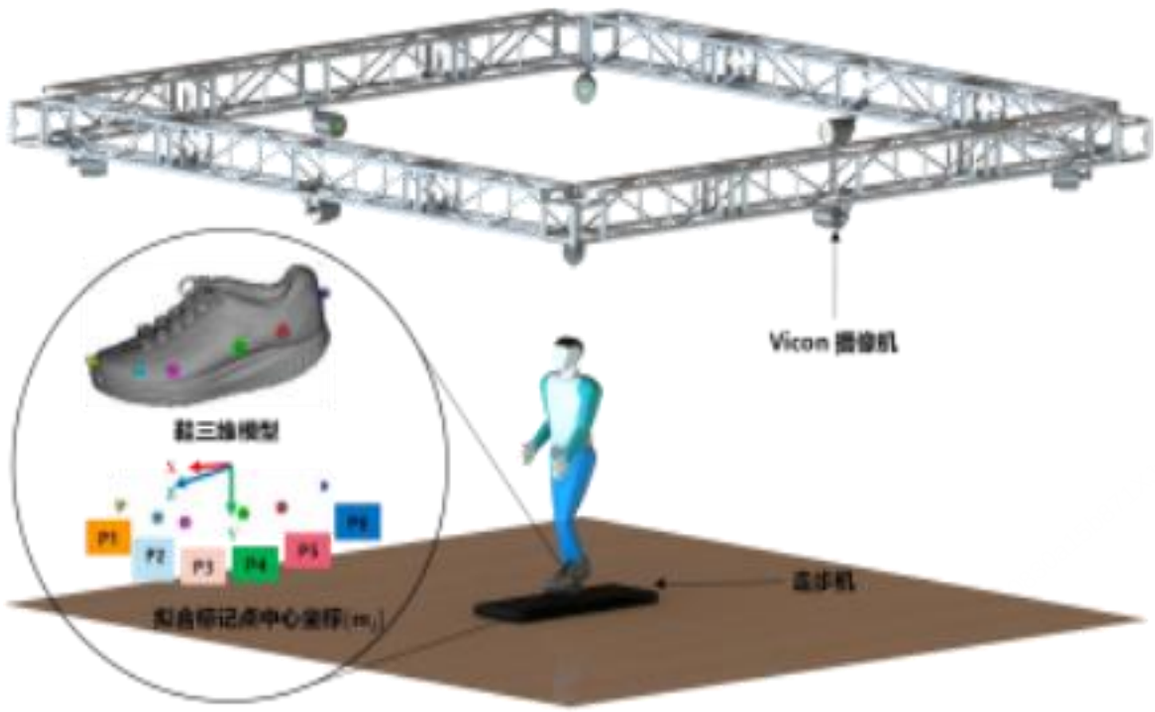

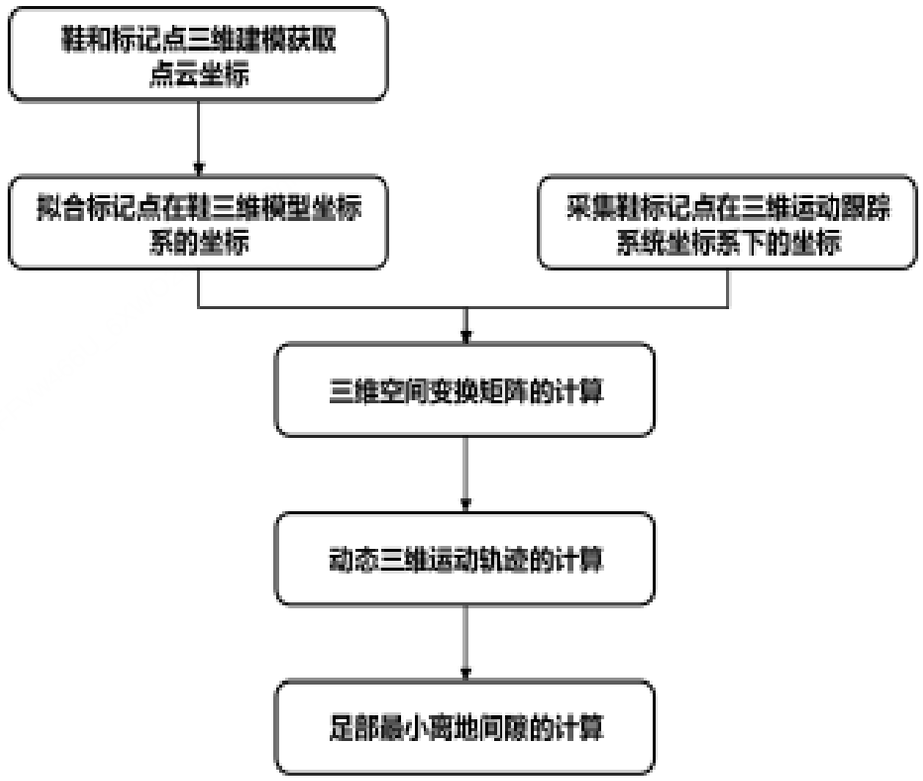

- **利用可穿戴机器人-外骨骼设备估计最小趾部间隙的AI方法**

2021.07-2022.12

由于可穿戴传感器的耐磨性、紧凑性和低成本，人们对使用其进行实用步态监控的需求越来越大，例如包括加速计和陀螺仪的惯性测量单元(IMU)。然而，一个主要的限制是固有的噪声，使得加速度积分对于从IMU数据估计MFC高度不可靠和不准确。本项目提出了一种利用爬山特征选择方法训练广义回归神经网络(GRNN)估计MFC高度的机器学习方法。基于GRNN预测MFC高度的均方根误差(RMSE)为6.6mm。本项目提出的基于GRNN的MFC高程估计方法比其他估计方法的均方根误差降低了约68%。研究结果表明，实验室外的步态监测具有很强的潜力，可以在日常运动中提供实时的MFC高度信息。

- **基于自回归和支持向量机的老年人绊倒步态模式检测**

2022.03-2023.03

本项目提出了一种智能步态检测系统(自回归-支持向量机)，用于筛选有跌倒危险的老年人。这个系统的目的是为老年人的步态提供早期检测，使人想起绊倒的特征，以便能够实施预防措施。我们的系统由两个阶段组成，一个是由自回归(AR)过程估计的预测器模型，另一个是支持向量机(SVM)分类器。系统输入是由代表稳定行走的MFC的连续测量构建的数字信号。AR-SVM系统在23名个体(13名健康，10名在过去一年中至少摔倒过一次)上进行了测试，他们每个人都以自己选择的速度在跑步机上完成了至少10分钟的步行。在第一阶段，四阶AR模型需要至少64个MFC值才能正确地分类。当模型系数作为支持向量机分类器的输入特征时，检测速度进一步提高，步行时间小于1min。该系统仅用16个MTC样本就能达到95.65%的检测正确率，而当用8个MTC样本时，准确率下降到69.57%。

在读期间发表的论文

[1] H. Chen, W.-M. Chen, L. Chen, X.-G. Yang and X. Ma, "3D-MFC: A method for computing critical gait parameters based on virtual marker tracking," 2022 15th International Congress on Image and Signal Processing, Bio Medical Engineering and Informatics (CISP-BMEI), Beijing, China, 2022, pp. 1-5, doi:10.1109/CISP-BMEI56279.2022.9979984. (IEEE Open Journal of Signal Processing.)

[2] Hao-Chen, Xin Ma, Wen-Ming Chen. Optimal designs for rocker-profile footwear: effect of forefoot rocker radius on walking economy in healthy individuals. The 12th IFMBE Asian Pacific Conference on Medical and Biological Engineering, APCMBE 2023. (A Springer book IFBME Proceedings.)

[3] 陈浩，蒋东港，朱云超，黄吉，钱乐文，宁心仪，罗虎，马昕，陈文明*. 3D-MFC:一种基于虚拟点云跟踪计算关键性步态参数的方法. 第 8 届中美生物医学工程 暨海内外生物力学学术研讨会.

[4] 陈浩，蒋东港，朱云超，黄吉，钱乐文，宁心仪，罗虎，马昕，陈文明*. 一种 基于三维重建计算关键性步态参数 的方法. 中华 医学会第二十二届骨科学术会议暨 第十五届COA学术大会.

[5] Hao-Chen, Xin Ma, Wen-Ming Chen. Response of able-bodied persons to changes in kinematics of human locomotor systems during walking: effects of rocker radius and walking speed. Gait & Posture. 在投

[6] Hao-Chen, Xin Ma, Wen-Ming Chen. Effect of different forefoot rocker radius on lower limb joint biomechanics in able-bodied persons. Journal of Science and Medicine in Sport 2023.在投

[7] Hao-Chen, Xin Ma, Wen-Ming Chen. Design of ergonomic rocker shoes using 3D-MFC, virtual modeling and toe clearance sensitivity analysis. medical engineering and physics 2023. 在投

[8] Hao-Chen, Xin Ma, Wen-Ming Chen. The mean sensitivities of toe clearance to the hip, knee, ankle joint angles and shank-to-vertical angle (SVA) during the swing phase of able-bodied walking under different rocker radius conditions. journal of biomechanics 2023. 在投

专利

[1] 陈浩，蒋东港，朱云超，黄吉，钱乐文，宁欣怡，罗虎，马昕，陈文明. 基于足 与地面最小距离检测的人体绊倒风险识别方法. 专利号：202210824720.4.

[2] 陈浩，蒋东港，马昕，陈文明. 一种下肢辅具翻滚形状的仿生设计方法. 专利号：202310808613.7.