伦恒睿

手机：13011655995 | 邮箱：hengruilun@163.com | 微信：luntuotuo
2000-11-24 | 男

教育背景

格勒诺布尔-阿尔卑斯大学 2023-07 至 2025-05
计算机与电子 | 硕士　　成绩排名：1%～5%

西安电子科技大学 2019-09 至 2023-06
电子工程学院 | 电子信息工程 | 本科　　成绩排名：5%～20%

个人技能

c++、python、cuda、异构编程　　PyTorch、LLVM、NCCL通讯库

语言能力：CET4、商务英语 Linguaskill B2、TFU4、TCF B1

工作/实习经历

百度（昆仑芯）
高性能计算工程师 2025-07 至 2026-01

昆仑芯片P800 BLAS算子库建设与高性能优化
维护P800的BLAS算子库，重点攻关GEMM、MoE、Bmm等关键算子

- 创新MoE、Fa性能优化方案：针对**MoE算子**的负载不均问题，原创设计了多核心均衡负载算法，结合动态模式与组内/组间微调Solver，解决了专家路由的性能瓶颈，**达成全量性能提升20%**。同时针对mlp-mtp的flash attention设计任务化均衡方案，已申请专利。
- 主导关键算子开发与迭代：独立负责GEMM、BMM算子的功能扩展，**包括Bf16/FP16舍入、多样化Scale及激活模式支持**；拆分DeepSeek最新论文中的算子mhc并实现。
- 参与通算融合相关项目，主导设计并实现了**QuantGEMM、ReduceGEMM**等多个定制化融合算子。
- 构建芯片级质量验证体系：升级单测基建，建立覆盖所有算子及算法的测试案例与精度标准。通过硬件设计反向推导理论精度边界，并引入SNR信噪比精度校验机制，**实现功能单测覆盖率90%。**

上海期智研究院
模型算子工程师 2025-03 至 2025-06

参与“感存算控一体”高能效计算架构研究，负责**大语言模型（LLM)**在华为**昇腾**芯片上的性能调优。

- 针对当前大模型对于长文本推理的困难性，基于**transformer架构**优化**自注意力计算算子**，利用**IVF**实现**KV cache的稀疏性计算+**PQ量化（以查代算）在千级长文本减少40%的推理时间（相比于LLAMA2）。**改良flash attention机制**，使关键算子吞吐率提高 1.5 倍，推动昇腾 NPU 低精度计算能力的深度适配。
- 对于分布式推理引擎，提出TOKEN-RING机制，即在**环形拓扑结构中同时传输查询张量(Q)和输出块(block out)**，我们显著提高了**NVLink等高速互连架构**的带宽利用率。与传统的单向Ring Attention相比，TokenRing通过重叠通信与计算，实现了更高效的长序列处理能力，同时保持与Flash Attention的高效计算特性的兼容性

华为技术有限公司
高性能计算工程师 2024-03 至 2024-09

参与硬件领域的高级研发主题架构 - 针对下一代基于 **ARM/RISC-V 的架构**用于网络设备的片上系统（防火墙、接入路由器等）。

- 在 ARM/RISC-V 片上系统（SoC）研发中，传统模拟器（如 **gem5**）在性能仿真时效率低千倍，严重影响设计迭代速度。为解决这一问题，我开发了 基于 **DynamoRIO 和 objdump 的 benchmark generator 工具链**，实现自动化、高效的 CPU 性能测试。

- 该工具链通过 h**ot attach 提取多核多线程设备的关键 trace，自动生成可执行的 ELF 格式 benchmark**，在 保证 90% 置信度 的同时，减少 95% 迭代时间。目前，该工具链已推广至开发端，并被 华为南研所 采用，用于 CPU 研发与性能优化。

施耐德电气

嵌入式软件工程师 2023-12 至 2024-03

针对行业痛点（实时监控能力弱、远程控制延迟高、设备维护成本高），主导设计基于物联网架构的系统优化方案。整合 Tesla Simulator 模拟器与多元传感器数据采集方案，设计统一设备状态码传输协议，并通过 **Web API + MQTT** 混合通信架构 实现低延迟远程控制与设备自检能力。

- 构建工程以捕获PWM信号等充电桩的属性，实现Tesla Simulator的控制，部署多种解决方案于Raspberry Pi（wiringpi、spidev、DMA ） 技术栈：python、 C、C++ 。
  设计数据读取、控制的驱动程序并集成在当前环境中。
  Web API等充电桩物联系统的设计，对采集数据通过MTQQ协议上下行。

影石insta360

嵌入式软件工程师 2024-10 至 2025-02

负责运动相机 **Ace Pro 系列的 UI 界面开发，**策划整个相机**回放模块**的功能及**代码开发框架。**

- 设计新特性“高斯模糊”“手势控制”“个性页面定制”等十余个特性，提出**浮窗岛**和**常用状态页使**用户**操作路径缩短21.7%，交互流畅度提升 9.1%。与竞品大疆action系列进行A/B测试，特性页面的均分高于友商20%**。
- 由于**Embedded Wizard** UI开发工具的基础架构过于简易，为开发团队提出**组件化管理架构**，整个UI开发逻辑被细分至**moodle 、manager、root page 、page 、component层**，为每层提供不同特性的模板（参与核心源码编程），整体减少开发团队80%的重复工作，规范化的UI设计结构已推广至全景、口袋相机业务线。在Go相机系列（主机、充电盒显示屏分开的产品）使用**ERPC（远程过程调用）**部署组件间通信，实现模块的**分布式部署，**利用这个体系的**高可拓展性**保证与友商的**功能竞赛**中可以**快速协作**开发。

项目经历

智能交通系统-雷视融合 算法开发者 2023-04 至 2023-08

本项目使用毫米波雷达收发线性调频波来对交通目标进行监控，并与摄像头数据进行融合，最终开发成果为一个智能交通 系统。使用C++在zynq7030的ARM端开发，同时也涉及基于pytorch库的目标检测等相关人工智能算法。技术栈：ARM架 构开发、C++、Python(pytorch)

工作内容：

1.在Zynq 7030的ARM端，使用C++开发了4000行代码，实现了CFAR、聚类、目标跟踪和目标检测等算法，配置PS端和PL端的DMA通信以优化CPU调度，编写UDP网络协议实例，使用本地网络向上位机上传结果以供调试。

2.优化了YOLOV5算法。

3.利用Python编写坐标转换、相机标定和数据融合算法，将雷达数据与视频画面融合。

基于Freertos的智能门禁系统 独立开发者 2023-02 至 2023-07

开发一款STM32F407单片机基于Freertos实时操作系统的智能门锁系统。该系统可识别四种不同的解锁方式,包括：AS608指纹硬件模块、 RC522射频识别硬件模块、TFTLCD屏幕模块 、SG90舵机硬件模块、ESP8266 WIFI模块等。

主要工作内容：

1.硬件系统设计： 根据手册选择端口和外设连接，配置通信方式、各个模块初始化等操作，

2.软件系统设计：使用FREERTOS调度各个模块任务， 触摸屏任务：FSMC控制器+模拟SPI通信实现并口协议完成。AS608 指纹任务：使用串口进行命令操作， ESP8266WIFI任务：中断获取串口指令，识别指令。MFRC522射频识别任务：通过模拟SPI发送命令。

获奖情况

百度昆仑芯 H2优秀员工 2026-01

西安电子科技大学优秀毕业生奖学金 2023-06

RoboCore机器人大赛团队奖 2022-12