吴金辰

电话： (+86) 15520760201 | 邮箱： wujinchen1998@163.com | 现居城市： 上海
生日： 1998-08 | 性别： 男

个人简介

作为分布式并行计算领域的AI框架工程师，在大模型训推框架和AsendC算子设计开发方面具有深入的技术背景和丰富的项目经验。

- 在训推框架方面，作为FO与迭代项目经理带领团队成功实现了从不同层级实现自动切分并行策略算法，并在客户现场成功落地应用，显著提升了模型性能与计算效率；
- 在算子设计方面，主导了Moe网络中多个关键算子的开发和落地，包括dispatch、combine以及barrier、eplb等算子，并成为Moe系列算子的Owner；
- 除此以外，还参与Ai4Science领域中算子的创新技术项目，推动框架和算子在实际应用中的持续优化与创新。

专业技能

客户驻场经验丰富，具备bug shotting，闭环能力强，项目管理经验足

熟练掌握Python, C/C++，具备芯片侧（AscendC，对标CUDA）与框架侧（MindSpore/PytorchToAscend，对标Pytorch）设计与开发能力

教育背景

加州大学洛杉矶分校-电子与计算机工程 硕士 工程学院 2021年09月 - 2022年12月

方向：高级计算机架构、AI on Chip

电子科技大学-计算机科学与技术 本科 计算机科学与工程学院 第一学位 2016年09月 - 2020年06月

数学与应用数学 本科 数学科学学院 第二学位

工作经历

华为技术有限公司-AI框架工程师 分布式并行计算实验室 2023年04月 - 至今

- 所在团队：MindSpore创新团队
- 工作职能：和国内企业团队合作（蚂蚁、字节、美团等互联网企业及各大运营商），聚焦模型性能调优摸高、并行优化和通算算子穿刺落地，提升框架性能与易用性；协同清北等一线高校、科研机构，推动AI解决方案在传统领域的落地及昇腾算力生态构建

北京陌陌科技有限公司-算法实习生 深度学习算法实验室 2020年09月 - 2021年02月

- 所在团队：深度学习算法实验室
- 工作职能：人脸图像发型生成、风格化图片生成

项目经历

Moe大EP通信算子及相关特性-Feature Owner 2025年05月 - 至今

大EP场景下Moe网络推理算子及相关特性设计、开发、落地

- 传统AlltoAllv算子在大EP场景通信开销巨大，整网TPS提升困难，设计并开发MoeDistributeDispatch、MoeDistributeCombine算子，通过token粒度的流水排布与内存语义通信技术减少卡间同步开销，单算子场景下**性能可提升30%+**
- 字节SEED客户需求：设计并开发大EP场景故障快恢特性，新增检测算子协同DFS算法，使传统Server故障恢复重新拉起服务的时间从**20min以上缩短至秒级**业务恢复，极大提高推理服务系统可靠性
- 算子与特性均落地蚂蚁、字节、美团等客户现场，驻场迁移至客户框架并提供持续技术支持

Layer级自动流水线负载均衡调优算法-迭代项目经理、Feature Owner 2025年01月 - 2025年03月

带领国内外团队，基于MindSpore框架+昇腾MindFormers套件实现流水线负载均衡算法性能调优工具

- 实现了均衡计算和内存的全局求解方法，面向复杂的流水线编排逻辑，自动生成最优的stage-layer分配和重计算策略
- 将算法打包成为自动流水负载均衡工具，结合Dryrun集群内存仿真工具，实现低成本高效模型调优
- 达到**分钟级**找到最佳负载均衡策略，大幅提高调优效率；在**万卡集群千亿参数Llama模型端到端相比开箱性能提升14%、千卡集群671B DeepSeek-V3将TFlops从3xT提高至6xT**

算子级自动并行切分算法-Feature Owner 2024年08月 - 2024年12月

解决静态图场景算子并行切分策略配置繁琐问题，通过自动搜索代价最低的切分策略，降低模型并行配置门槛，增加易用性

- 通过建立代价模型，实现由配置并行策略的算子向未配置的算子传播并行策略，提升MindSpore框架并行能力的易用性
- 算法通过逐步迭代，支持市面经典大语言模型，并通过迭代特性逐步优化算法逻辑与泛化性能力
- 开发策略保存加载功能，大大缩短训练拉起时执行时间，在万亿参数量Moe网络，8k卡集群下将静态图模式编译**总耗时从45min优化至10min以内**
- 商业上落地昇腾MindFormers、电信、移动等客户，并通过国家科技部项目验收；作为MindSpore布道师，在MS易用性SIG会议中宣讲切分策略传播算法

昇腾CANN开源开放-通算算子编译工程架构师 2025年07月 - 2025年09月

作为开源技术专家，为海思CANN开源开放任务提供关键技术支撑，提升了开源效率和质量

- 设计通算融合算子整体开源方案架构
- 在开源仓搭建通算算子编译工程
- 带领团队将旧仓中通算算子整体迁移至开源仓，包括AlltoAllvGmm、AllGatherMatmul等通算融合算子、以及MoeDistributeDispatch、MoeDistributeCombine等纯Moe通信算子，累计迁移算子共10+

AIGC风格化图片生成-实习生 2020年09月 - 2021年02月

- 训练神经网络实现自动监督标注实习生与外包公司挑图结果，筛选FFHQ与CelebA人脸数据集训练SVM分类器
- 使用StyleGAN网络为人脸照片生成刘海，在确保id的情况下可以保证大部分图片生成自然美观的刘海
- 利用上述方案生成大量数据(100w数量级)，筛选出优质图片(10w数量级)训练Pixel2Pixel网络，显著提高了项目鲁棒性
- 将不同的StyleGAN模型融合得到风格化图片(丧尸风、小丑妆等)
- 功能顺利按时上线，获得优秀实习生荣誉

荣誉奖项与证书

分布式与并行软件实验室部长奖-技术竞争力上市 2025年4月

2024年度绩效A 2025年2月

昇腾基础软件STDT激励-技术创新与突破奖 2024年12月

华为“明日之星” 2023年11月

计算机科学与技术学院卓越学生奖 2019年1月

专利：一种智能家居系统 专利号：ZL 2018 2 0497301.3 2018年6月