周培晨

男 | 29 岁 18868130765 1303359419@qq.com

8 年工作经验 | 算法工程师 | 期望薪资：60-80K | 期望城市：杭州

教育经历

浙江大学 本科 软件工程 2013-2017

个人优势

1. 精通 Transformer/GPT/LLaMA 等模型结构设计，深入掌握 MoE 稀疏化训练等前沿技术。精通 3D 并行/ZeRO 优化等分布式并行技术，主导落地自研框架，为客户调优并行训练性能，消减拖尾时间，降低空泡率；熟悉 LoRA 等 PEFT 技术，实战为终端部门微调小模型。为头部运营商调试和落地基于 GRPO 算法的分布式 MindRLHF 训练框架，实现 KL 散度约束奖励模型，并穿刺 MPMD 训练范式，为 rollout 流程，reward 计算和和 actor 训练异步打下框架基础。
2. 作为 AI 框架 MindSpore 初始成员，在分布式领域深耕多年，作为分布式框架团队（5-6 人）负责人，从 0 搭建 MindSpore 分布式基础架构，实现 MindSpore 自研 Parameter Server，Embedding Cache 异构缓存，Federated Learning，强化学习 MPMD 等分布式框架，对接和实现 GPU/CPU/Ascend 多种集合通信库，设计和实现自研弹性伸缩和容灾回复功能，并将各类算法落地到自研框架中，帮助 MindSpore 抢占国内市场份额至 30%+，撬动国内大规模集群市场 xx 亿元。
3. 精通 llm 模型结构，强化学习后训练，llm 推理，联邦学习，推荐网络等原理，擅长在熟悉算法的基础上，结合对基础框架的掌握，对分布式任务进行端到端深度调优，并将各类算法落地生产环境。对大规模集群性能/内存优化，精度调试，多流并发，host 调度，异构通信，并行策略调试等有极其丰富的经验，与周边团队通力合作，也和开源社区保持紧密联系（torch，nccl，hugectr，pslite 等），支撑多个昇腾局点项目交付，并多次获得公司激励。
4. 对 AI 领域拥有极大的兴趣和学习动力，平时会自学算法和主动跟进业界 sota 技术，手写 mla 等热点算子推导公式，独立部署环境复现训练效果（ds-r1 zero）等，。持续充电已养成习惯，努力提升自我竞争力，为团队带来更大价值。
5. 擅长根据团队成员能力优点和自我价值实现等方面，综合考虑成员的任务分工，能力提升和职业规划，在保证达成组织业务目标的同时，帮助个人成长。作为新员工导师，培养出一名优秀实习生和一名优秀新员工（投入 AI 领域仅仅半年），且团队氛围融洽，人员稳定。

本人渴望投入算法调试和工程实现结合的垂直领域发光发热，在性能和内存最优的情况下，同时进行算法创新，提升训练效果，为实现 AGI 贡献自己的力量。

工作经历

华为技术有限公司 ai 软件开发工程师 2019.06-至今

内容:

1. 落地 3D 并行/ZeRO 优化等分布式并行技术，主导落地自研框架 MindSpore，为头部运营商客户万卡规模集群调优并行训练性能，消减拖尾时间，降低空泡率，性能稳定性提升 50%+，助力性能摸高测试；熟悉 LoRA 等 PEFT 技术，为终端部门微调端侧模型，精度相比云侧训练提升 3%。为头部运营商调试和落地基于 GRPO 算法的分布式 MindRLHF 训练框架，实现 KL 散度约束奖励模型，并穿刺 MPMD 训练范式，为 rollout 流程，reward 计算和和 actor 训练异步打下框架基础。
2. 负责国产开源框架 MindSpore 分布式框架设计，开发和维护。实现自研 Parameter Server，Embedding Cache 异构缓存，Federated Learning，强化学习 MPMD 等分布式框架，实现了自研 cpu 集合通信库 MCCL，对接 GPU/Ascend 集合通信库，设计和实现自研弹性伸缩和容灾回复功能。
3. 优化超大规模集群组网和训练性能，出差多个现场攻克大规模集群难题，撬动国内多个局点万卡规模业务：运行商 Y xx 万卡集群，销售额 xx 亿元；运营商 D x 万卡集群，销售额 xx 亿元等等。并且在 x 万卡规模下，断点续训比拼中超越业界通用框架，通过组网异步初始化，pp 流水预建链，编译缓存等，将断点续训耗时控制在 10 分钟以内，帮助昇腾芯片攻坚市场。
4. 设计和开发了联邦学习框架，实现 cross-device 端云协同分布式训练，通过控制 fedavg 时间窗口，异步更新等算法，

ALBERT 网络精度在联邦学习训练场景下精度达 83%，超越云侧独立训练精度 80%，成功交付终端云。同时作为二作成功投递 2022 sigkdd 论文一篇，作为专利实现人输出高潜专利两篇。5. 搭建分布式统一运行时框架，将多种分布式业务场景抽象为统一 DAG，支持异构设备间通信，实现通信融合，多级粒度绑核，计算通信流分配等框架优化，提升分布式训练和推理场景下泛化性能。

6. 作为初始团队成员，从 0 到 1 搭建 MindSpore 的 gpu 后端框架，手写多个 gpu 算子，攻克搭建初期存在的执行序和算子正确性问题，为 MindSpore 后续的演进和网络调试提供实践经验，一杆到底打通了了 MindSpore 首个 cv 网络在 gpu 的精度正确性，精度和性能对标业界 sota 框架。

业绩:

1. 多次总裁奖，技术突破奖等公司内部奖项激励。
2. 多次明日之星，质量之星。
3. 在五年时间从 14 级升到 17 级，最近即将升 18（已在三级部门评审）

华为技术有限公司 C/C++ 2017 .07-2019.06

负责视频监控产品的视频编解码，存储，sdk 等相关特性的设计和开发

项目经历

强化学习框架落地业界算法 框架重构负责人 2025.01-2025.06

负责自研强化学习框架 MindRLHF 的重构，MPMD 训练范式穿刺和 grpo 算法复现：

1.抽象化基础模型类，将 actor，reward 和 ref 等模型分别抽象为对应 worker 类，为后续强化学习框架生态演进打下基础。

2.搭建基于 ray 的 MPMD 训练范式，支持 rollout，reward 和训练流程并行流水起来，提升算法的易用性和泛化性。

3.支撑外部客户 xx 实验室复现 grpo 强化学习算法，攻克解决多个显存峰值高，通信算子拖尾，训推权重切分错误等问题，保障算法的顺利落地自研框架。

一体机推理性能优化以及异构通信 分布式性能优化负责人 2025.01-2025.06

负责 DeepSeek 推理模型的性能优化工作。针对芯片硬件无法跨机通信的瓶颈，创新性地设计了异构通信算法，自主研发跨机 CPU 集合通信库，成功突破硬件限制，为项目上线奠定关键技术基础。同时深度优化框架 Host 侧性能，通过实现高性能模式运行时、内存去锁化等核心技术，将算子下发性能优化至 10us 以内，最终使满血 DeepSeek 推理吞吐量提升 10%以上。异构通信方案已成为公司在特定芯片型号下推理加速的标准做法。

分布式推理性能优化 算子开发及优化负责人 2024. 10-2024. 12

带领两名同事负责函数式通信算子开发和性能优化，性能最终持平业界 sota 框架，并且通过对接 aiv 通信算子，在推理场景平均提升吞吐达 13%，大大提升了推理框架竞争力。

超大规模集群项目交付 分布式框架负责人 2024.06-2024. 10

头部运营商以及互联网用户总计 xx 万卡交付项目，对集群稳定性，分布式框架可维护性和易用性，3D 并行性能以及 mfu 存在较高要求，对于产品线达成 xx 亿元的销售额目标至关重要。本人出差多个项目局点，与客户积极沟通业务痛点，攻克多个网络通信疑难问题，通过流程剪枝，多线程处理注册消息等优化，万卡规模集群组网性能提升 80%以上；同时通过 pp 并行动态 shape 场景下不断流等优化，降低空泡时间，单 step 性能提升 5%，图编译时间提升 45%，为 MindSpore 静态图突破国内市场打响第一枪，撬动 xx 万卡芯片销售，同时受到公司内部产品线和实验室多个层级奖项。

内部会战项目及客户交付项目 分布式任务负责人 2024.01-2024.05

参与多个公司内部会战项目，带领三人团队，主导设计和构建动态图分布式框架，以及内存，流，事件接口，性能均持平业界 sota 框架；同时出差支撑多个现场局点，攻克多个千卡规模集群断点续训，训练性能抖动问题，将分布式框架的易用性，可定位性和稳定性提升至交付水平，并收到客户的认同，累计支撑 6 个现场千卡级规模项目交付，助力昇腾芯片开拓业务市

场。

MPMD 训练范式课题 课题导师及负责人 2023.07-2023. 12

带领课题团队三人，设计基于 Mindspore 框架的自动图切分算法，实现 MPMD 课题穿刺，在 dit1.0 网络下，MPMD 训练范式获得 10%提升

EmbeddingCache 推荐网络算法落地 算法落地和性能优化负责人 2023.01-2023.06

为攻克公司内部推荐项目，对 embedding cache 多级缓存和 ps 异构通信进行深度优化，调研业界多个 ps 架构优化论文，通过落地优化器异构，通信融合，id 去重，rdma 通信等技术，提升 wide&deep 网络吞吐，在昇腾卡上性能超越 nvidia 官方推荐框架 hugectr 30%以上，保障项目内部交付达成。