常玉锟

出生:1995.10 | 现居:北京
Phone: +86-166-8962-8062[1] | Email: Evan.Q.Chang@Gmail.com
方向:**资深 AI 产品** | 薪资:面议 | WechatID: Nehemiah_Gene

教育背景

哈尔滨工业大学（深圳） | **理学院** | **C9** **工程力学|硕士** **2017.09 – 2020.01**
西安科技大学 | **理学院** **工程力学|学士** **2013.09 – 2017.06**

业绩提炼

· **Deep-Agent:裂变意图**架构+**L3 ~ L4** 弹性层级,5 ~ 8Thinking 步序 *9 个**分治模型**, Deep-Query **提问量增 12PP**。
· **vLLM 架构:分治架构降综合 Token 15%**,GPU Opex -15PP,报送**财年 P&L**,1+9 搜索架构使 RAG 空间**扩充 40PP**。
· **产品商业化:**促天工 ARR 营收**环比+3PP**,**+5PP 支付**基数,科大系辅助**获 46 亿** C 端营收,**1050 万 QPU/月**推理调用。

经历概览

· **NTU PACE(出境)**	脱产进修 |BASE:新加坡 | 学员	**2025.12-2025.12**
· **昆仑万维 (上市)**	全职工作 |BASE:上海 |AI 产品	**2023.07-2025.12**
· **NTU PACE(出境)**	脱产进修 |BASE:新加坡 | 学员	**2023.06-2023.06**
· **科大讯飞 (上市)**	全职工作 |BASE:上海| AI 产品	**2021.02-2023.05**
· **商线科技 (港企)**	全职工作 |BASE:香港 | 数据开发	**2020.03-2020.12**

全职经历

昆仑万维(上海科研团队) **高级产品经理** **2023.07 – 2025.12**
✧ **国内分治架构+弹性上下文**产品工程产物,**垂类 Deep-Agent**1-10 落地,亲历通用 AI 至专业 AI 强化转型。
- **(S)情景:**面对天工通用 AI 的强化转型,推进:垂类 Agent、成本降解、内置风控、会员增收四项基本工作分支。
- **(T)任务:**建立 Query 价值矩阵、裂变意图、分治架构、弹性上下文,定义 Road-Map 并量化 AI 产品各项目标。
- **(A)行动:**交付:1 个 0.8B 级路由模型，协作和微调 9 个 4B 级垂类小模型、独立推动:基于自定义 Slot 的 Prompt 组装能力(SPS),基于上下行数据链-落地带携险风控的弹性上下文模块,SCS 风险词条模块,裂变意图模块。独立且全程掌管:上下文数据规范和内置 Schema。独立编写:工程 Prompt,各项模型指令,保障除基座模型外的指令遵循能力,负责所辖 Agent 通道中 Token 的吞吐经济性优化工作。并行定义及输出 AI PRD,微调语料,测试范例,用户隐私 Item 等多项专业工作。横跨累计 24 团队成员完成既定范围内所有交付目标。
- **(R)结果:**垂类 Query 增量环比+12%,低价 Query 应答成本降 40%,高价 Query 达 L3 层思考,使天工 C 端 ARR+3PP。

科大讯飞 **语义智能 PM** **2021.02 – 2023.05**
✧ 隶属讯峰如飞,科大全资控股,归为**消费者 BU - 语义智能**方向,前 10%绩效,业务线种子成员,0-1 产品落地。
- **(S)情景:**面对科大下游 C 端产品的快速产研及语义迭代需求,解决通用意图识别+语意路由能力用于语音交互支持。
- **(T)任务:**建立语音意图语料库,规划上线 DLP 智能语义系统,推动使用 Word2Vec 实现词嵌入意图的产品化落地,含语义特征模型和自助语义意图编排能力,发布语音意图通用 API,降低科大下游 C 端新品产研成本,提高意图精准度。
- **(A)行动:**独立推动语义库+标注组件发布,基于哈工大 SCIR 做通用意图推理产品化交付,持续推理迭代和监控。
- **(R)结果:**为[讯飞翻译机,学习机,讯飞听见,讯飞输入法]提供意图推理服务,调用量 12w/月,调用 CARG=28%/月口径。

商线科技 **数据开发** **2020.03 – 2020.12**
✧ 香港本土电商 SAAS 服务商,辐射东南亚,具备 5k+B 端消费者,承担数亿美元 GMV,属港资电商科技前沿企业。
(R)结果:参与'Keeper'系列交易 BI 报表开发,使用 Python、Postman、PostgreSQL 进行数据治理,交付 2 个独立 API。

项目经历

【天工 C 端 AI】 **高级产品经理 | 昆仑万维** **2023.07 – 2025.12**
✧ **特点:十万级 DAU, C 端, 裂变意图, 分治小模型, 弹性上下文, 循环 Call, 深度 Agent, 自研 MoE 模型。**
- **[背景]**

天工 AI 搜索（C 端）是昆仑万维集团旗下独立 Multi AI 项目,截止 2026-Q1 注册用户 1.24 亿,DAU 约 129 万。随市场竞争格局的快速变迁、集团战略的调整,该项目自 2023-Q3 以来面临重大发展挑战。本人在天工 AI 团队中隶属于上下文工程小组,重点面对通用 AI 至深度强化 AI 的战发展转型,保障以下四类战略分支可同步达成:算力成本降解、ARR 经济转化、AI 风控降险、体验及粘性运营。本人独立担负 C 端天工 AI 搜索（**小模型方向**）AI-Native 综合解决方案,重点聚焦于裂变意图+弹性上下文。在 2.5 年职业生涯中,持续为四类战略分支产品化解决方案进行运营、监控、规划、验证、管理工作。

- **[目标]**

[1] V:1.2.0

· 算力成本降解:下调低经济价值 AI 任务软硬件成本,制止高经济 Query 对低经济 Query 的开销补偿,使成本扶正。
· ARR 经济转化:促进专业类 Query 会员支付转化率，拉高专业类 Query 话题频次和活跃度,扩大支付转化基数。
· AI 风控降险:减少公域互联网险情文本、上下文携险文本概率和比例，降低上下文拒采率，保障吞吐经济性。
· 用户粘性运营:在全局架构中局部重构意图门控模块,规划意图:拆分,裂变能力,增加高价值 Query 推理层级。

● [行动]

(1) 裂变意图:

· 布局和发布 **0.8B 路由模型**，配合主 MoE 大模型对高经济价值 Query 做路由指派,实现**跨模型任务**桥接。
· 独立控制上下文业务数据规范,上下行 Schema,基于 YAML+DAG 完成 Prompt 编排,使编排 Flow 稳定性达标。
· 摘选 SFT 私有预料、改编 400+Q:A 格式**指令文本**,对 0.8B 路由指派模型进行预训练微调,负责挂算法备案。
· 平均达 L3 Intent 拆解层级,高价值 Query 实现平均最达 L4 Intent 层级,对复杂 Query 承受深度拔高 40 个 PP。

(2) 分治模型:

· 先后参与从天工 MoE 模型蒸馏 9 个 **4B 分治小模型**,独立完成 Prompt 编写且控制**指令遵循覆盖率** 99%。
· 推动 0.8B 路由模型到分治小模型上下文元结构，兜底规范，连带同打通 20 余个 Tools 上下行数据通道。
· 分治模型以平均约 3B 参数优势,实现 700ms 内垂类意图推理,在法律等 11 个领域对单边 MoE 模型保持优势。

(3) 弹性上下文:

· 独立研究 Deep-Agent Paper 先进知识,产出**分治型提示引擎**。落在 Prompt-Slot,Tools-Slot 的遴选及组装能力。
· 率先携领团队使用基于槽位+变量+自然语言的纯文本提示工作,基于分治提示引擎实现快速提示词封版发布。
· 建立规则级+关联级风控词条,独责 SCS 风险词条管理系统上线，用以在 MCP 填参,返参阶段进行热更新风控。
· 独责并推广会话价值计算矩阵，借助该矩阵实现**上下文弹性增缩**,降低上下行低权 Token 消耗累计达 95w。

(4) 运营监控:

· 推进重设 Query 埋点数据库,建立实时可调的会话特征统计报表 BI,用以配套完成 AI 大盘监控体系。
· 建立:话题路线、转化漏斗、风险词报文、AI-Agent 用户反馈统计工具,并推广至各职能进行上线运营实操。

(5) 成本降解:

· 对 Cloud GPU,Private GPU,三方 LLM 和 API 进行经济审查,建立 Query 价值矩阵(CVTs)以辅助专项 P&L 工作。
· 成效:Token,GPU 冗余**消耗降 15%**,基于 CVTs-低价 Query 增量和粘度保持不变时反降 40%GPU Opex 开销。

● [成果]

· 营收转化:AI 类 ARR 环比**增量+3%/月**,专业 Query 会话增量环比+12%/月,潜在会员**支付基数环比+5%/月**。
· 模型风控:携险上下文拒采率**降至 0.05%~0.1%**,控制 MCP,高成本 API 拉起数,调控其降至安全经济范围。
· 推理能力:平均**达 L3 层 Intent**,专业纵深 Query(CVTs 中 23 类)-AB 对照下**增量比:3.3**,Query 间隔由 9h 降至 6h。

【科大智能语义系统】 **语义智能 PM | 讯峰如飞** **2021.02 – 2023.05**

✧ 特点:语义 AI，NLP 产品，中台产品，语音识别，文本意图，数千万 C 端用户，科大消费者 BU

● [背景]

于 2021 年启动,已经为消费者 BU 下辖:讯飞输入法,讯飞听见等 5 类 C 端线提供语音意图推理支持,辅助 C 端营收约 46 亿元(同比+53 个 PP)。由于消费者 BU 进入新品密集发布期,对语音意图推理需求极速攀升,各二级 BU 独立构建语义推理资源重复、周期延长、层级浅薄。传统 NLP 管道在复杂 Query 下能力受限,由于语料碎片化阻碍数据利用,致使 ROI 降低。消费者 BU 启动通用语义战略,定位为内部语义能力集中支撑。该方向针对 C 端产品语义意图痛点,通过语料治理与算法策略建模,实现对语义推理的干预式管控,使下游产品意图推理深度提升。直接驱动 DAU、留存、转化等关键指标向上,并为后续 LLM 时代积累高质量语料与基础模型能力。本人并行负责对科大智能语义系统进行:规划、定义、交付、风控四个工作方向。

● [目标]

· Query 推理:扩大对 Query 的识别范围和意图支持力度,支持科大新系 C 端单品快速 POC 验证,提高推理 F1 分数。
· 意图工程化 ROI:增加语料训练转化率,减少科大 C 端单品 POC 和 MPV 成本,将二级 PU 推理工程进行调控干预。
· C 端转化:将基础 C 端意图分析能力迁回中台,增加意图服务调用量和增长率,优化 C 端 DAU、QPU、留存指标。

● [行动]

(1) 特征工程

· 评估科大 C 侧 User-Query 类型分布,锚定数据需求-DRD,推动语料采买、标注及清洗,对 6wQA 语料完成落库。
· 跨团队将 NLP-SCIR 算法资源导入本团队,对海量 Query 抽象为四类建模目标,管控 Fine-Tune 并完成模型实例化。
· 建立 3 类基线 AI 训练准则,拉动标注、测试、风控团队进行循环执行,最终完成 F1:0.97,3 层图状 Intent 推理能力。

(2) 语义中台

· 使用轻量词汇路由机制,建立 MVP 线性意图版本,实现对硬指令的遵循和意图分析,低噪声环境 F1 分数达 0.99。
· MVP 论证后,规划上线基于:词路由、词转译、词正则的 LDP 系统,有效覆盖题型互动、知识对话等数个场景。
· 中期通过 Word2Vec 模式对模型实例进行升级,规划上线自助编排式 LDP（V3.0),已推广至 5 个 2 级 BU 团队。
· 独立负责中台产品线下:标签、词汇、编排、发布等共 6 功能板块, 跨 6 个团队对 LDP 全局迭代 22 次[2]。

(3) 推理运营

· 将高频通用 Query 进行归纳,推动将高频 QA 策略封装在 LDP 发布层,落实各项测试,累计封装 1900 个开箱单元。
· 规划 LDP 自助 Query 解析编排功能,带团队归纳最佳解析实践并封装为预设模板,使 C 端 POC 新品成本降低。

● [成果]

· 量化应用:全渠道调用量 12w/日,环增+4 个 PP/月,为科大 18 个新品提供接入,单用户 1200 次调用,环增 2 个 PP。
· 意图推理:为 5 个 2 级 BU 提供功能唤醒、解题对话、知识对答、情景对话基础能力,3400 个开箱组件,F1:0.97

[2] V:1.2.0

· 横向价值:为 40 余新品 POC,MVP 阶段提供意图推理支持,ROI 环增 1.5 个 PP,二级/三级 BU 接入覆盖率 70%。

进修经历

NTU PACE **脱产进修 | BASE:Singapore** **2025.12 – 2025.12**

Project name:《Agent base active》

✧ **[目标]**

切入:分治型 Agent,Multi-Agent,集群型 Agent 应用及工程化理论,用以对接下一阶段职业需求,扩大国际化视野。

● **[收获]**

与国际成员合作探讨 Active-agent 架构,接受指导并且获 NTU 和 Unit.co 技术组评估和建议。在 NTU 学术指导下对数篇 NTU Paper 进行摘要研读,将课程实践和讯息归纳为 AI 解决方案方法论,储备用于指导下一阶段工作产出。

● **[内容]**

· 主动 AI 架构:双通道上下文前沿理论,用以扩大基于复杂 Query 上下文空间, 适用强打断,持久反思类 Agent 场景。
· 动态 Function:主动 Route+Tools 模式+辅助 Call 机制,适用于海量 Functions 的长步序任务,强化韧度-提高经济性。
· LLM 经济审计:本地/云 GPU,全参/微调训练在不同目标下的经济 ROI 核算,可参与 AI 项目全程 P&L 评估。

NTU PACE **脱产进修 | BASE:Singapore** **2023.06 – 2023.06**

Project name:《Deep Research base Multi-Agent》

✧ **[目标]**

切入:多态 Agent 基础架构,对齐由 Google、Open-AI 所推动的技术理论,用以指导应用层的产品架构及落地能力。

● **[收获]**

理论层设计 Multi-Agent 书面方案并接受 NTU 相关方点评,应用层通过 Lang Graph/Chain 发布 Agent 工程作业。

● **[内容]**

掌握《Deep Research》原生理论, 衍生学习 RAG、CoT、Function Call、Context Engineering、MCP、弹性上下文标准化知识。同步掌握 Token 经济性管理技能,可体系化降低业务 Token 平均开支,掌握全上下文 Prompt 编写能力。

个人自评

· AIIA 成员,SAIA 成员,已掌握国内外学术界和科技权人脉,常年参加 AI 产业会议,有增修第二硕士学位计划。
· 较强独[3]立探索兴趣,能引领团队进步氛围,希望下一阶段将本人所知所学用在更大平台, 报效祖国、回馈社会。

[3] V:1.2.0