李星利

性别： 男　　**年龄：** 34

电话： 15558068258　　**邮箱：** cyneck@qq.com

个人介绍

资深 AI 智算平台架构师 ，10 年全栈研发与技术管理经验，专注于大型 AI 中台/智算平台的私有化架构设计、高难度交付与效能优化，尤其在异构算力管理、零停服迁移、亿级高并发保障领域拥有成功实践。主导交付国家级标杆项目（如央视 AI 中台），成功支撑日均亿级请求、99.99%可用性的 AI 生产系统稳定运行。擅长洞察政企客户（2B/2G）业务痛点，通过架构创新（如多集群管理、弹性灾备）与工程优化（性能调优、流程标准化）推动 AI 能力高效落地，缩短交付周期 20%+，显著提升系统稳定性。拥有智能工作流引擎国家专利，并在新媒体多模态 AI 应用（老片修复、跨模态检索、大模型服务化）中推动平台与产品持续迭代。以解决复杂工程问题和创造客户价值为核心驱动力。

相关技能

- 架构设计：深度实践 AI 智算平台架构（混合云/私有化）以及部分 AI infra 技术、主导异构算力管理（NVIDIA/华为 GPU 集群）与高可用灾备设计（K8S）；持续优化 AI 工程化链路：包括算法服务化改造、大模型训练/微调交付、模型轻量化（量化/剪枝）等，成功支撑亿级并发生产需求
- 工程技能：精通容器技术，7 年+容器化实战经验，深度实践 Kubernetes（K8S）集群管理（含 GPU 调度策略开发），主导 AI 服务性能调优与安全加固。多次完成原子 AI 能力交付，ASR/OCR/TTS 等容器化改造及第三方系统对接。在编程语言方面，精通 JAVA 和 Python，具备 Golang/C++跨语言协同优化经验，熟练掌握常见流行的开发框架和各种中间件，擅长在应用系统中对 AI 能力工程优化
- 算法知识：聚焦算法工程化落地，掌握扎实的数据结构算法知识，系统掌握模式识别方向基础理论，掌握机器学习/深度学习，熟练应用特征工程以及提示词工程及数据挖掘技术，推动多项 CV/NLP 能力上线生产
- 行业交付：新媒体央视 AI 中台（私有化部署丨支撑亿级日请求），省级智慧交通平台，网络安全态势感知，智能制造 MES 系统等。全流程技术管理：覆盖架构设计→定制开发→高可用保障→人员赋能。
- 软技能：具备技术管理、工程问题解决(主导处理 300+生产环境问题)；项目管理、技术方案编写能力，擅长需求转化、跨团队协作与技术培训；懂技术专利申请技巧等。

教育经历

2021.01-2024.06　　**伊利诺伊理工学院**

计算机科学 | 硕士

研究方向：数据挖掘、自然语言处理

2011.09-2015.06 **四川大学锦城学院**

电子信息工程 | 本科

相关培训

- **Udacity 深度学习学位认证**
- **青云 QCP 认证**
- **腾讯云 AI 产品交付能力认证**
- **工信部生成式人工智能应用工程师认证**

工作经历

2022.1-至今 **腾云悦智（腾讯集团子公司）**

AI 架构师/平台研发 | 计算机软件

项目：央视新媒体 AI 中台私有化 SaaS 项目 | 平台升级迁移项目

- 主要负责央视 5G 新媒体 AI 中台项目的私有化交付，定制化交付(100 多节点、150 多 GPU)，覆盖对客技术咨询、技术管理、运行保障与培训支持全流程技术管理
- 负责客户现场的技术统筹：组织处理关键问题、协调多团队问题定位、推进技术变更与跨部门技术沟通
- 对客构建高可用运维体系，日常巡检、安全漏洞治理、组件升级、性能调优与重大活动保障等任务，显著提升系统稳定性
- 主导腾讯 AI 产品在央视私有化交付和售后服务：覆盖 OCR、ASR、人脸识别、内容审核、翻译、跨模态检索等数十项 AI 能力的多款产品的私有化交付验收，以及 AI 原子能力接口对接第三方应用系统；协调产品团队进行定制开发与优化迭代
- 支持第三方厂商的 AI 服务在腾讯专有云交付，解决智算平台在网络、存储、权限、资源调度、监控等方面的工程化问题，推动平台可用性提升
- 智算平台国产化适配评测，完成主流大模型的交付测试与多个厂商的平台评估，推动异构算力环境下的产品兼容性优化
- CPU、GPU 算力资源优化，根据 AI 智算平台的节点级、业务级、服务级不同维度的可观性数据，分析挖掘数据中心运营数据，采用综合优化策略，对 AI 智算平台优化扩缩容服务调度策略（NUMA 拓扑感知调度、节点负载感知、时间潮汐调度、无状态化改造、Device Plugin 适配、Volcano 调度器增强、超卖支持等），优化 CPU 和 GPU 节点资源比例，以提高算力资源的利用率，减少碎片资源，推动未来 MLOps 的 AI 辅助驾驶的调度研究实践。

关键成果：

- 成功支持央视大模型智算平台上线运行，日均处理请求量上亿，系统全年可用性达 99.99%
- 负责并解决超 300 起工程类大小疑难问题，运行问题大幅减少
- 推动多个 AI 能力快速上线智算平台，纳管了客户所有 AI 模型能力；并协助客户技术部门在前台业务场景中推广应用 AI 能力的可行性方案
- 整理流程规范文档，推动平台交付 AI 能力流程标准化，减少交付周期 20%以上

- 推动售后维保处理流程化，引导客户运维人员问题响应，我方人员远程支持

2020.12-2021.12 **杭州安恒信息**

资深 Java 工程师 | 网络/信息安全

项目：多个网安项目

- 主导工作流程引擎架构设计，实现流程编排、节点控制、动态配置等关键功能模块，提升系统灵活性与可扩展性，相关设计（基于有向图的自循环检测算法）已申请国家技术专利
- 深度负责公司态势感知产品核心模块研发，如智能研判，响应处置，重大活动保障，产品获得多项行业权威认证
- 负责多个百万级定制项目的技术开发，主要负责数据采集、风险预警、指挥调度、告警联动等核心功能开发和定制，实现项目高质量交付

关键成果：

- 专利级引擎设计实现模块解耦与灵活配置，已应用于公司多个安全类产品
- 持续优化交付效率与客户体验，年度项目交付满意度超过 100%，获公司项目部公开表扬

2019.10-2020.11 **杭州麟云科技**

研发主管 | 计算机软件+智慧交通

项目：某省交通运输非法营运监控平台（省级政府项目）

- 技术架构设计：主导平台技术架构升级，设计高可用微服务架构与基础中台能力，支撑省级各市级交通单位的业务场景联动，打通数据孤岛，提升系统弹性与扩展性
- 全流程管理产品迭代，从需求分析、负责原型设计，到上线交付，完成执法流程全链路数字化重构，显著提升执法效率与业务合规性
- 建立标准化项目交付体系：输出可复用组件库、编写产品化的技术架构设计-测试-交付的技术文档，建立标准化交付文档，推动项目快速交付验收以上
- 搭建 10 人技术团队（App 端/前端/后端），实施敏捷开发流程，引入测试驱动开发机制、减少协作开发中依赖耦合，显著提升代码开发效率

关键成果：

- 平台顺利上线并在全省多个城市推广，支撑上亿交通数据实时处理与监控
- 架构设计实现服务解耦与弹性交付，有效支撑多个业务版本并行运行

2017.11-2019.9 **浙江吉利**

高级研发工程师 | 汽车制造

项目：集团 MES 系统平台| 低代码工具建设

- 负责集团级 MES 系统基础框架组件的设计与研发，负责构建统一开发范式与模块化开发体系，支撑集团 13 个工厂基地智能化改造
- 主导开发低代码可视化搭建平台，覆盖数据库管理、流程建模、表单配置、逻辑编排等能力，支持 70%以上业务场景快速上线，极大提升交付效率
- 建立跨基地复用组件体系：通过微服务 API 标准化、组件抽象与模板统一，提升系统的可复用性与跨场景适配能力
- 提炼通用业务模块库（如生产调度、质量追溯、物料跟踪等），推动组件复用率从 30%提升至 80%，有效降低维护成本与重复开发

关键成果：

- 提升系统的复用性和多数据库兼容性
- 支持 70%以上业务场景快速上线，极大提升交付效率

2015.7-2017.7 **中软国际**

研发工程师 | 计算机软件

项目：无线通信网络性能分析预测与扩容工具

- 项目概述：3G 无线通信网数据分析产品的原型设计开发与迭代，覆盖数据采集、处理、建模与可视化分析、一键报告等全生命周期流程
- 设计并实现基于 Python 的数据清洗与特征处理模块。从业务角度主导工具开发，把人工分析规则和机器学习算法集成，与算法研发对接，集成多种机器学习算法（如聚类、异常检测）用于异常流量识别与容量预测。并与小组团队一起从桌面工具改造成上云 web 产品
- 工具支持对全球各大运营商的华为无线通信网 3G 基站设备的数据进行性能评估，辅助客户进行网络优化与扩容决策

关键成果：

- 实现基础分析自动化处理流程，通信数据分析任务极大缩短（1 周→1 天），大量节省人工数据分析时间
- 工具已从桌面工具改造成上云 web 产品

项目经历

2025.8-至今 **AI 浏览器智能体**

Owner

- 项目介绍：该项目基于 playwright 和 langchain 框架构建的智能体浏览器自动化助手，通过集成 LLM 能力，实现了自然语言驱动的网页浏览、信息检索和复杂交互操作，能够智能处理各种网页自动化任务
- 技术设计：使用 python 语言、python 元编程、playwright 框架、langchain 框架、LLM 模型、FastAPI 的 web 框架，采用智能体分层设计，感知层、推理层、执行层完成整个架构模块设计
- 功能支持：智能网页浏览、多轮会话、用户会话状态持久化、多搜索引擎支持、双界面操作（web 界面和命令行界面）、插件化定制网站 agent、拟人化操作等
- 成果：可实现通用网页的常见任务的自动化任务，部分特定网站（小红书、知乎）的定制化插件扩展

2025.1-至今 **智算平台升级项目**

AI 交付架构师

- 技术方案设计：采用数据一次性全量迁移和动态增量迁移，按业务分功能模块，逐步升级等综合策略迁移。前期准备：业务层从重要性、容易性综合角度排序多次迁移；技术层按照组件依赖顺序，一次性迁移环境配置和数据，把一个项目作为整体最小迁移颗粒，服务接口镜像流量灰度测试，逐步迁移完成。前期评估环境数据规模、网关接口异同、冗余资源大小、版本差异（定制开发）、迁移工具开发等，还有节点层面 GPU 驱动适配、回退方案等各项风险评估。实施：一次性迁移数据和配置，进行灰度测试；启动一个业务服务，切换该业务的流量；逐步数次迁移切换完成
- 项目挑战：智算平台无法原地升级，需要迁移数据切换新版本环境方式迁移，且 GPU 资源冗余较少，无法完整一次性迁移切换，对业务影响仅允许闪断，不允许停服切换
- 架构设计：标准化智算产品采用多集群异构算力管理（global 集群+arm 子集群），数据标注模块在图片标注数据的基础上，增加了多模态数据标注能力，开发训练模块增加了远程开发调试能力，推理模块中增加了大模型微调产品能力，产品基本架构和旧版本保持一致

- 成果：主导技术方案可行最优方向，反逼产品研发内部提高技术能力，满足了客户对生产环境的持续性运行要求，赢得客户长期信任，反哺内部产品优化迭代和研发能力

2022.1-2024 **AI 中台私有化项目**

AI 交付架构师

- 架构设计：平台基于腾讯 TCS 构建的 AI Saas 平台，底层通过 K8S 集群实现服务高可用，设计弹性伸缩及智能灾备机制。通过产品多个版本的迭代，央视二期项目改造，统一了客户环境的独立的标注系统、训练平台、推理平台，并对主要 AI 服务能力进行容器化改造，支持了 GPU 分卡、定制调度器策略，并支持 logo、地标、旗帜等图像处理任务进行小样本训练能力
- 需求分析：深度跟踪了解客情，收集 50+项大小功能需求，拉各不同产品团队做需求评估，或定制或集成到标准产品体系，协助客户在台里内部推广体验 AI 能力，协助客户的第三方在腾讯专有云算力平台上交付 AI 能力服务，业务接口对接、服务健康告警等，不断提升产品体验
- 交付实施：完成核心智算产品交付并输出多套运维手册和使用手册，主导客户多场培训
- 成果：客户环境问题越来越少，集群越来越稳定；统一纳管了客户的所有 GPU 算力，支撑了视频前台、媒资、审核，以及各个栏目的制作播出，并协助客户 OA 系统中集成有关知识库问答 AI 能力

2023.06-2023.08 **简易关系型数据库存储引擎**

owner

- 项目描述：该项目是高级数据库设计课程要求的一个项目作业，要求用 C++从 0 到 1 实现完整单机存储引擎，支持 8 KB 页式存储、LRU-K 缓冲、可变长记录管理及磁盘 B+ 树索引的数据库存储引擎
- 技术要点：Storage Manager 模块中用 POSIX API 实现页级 I/O，支持 4 KB 定长页，并在文件头部预留元数据区记录；Buffer Manager 实现 FIFO + LRU + CLOCK 三种置换策略，LRU 采用时间戳+双向链表，降低命中延迟 30%；开发内存页帧池，支持多文件并发访问，设计脏页回写机制，保证多线程 pin/unpin 安全和数据一致性；Record Manager 模块基于槽式页布局管理定长记录，支持增删改查，开发表达式引擎解析 WHERE 条件
- 成果：用 5k 行 C++把 MySQL-InnoDB 的“页→缓冲→记录→索引”核心链路完整复现

2023.3-2023.6 **AI 公平性研究**

owner

- 项目描述：当下 LLM 的伦理安全问题、数据质量等问题等生活中越来越重视，构建包含 5 类模型的情感分析系统，基于 EEC 语料库设计控制变量实验，量化发现：预训练模型（RoBERTa/mBERT）比传统模型（LR/SVM）放大 3.2 倍社会偏见（$p<0.01$）
- 关键技术：因果推断/反事实数据生成/Scikit-learn 优化/Transformers 微调
- 提出分层消偏框架：通过中性词替换+嵌入向量修正，使 LR 模型在保持 78.4%准确率前提下，性别偏差降低 40%，相关方法推广至 LightGBM 获 34%偏差削减
- 开发偏见诊断工具包：支持 T 检验/McNemar 自动化报表，检测效率提升 22 倍；发现 3 类典型社会偏见案例被纳入课程教学素材
- 成果：在零 GPU 资源约束下，通过 sag 优化器+特征压缩，使 LR 模型训练速度达 2 秒级，满足工业级实时分析需求；采用双重统计验证（T 检验+McNemar），首次发现 mBERT 在种族维度存在偏差反转现象

2021.09 – 2021.12 **视频超分辨率系统（DRN-S）**

owner

个人项目，核心代码：https://github.com/cyneck/cs584project

- 项目描述：基于 DRN-S 双闭环网络，在 PyTorch 中重构并优化官方实现，仅用 4.8 M 参数量即可把 540p 视频实时放大至 4K，PSNR 32.68 dB，比原始 ESRGAN 提升 0.4 dB 且推理速度快 2.3×
- 算法复现：阅读 CVPR’20 论文，用 PyTorch 1.8 完整实现 Dual Regression Network，含主网络 + 对偶回归网络闭环训练
- 工程优化：将 3D 卷积改为分组卷积 + PixelShuffle，GPU 显存占用从 8 GB 降至 3.2 GB；用 FFmpeg 抽帧、moviepy 做色彩空间对齐
- 一键脚本：封装 Test.py，支持参数化调用
- 成果：论文到落地，在消费级显卡上跑通实时 4K 超分，验证了轻量化 SR 模型的可行性

2020.12-2020.03 **workflow 工作流程引擎研发**

技术负责人

- 项目描述：基于项目中很多的流程模型，进行了功能需求调研，基于 flowable 深度开发设计的一款可动态加签的、可版本管理的流程引擎，来解决项目中因流程变动而不好扩展的问题
- 技术栈：SpringBoot + Flowable + Mysql + Mybatisplus + Liquidbase
- 成果：核心功能动态加签基于图算法和智能识别流程方向（已获得实用发明专利）

2020.6-2020.9 **浙江省交通运输非法营运监控平台**

技术负责人

- 项目描述：基于浙江省的高速路网监控、城市街道路网监控的大数据，对各类车辆进行监控分析，打通打破省市县三级数据壁垒，建立跨区域联防联控机制，实现浙江省交通运输车辆信息共享；对可疑车辆进行重点识别、监控，并对黑车进行路线预测，实施布控抓捕
- 系统架构：基于 Spring Cloud 微服务+HBase 构建，整合全省各个地市交通数据，支撑日均亿级数据处理，实现单体/微服务灵活交付
- 规则引擎优化：引入 Easy-Rules 实现规则动态加载，迭代周期压缩 85%（1 周→1 天），研判规则开发效率提升
- 成果：可单体和可微服务化的设计，增加了交付实施的灵活性；重构规则研判系统降低 30%开发成本，设计车辆特征模型，提升布控精准度

2019.12-2020.06 **旅游知识图谱构建**

owner

- 项目描述：从 0 到 1 构建旅游领域知识图谱，设计多源数据融合架构：基于 Selenium+BS4 爬取 7 大平台数据，使用“地理-语义联合实体对齐算法”，解决 37%数据冲突问题，构建含 5 万+节点的行业旅游图谱
- 开发 Neo4j 存储优化方案：通过索引优化与分布式部署，实现千级关系节点的 50ms 级实时查询，支撑智能问答（89.3%准确率）与行程规划核心场景
- 主导 D3.js 可视化引擎开发：实现 3D 力导向图谱探索系统，支持动态 CRUD 操作与智能路径生成，成为后续行程

规划功能的底层引擎

- 技术栈：Neo4j + 知识抽取 + 多源数据对齐 + Selenium/BS4 + D3.js + SPO 三元组
- 成果：设计实现了友好的批量数据模型设计和数据导入工具

2017.09-2017.11 **自行车共享需求预测神经网络**

owner

个人独立项目，核心代码：https://github.com/cyneck/dlnd_cyclehop_predict

- 项目描述：用纯 NumPy 从零实现并训练 3 层全连接神经网络，在 Kaggle 公共数据集上把 RMSE 降低 17%，为共享出行公司提供了可落地的单车投放决策工具
- 端到端数据工程：清洗 2.3 M 条骑行记录，构造 27 维时空特征（天气、节假日、POI 密度等），使用 Box-Cox 变换解决右偏分布，缺失值插补后保留 99.6% 样本
- 模型设计：手动推导反向传播，实现 Sigmoid、Dropout、L2 正则化及 Mini-Batch SGD；通过网格搜索确定最优隐层维度 128→64，学习率 3e-3，Batch Size 为 128